

Optimización Convexa

Mauricio Junca

Índice

1. Preliminares de cálculo	2
2. Criterios básicos de optimalidad	6
2.1. Mínimos globales	6
2.2. Funciones suaves	7
3. Métodos numéricos para optimización suave	9
3.1. Métodos de búsqueda lineal - Caso general	9
3.2. Método de región de confianza - Caso general suave	18
4. Conjuntos y funciones convexas	24
4.1. Conjuntos convexas	24
4.2. Funciones convexas	27
5. Optimización convexa suave	30
5.1. Método del descenso del gradiente - Caso C^1 convexo	30
5.1.1. Caso fuertemente convexo	32
5.2. Método acelerado de Nesterov	34
5.3. Método de (Quasi-)Newton	35
5.3.1. Caso fuertemente convexo C^2	35
5.3.2. Caso <i>self-concordant</i>	35
6. Conceptos básicos de análisis convexo	36
6.1. Subgradientes I	38
6.2. Teoremas de separación I	40
6.3. Subgradientes II	42
6.3.1. Cálculo con subgradientes	44
6.4. Teoremas de separación II	47
6.5. Funciones conjugadas	48
7. Optimización convexa no suave	49
7.1. Método del subgradiente	49
7.2. Método del (sub)gradiente estocástico	52
7.3. Método del gradiente proximal	54

8. Programación lineal	57
8.1. Conos y poliedros	57
8.2. Dualidad	60
9. Problemas convexos generales	62
9.1. Ejemplos	63
9.1.1. Programación cuadrática	63
9.1.2. Programación cónica	64
9.1.3. Programación seminfinita - Problema de momentos	65
9.2. Puntos de silla y condiciones KKT	66
9.3. Dualidad fuerte	69
9.3.1. Prueba del teorema	71
10. Minimización con restricciones	72
10.1. Minimización con restricciones de igualdad	73
10.2. Método de barrera	74
10.2.1. Cono semidefinido positivo	76
10.3. Método primal-dual	76
10.3.1. Programación lineal	79
10.3.2. Programación cuadrática	81
10.3.3. Programación semidefinida	82

1. Preliminares de cálculo

Sea $U \subset \mathbb{R}^n$ abierto y $f : U \mapsto \mathbb{R}$. Dado $x \in U$, si el siguiente límite existe

$$\lim_{t \rightarrow 0} \frac{f(x_1, \dots, x_i + t, \dots, x_n) - f(x)}{t},$$

lo denotamos como $\frac{\partial f}{\partial x_i}(x)$ y la llamamos derivada parcial de f con respecto a x_i . Si todas las derivadas parciales existen, llamamos al vector $\nabla f(x)$ cuyas entradas son las derivadas parciales gradiente de f en x . La derivada direccional de f en x en la dirección $d \in \mathbb{R}^n$ está dada por

$$f'(x; d) := \lim_{t \downarrow 0} \frac{f(x + td) - f(x)}{t},$$

siempre que exista. Notemos que $f'(x; e_i) = \frac{\partial f}{\partial x_i}(x)$, donde e_i es el i -ésimo vector canónico.

Definición. Decimos que f es Gâteaux diferenciable en $x \in U$ si la derivada direccional $f'(x; d)$ existe para toda $d \in \mathbb{R}^n$ y además es una función lineal en d .

Notemos que si f es Gâteaux diferenciable en x , entonces para $d \in \mathbb{R}^n$ se tiene que

$$f'(x; d) = f'(x; d_1 e_1 + \dots + d_n e_n) = d_1 f'(x; e_1) + \dots + d_n f'(x; e_n) = \langle \nabla f(x), d \rangle.$$

Definición. Decimos que f es Fréchet diferenciable en $x \in U$ si existe una función lineal $\ell : \mathbb{R}^n \mapsto \mathbb{R}$, es decir, si existe $\ell \in \mathbb{R}^n$ tal que $\ell(x) = \langle \ell, x \rangle$, tal que

$$\lim_{\|h\| \rightarrow 0} \frac{f(x+h) - f(x) - \langle \ell, x \rangle}{\|h\|} = 0.$$

Otra forma equivalente de diferenciabilidad en el sentido de Fréchet es decir que

$$f(x+h) = f(x) + \langle \ell, x \rangle + o(\|h\|).$$

Veamos algunas propiedades y relaciones de las diferentes nociones de diferenciabilidad.

1. Si f es Fréchet diferenciable en x entonces f es continua en x .
2. Si f es Fréchet diferenciable en x , entonces f es Gâteaux diferenciable y además $\ell = \nabla f(x)$. Esto se sigue de tomar $h = te_i$ para cada i con $t > 0$. Así que

$$f(x+h) = f(x) + \langle \nabla f(x), h \rangle + o(\|h\|).$$

3. El converso no es cierto. (Ejercicio)
4. Sea f Gâteaux diferenciable en U y sean $x, y \in U$ tales que el segmento que une a x con y , que lo notamos como $[x, y]$, esté contenido en U . Sea $g(t) = f(x + t(y-x))$ para $t \in [0, 1]$, entonces g es una función diferenciable y además $g'(t) = \langle \nabla f(x + t(y-x)), y-x \rangle$. Por el teorema de valor medio existe $\bar{t}$ tal que $g(1) - g(0) = g'(\bar{t})$, es decir, existe $z \in [x, y]$ tal que $f(y) - f(x) = \langle \nabla f(z), y-x \rangle$. Esto no es más que el Teorema del Valor Medio.

De lo anterior, si además asumimos que todas las derivadas parciales son continuas en x , se tiene que para todo $h \in \mathbb{R}^n$ tal que el segmento $[x, x+h] \subset U$ existe $x_h \in [x, x+h]$ tal que

$$f(x+h) - f(x) - \langle \nabla f(x), h \rangle = \langle \nabla f(x_h) - \nabla f(x), h \rangle = o(\|h\|),$$

dado que la continuidad de las derivadas implica que

$$\lim_{\|h\| \rightarrow 0} \frac{|\langle \nabla f(x_h) - \nabla f(x), h \rangle|}{\|h\|} \leq \lim_{\|h\| \rightarrow 0} \|\nabla f(x_h) - \nabla f(x)\| = 0.$$

Es decir, f es Fréchet diferenciable en x . Lo anterior motiva la siguiente definición.

Definición. Si $f : U \mapsto \mathbb{R}$ es Gâteaux diferenciable en U y ∇f es continua en U , decimos que $f \in C^1(U)$.

Las definiciones anteriores las podemos extender al caso vectorial, es decir, cuando $F : U \mapsto \mathbb{R}^m$. En este caso, si F es Gâteaux diferenciable, entonces para toda $d \in \mathbb{R}^n$ la derivada direccional en x satisface que

$$F'(x; d) = Ad,$$

donde A es una matriz de $m \times n$ cuyas entradas están dadas por $A_{ij} = \frac{\partial F_i(x)}{\partial x_j}$, la llamamos la matriz Jacobiana de F en x y la denotamos como $DF(x)$. Si F es Fréchet diferenciable en $x \in U$, entonces

$$\lim_{\|h\| \rightarrow 0} \frac{\|F(x+h) - F(x) - DF(x)h\|}{\|h\|} = 0.$$

Ahora, si $f : U \mapsto \mathbb{R}$ y ∇f es Gâteaux diferenciable en x , entonces llamamos la matriz Hessiana de f en x a $Hf(x) := D^2f(x) := D(\nabla f)(x)$ con entradas

$$Hf(x)_{ij} = \frac{\partial^2 f}{\partial x_i \partial x_j}(x).$$

Si además las entradas de la matriz Hessiana son continuas en U , decimos que $f \in C^2(U)$. En este caso sabemos que la matriz es simétrica.

Fórmula de Taylor

Si $f \in C^2(U)$ y $x, y \in U$ son tales que $[x, y] \subset U$, entonces existe $z \in [x, y]$ tal que

$$f(y) = f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2} \langle Hf(z)(y - x), y - x \rangle.$$

Otra forma equivalente de escribir la fórmula de Taylor de segundo orden de f es la siguiente: Para todo $h \in \mathbb{R}^n$ tal que el segmento $[x, x+h] \subset U$ se tiene que

$$f(x+h) = f(x) + \langle \nabla f(x), h \rangle + \frac{1}{2} \langle Hf(x)h, h \rangle + o(\|h\|^2).$$

Ejemplo. Consideremos la función cuadrática

$$f(x) = \frac{1}{2} \langle Ax, x \rangle + \langle b, x \rangle + c,$$

con A matriz simétrica. En este caso es fácil ver que $\nabla f(x) = Ax + b$ y $Hf(x) = A$.

Para el siguiente ejemplo necesitamos algunos resultados sobre matrices simétricas semi-definidas positivas. Recordemos que una matriz simétrica de $n \times n$ es semidefinida positiva, y lo notamos como $A \succeq 0$, si para todo $x \in \mathbb{R}^n$ se tiene que $\langle Ax, x \rangle \geq 0$, y es definida positiva ($A \succ 0$) si la desigualdad es estricta para todo $x \neq 0$. Como A es simétrica, el teorema espectral garantiza que existen matrices diagonal Λ y ortogonal Q que diagonalizan a $A = Q\Lambda Q^T$. Luego

$$\langle Ax, x \rangle = \langle \Lambda Q^T x, Q^T x \rangle.$$

Esto implica que $A \succeq 0$ si y solo si $\Lambda \succeq 0$ y lo último es equivalente si y solo si las entradas de la diagonal Λ son no negativas. Así que los valores propios de A son no negativos. Análogamente $A \succ 0$ si y solo si sus valores propios son positivos. Además, se tiene que

$$\lambda_{\min}(A)\|x\|^2 \leq \langle Ax, x \rangle \leq \lambda_{\max}(A)\|x\|^2.$$

We compute the Taylor series of f at a given positive definite matrix $X \in S^n$ and a given direction $D \in S^n$. We have

$$\begin{aligned} f(X + tD) &= \ln \det(X + tD) = \ln \det(X^{1/2}(I + tX^{-1/2}DX^{-1/2})X^{1/2}) \\ &= \ln \det X + \ln \det(I + tX^{-1/2}DX^{-1/2}). \end{aligned}$$

Writing $\overline{D} := X^{-1/2}DX^{-1/2} = Q^T \Lambda Q$, where Q is an orthogonal matrix and $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$, we obtain

$$\begin{aligned} f(X + tD) - f(X) &= \ln \det(I + t\overline{D}) = \ln \det(Q^T(I + t\Lambda)Q) \\ &= \ln \det(I + t\Lambda) = \ln \prod_{i=1}^n (1 + t\lambda_i) = \sum_{i=1}^n \ln(1 + t\lambda_i). \end{aligned}$$

Since

$$\ln(1 + s) = \int \frac{ds}{1 + s} = \int (1 - s + s^2 - s^3 + \dots) ds = s - \frac{s^2}{2} + \frac{s^3}{3} + \dots,$$

we have

$$f(X + tD) - f(X) = \sum_{i=1}^n t\lambda_i - \frac{t^2}{2}\lambda_i^2 + o(t^2) = t \text{tr}(\Lambda) - \frac{t^2}{2} \text{tr}(\Lambda^2) + o(t^2).$$

Noting that

$$\text{tr}(\Lambda) = \text{tr}(Q^T \Lambda Q) = \text{tr}(\overline{D}) = \text{tr}(X^{-1}D) = \langle X^{-1}, D \rangle,$$

and similarly

$$\text{tr}(\Lambda^2) = \text{tr}(X^{-1/2}DXD^{-1/2})^2 = \text{tr}(X^{-1}DX^{-1}D) = \langle X^{-1}DX^{-1}, D \rangle,$$

we obtain

$$f(X + tD) = f(X) + t\langle X^{-1}, D \rangle - \frac{t^2}{2}\langle X^{-1}DX^{-1}, D \rangle + o(t^2).$$

Theorem 1.25 again implies that $\nabla f(X) = X^{-1}$ and $D^2 f(X)(D) = X^{-1}DX^{-1}$. Here $D^2 f(X)(D)$ can be written, using the tensor (Kronecker) product notation,

$$(X^{-1} \otimes X^{-1})(D) := X^{-1}DX^{-1}.$$

In summary, we have

$$\nabla f(X) = X^{-1}, \quad D^2 f(X) = -X^{-1} \otimes X^{-1}. \quad (1.13)$$

Figura 1: Cálculo del gradiente y la segunda derivada de la función $\ln \det(X)$.

Ejemplo. Consideremos ahora un ejemplo más elaborado. Recordemos que en el espacio vectorial de las matrices cuadradas de $n \times n$ se puede definir naturalmente el producto interno

$$\langle X, Y \rangle := \sum_{i,j} x_{ij}y_{ij} = \text{tr}(X^T Y) = \text{tr}(Y^T X).$$

Si solo consideramos el subespacio de matrices simétricas, es claro que $\langle X, Y \rangle = \text{tr}(XY) =$

$\text{tr}(YX)$. Del subespacio anterior vamos a considerar el subconjunto abierto $U = \{X : X \succ 0\}$, es decir, el conjunto de matrices simétricas definidas positivas. Sea $f : U \mapsto \mathbb{R}$ definida como

$$f(X) = \ln \det(X).$$

Esta es una función muy importante en el estudio de la programación semidefinida. Queremos calcular ∇f y $D^2 f$. Ver Figura 1.

2. Criterios básicos de optimalidad

En esta sección vamos a introducir los primeros conceptos, resultados y algoritmos de optimización sin restricciones para funciones suaves. Vamos a denotar $\mathcal{B}_r(x) = \{y \in \mathbb{R}^n : \|x - y\| \leq r\}$.

Definición. Sea $f : U \mapsto \mathbb{R}$ con $U \subset \mathbb{R}^n$ abierto. Decimos que $x \in U$ es

- un mínimo local de f si existe $r > 0$ tal que $f(x) \leq f(y)$ para todo $y \in \mathcal{B}_r(x)$ y mínimo local estricto si la desigualdad es estricta para todo $y \neq x$,
- un mínimo global de f si $f(x) \leq f(y)$ para todo $y \in U$ y mínimo global estricto si la desigualdad es estricta para todo $y \neq x$,
- un punto crítico de f si es Gâteaux diferenciable en x y $\nabla f(x) = 0$.

2.1. Mínimos globales

El primer criterio para la existencia de mínimos globales es el teorema de Weierstrass. Este dice que si $f : K \mapsto \mathbb{R}$ es continua y K es compacto, entonces existe x^* que es mínimo global. Existen versiones más débiles de este teorema como la siguiente.

Teorema (Weierstrass). Sea $f : U \mapsto \mathbb{R}$ continua tal que existe un $\alpha \in \mathbb{R}$ para el cual el conjunto de nivel $L_\alpha = \{x \in U : f(x) \leq \alpha\}$ es no vacío y compacto. Entonces existe $x^* \in U$ mínimo global.

Prueba. Sean $f^* = \inf_{x \in U} f(x)$ y $\{x_k\} \subset U$ sucesión minimizadora de f , es decir, $f(x_k) \rightarrow f^*$. Asumimos también que la sucesión está contenida en L_α , y como es compacto, existe una subsucesión convergente en L_α , es decir, $x_{k_n} \rightarrow x^*$. Por la continuidad de f se tiene además que $f(x_{k_n}) \rightarrow f(x^*) = f^*$, luego x^* es un mínimo global. $\square$

Definición. Sea U no acotado, decimos que es coerciva si $f(x) \rightarrow \infty$ cuando $\|x\| \rightarrow \infty$.

Notemos que si f es continua entonces L_α debe ser cerrado para todo $\alpha \in \mathbb{R}$. Además, si f es coerciva todo conjunto de nivel debe ser acotado, así que si f es continua y coerciva garantizamos las condiciones del teorema anterior. Ahora, la continuidad de la función tampoco es necesaria para tener que los conjuntos de nivel sean cerrados, veamos.

Definición. Una función $f : \mathbb{R}^n \mapsto \mathbb{R} \cup \{+\infty\}$ es semicontinua por debajo en $x \in \mathbb{R}^n$ si

$$f(x) \leq \liminf_{k \rightarrow \infty} f(x_k),$$

para toda sucesión tal que $x_k \rightarrow x$. Es semicontinua por debajo en $\mathbb{R}^n$ si lo es para todo x .

Definición. Sea $f : \mathbb{R}^n \mapsto \mathbb{R} \cup \{+\infty\}$. El epígrafo de f se define como

$$\text{epi}(f) = \{(x, t) \in \mathbb{R}^n \times \mathbb{R} : f(x) \leq t\}.$$

Teorema. Sea $f : \mathbb{R}^n \mapsto \mathbb{R} \cup \{+\infty\}$. Las siguientes son equivalentes;

1. f es semicontinua por debajo en $\mathbb{R}^n$.
2. $\text{epi}(f)$ es cerrado.
3. Los conjuntos de nivel L_α son cerrados para todo $\alpha \in \mathbb{R}$.

Prueba.

1. $\implies$ 2. Sea $\{(x_k, t_k)\} \subset \text{epi}(f)$ una sucesión que converge a (x, t) . Queremos ver que $(x, t) \in \text{epi}(f)$, es decir, que $f(x) \leq t$. Puesto que $x_k \rightarrow x$ se tiene, por ser f semicontinua por debajo, que

$$f(x) \leq \liminf_{k \rightarrow \infty} f(x_k) \leq \liminf_{k \rightarrow \infty} t_k = t.$$

2. $\implies$ 3. Sea $\alpha \in \mathbb{R}$ y sea $\{x_k\} \subset L_\alpha$ que converge a x . Entonces $\{(x_k, \alpha)\} \subset \text{epi}(f)$, y como es cerrado, entonces $(x, \alpha) \in \text{epi}(f)$, es decir, $x \in L_\alpha$.
3. $\implies$ 1. Supongamos que existe una sucesión $\{x_k\}$ que converge a x tal que $f(x) > \liminf_{k \rightarrow \infty} f(x_k)$ y sea α tal que $f(x) > \alpha > \liminf_{k \rightarrow \infty} f(x_k)$. Por lo tanto existe una subsucesión $\{x_{k_n}\}$ tal que $f(x_{k_n}) \leq \alpha$ para toda n , es decir, que está contenida en L_α . Como el conjunto de nivel es cerrado y la subsucesión converge a x , entonces $f(x) \leq \alpha$ y tenemos una contradicción.

□

Con lo anterior tenemos entonces que si f es semicontinua por debajo en $\mathbb{R}^n$ y coerciva, entonces tiene un mínimo global.

2.2. Funciones suaves

Pasemos ahora a resultados en donde vamos a asumir que f es suave. Los siguientes resultados se basan en el teorema de Taylor. Siempre vamos a asumir que $f : U \mapsto \mathbb{R}$ con U abierto.

Teorema (Condición necesaria de primer orden para mínimo local). Si f es Gâteaux diferenciable en U , entonces todo mínimo local es un punto crítico.

Prueba. Sea x mínimo local de f y sea $d \in \mathbb{R}^n$. Entonces

$$f'(x; d) = \lim_{t \downarrow 0} \frac{f(x + td) - f(x)}{t} \geq 0$$

pues x es mínimo local. Así que tomando $d = -\nabla f(x)$ se tiene que $0 \leq \langle \nabla f(x), d \rangle = -\|\nabla f(x)\|^2$ lo que implica que $\nabla f(x) = 0$. $\square$

Teorema (Condición de necesaria segundo orden para mínimo local). Sea $f \in C^2(U)$. Si x es mínimo local entonces la matriz $Hf(x)$ es semidefinida positiva.

Prueba. Sabemos que para todo $x \in U$ existen $\nabla f(x)$ y matriz simétrica $Hf(x)$ tal que para todo $h \in \mathbb{R}^n$ se tiene que

$$f(x + th) = f(x) + t\langle \nabla f(x), h \rangle + \frac{t^2}{2}\langle Hf(x)h, h \rangle + o(t^2).$$

Por el teorema anterior se tiene además que $\nabla f(x) = 0$, así que

$$0 \leq f(x + th) - f(x) = \frac{t^2}{2}\langle Hf(x)h, h \rangle + o(t^2),$$

y al dividir por t^2 y haciendo $t \rightarrow 0$ se obtiene que $\langle Hf(x)h, h \rangle \geq 0$. $\square$

Teorema (Condición suficiente de segundo orden para mínimo local estricto). Sea $f \in C^2(U)$. Si x es un punto crítico de f y $Hf(x)$ es definida positiva, entonces x es un mínimo local estricto.

Prueba. Sea $\lambda > 0$ el valor propio mínimo de la matriz Hessiana $Hf(x)$, tenemos entonces que $\langle Hf(x)d, d \rangle \geq \lambda\|d\|^2$ para todo $d \in \mathbb{R}^n$. Usando el teorema de Taylor tenemos que para $d \in \mathbb{R}^n$ con $\|d\|$ suficientemente pequeño se tiene que

$$\begin{aligned} f(x + d) &= f(x) + \langle \nabla f(x), d \rangle + \frac{1}{2}\langle Hf(x)d, d \rangle + o(\|d\|^2) \\ &\geq f(x) + \|d\|^2 \left(\frac{\lambda}{2} + \frac{o(\|d\|^2)}{\|d\|^2} \right) \\ &> f(x). \end{aligned}$$

$\square$

Por último tenemos una condición suficiente para un mínimo global, veremos que esto está relacionado con el concepto de convexidad.

Teorema (Condición suficiente de segundo orden para mínimo global). Sea $f \in C^2(U)$ tal que la matriz Hessiana $Hf(z) \succeq 0$ para todo $z \in U$. Si $x \in U$ es un punto crítico de f tal que para todo $y \in U$ el segmento $[x, y] \subset U$, entonces es mínimo global.

Prueba. Sea $y \in U$, a partir del teorema de Taylor tenemos que existe $z \in (x, y)$ tal que

$$f(y) = f(x) + \frac{1}{2}\langle Hf(z)(y - x), y - x \rangle \geq f(x).$$

$\square$

En el resultado anterior, si la matriz Hessiana es definida positiva, entonces x es un mínimo global estricto.

3. Métodos numéricos para optimización suave

Ahora vamos ver métodos numéricos para resolver el siguiente problema sin restricciones

$$\min_{x \in \mathbb{R}^n} f(x),$$

imponiendo diferentes condiciones para f , pero siempre vamos a asumir que existe un valor mínimo denotado por f^* . Existen dos grandes familias de métodos de minimización si restricciones:

- de búsqueda lineal
- de región de confianza

Ahondaremos principalmente en la primera familia, considerando diferentes condiciones para f . Primero veremos el caso cuando f es una función suave (C^1 y C^2).

3.1. Métodos de búsqueda lineal - Caso general

Inicialmente supongamos que $f : \mathbb{R}^n \rightarrow \mathbb{R}$ con $f \in C^1(\mathbb{R}^n)$. Adicionalmente, vamos a pedir que $\nabla f(\cdot)$ sea Lipschitz con constante L , es decir, para todo $x, y \in \mathbb{R}^n$ se cumple que

$$\|\nabla f(x) - \nabla f(y)\| \leq L\|x - y\|.$$

En cada iteración de los métodos de búsqueda lineal se calcula una *dirección* p_k y luego se decide qué tanto se avanza en esa dirección, de esta forma, cada iteración está dada por

$$x_{k+1} = x_k + \alpha_k p_k, \tag{1}$$

donde $\alpha_k > 0$ es el *tamaño del paso*. Así, el éxito del método depende de la escogencia de la dirección y el tamaño del paso. Recordemos que la derivada direccional cumple que

$$f'(x; p) := \lim_{\alpha \downarrow 0} \frac{f(x + \alpha p) - f(x)}{\alpha} = \langle \nabla f(x), p \rangle,$$

es decir, es la tasa de crecimiento de la función en la dirección p , y como estamos minimizando, en cada iteración debemos buscar direcciones tales que

$$\langle \nabla f(x_k), p_k \rangle < 0.$$

A estas las llamamos direcciones de descenso.

Nota. En muchos casos tienen la forma $p_k = -B_k^{-1} \nabla f(x_k)$ donde B_k es una matriz definida positiva, lo que garantiza que sí sea de descenso.

Comencemos por la escogencia más sencilla: $p_k = -\nabla f(x_k)$ (o $B_k = I$) y un tamaño de paso constante, este es el caso más sencillo del método del *descenso del gradiente*. Por el teorema fundamental del cálculo, para $x, y \in \mathbb{R}^n$, se tiene que

$$f(y) - f(x) = \int_0^1 \langle \nabla f(x + \alpha(y - x)), y - x \rangle d\alpha, \tag{2}$$

y usando esto tenemos que

$$\begin{aligned}
|f(y) - f(x) - \langle \nabla f(x), y - x \rangle| &= \left| \int_0^1 \langle \nabla f(x + \alpha(y - x)) - \nabla f(x), y - x \rangle d\alpha \right| \\
&\leq \int_0^1 |\langle \nabla f(x + \alpha(y - x)) - \nabla f(x), y - x \rangle| d\alpha \\
&\leq \int_0^1 \|\nabla f(x + \alpha(y - x)) - \nabla f(x)\| \|y - x\| d\alpha \\
&\leq \int_0^1 \alpha L \|y - x\|^2 d\alpha = \frac{L}{2} \|y - x\|^2.
\end{aligned} \tag{3}$$

Examinemos ahora el resultado de un paso del método. Sea $y = x - \alpha \nabla f(x)$, por (3) tenemos que

$$\begin{aligned}
f(y) &\leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L}{2} \|y - x\|^2 \\
&= f(x) - \alpha \|\nabla f(x)\|^2 + \frac{\alpha^2}{2} L \|\nabla f(x)\|^2 \\
&= f(x) - \alpha \left(1 - \frac{\alpha}{2} L\right) \|\nabla f(x)\|^2,
\end{aligned}$$

luego, tomando $\alpha = \frac{1}{L}$ se alcanza la mínima cota superior para el decrecimiento de la función en el nuevo punto y , y esta es

$$f(y) \leq f(x) - \frac{1}{2L} \|\nabla f(x)\|^2.$$

Así que el método del descenso del gradiente con tamaño de paso constante $\frac{1}{L}$ tiene la forma

$$x_{k+1} = x_k - \frac{1}{L} \nabla f(x_k)$$

y se cumple que

$$f(x_k) - f(x_{k+1}) \geq \frac{1}{2L} \|\nabla f(x_k)\|^2. \tag{4}$$

Sumando la desigualdad anterior sobre $k = 0, \dots, N$ tenemos que

$$\frac{1}{2L} \sum_{k=0}^N \|\nabla f(x_k)\|^2 \leq f(x_0) - f(x_{N+1}) \leq f(x_0) - f^*, \tag{5}$$

luego $\|\nabla f(x_k)\| \rightarrow 0$ cuando $k \rightarrow \infty$. Si definimos $g_N^* = \min_{0 \leq k \leq N} \|\nabla f(x_k)\|$, de (5) obtenemos que

$$g_N^* \leq \frac{1}{\sqrt{N+1}} (2L(f(x_0) - f^*))^{1/2}.$$




Figura 2: Condición de Armijo

Así que si queremos obtener un punto cuyo gradiente sea menor a ϵ , esto se garantiza cuando $N + 1 \geq \frac{2L}{\epsilon^2} (f(x_0) - f^*)$.

En muchos casos no es posible conocer la constante L de la función, así que debemos escoger el tamaño del paso de una forma distinta. La forma más usada en la práctica es escoger el tamaño del paso de tal forma que satisfagan ciertas condiciones de *decrecimiento suficiente*. Veamos estas condiciones para el caso general con dirección de descenso p_k , es decir, consideremos que cada iteración está dada por (1).

Condición de Armijo

Se busca un tamaño de paso α_k tal que

$$f(x_k) - f(x_{k+1}) \geq -c_1 \alpha_k \langle \nabla f(x_k), p_k \rangle,$$

para alguna constante $c_1 \in (0, 1)$. Si definimos las funciones $\phi(\alpha) := f(x_k + \alpha p_k)$ y $l(\alpha) := f(x_k) + c_1 \alpha \langle \nabla f(x_k), p_k \rangle$. Puesto que $c_1 \in (0, 1)$ entonces $\phi(\alpha) \leq l(\alpha)$ para valores de α suficientemente pequeños, como se muestra en la figura 2. Un algoritmo muy usado para encontrar un tamaño de paso que satisfaga la condición de Armijo es el llamado *backtracking*:

```

Escoger  $\bar{\alpha} > 0$ ,  $\rho \in (0, 1)$ . Se define  $\alpha \leftarrow \bar{\alpha}$ ;
mientras  $f(x_k + \alpha p_k) > f(x_k) + c_1 \alpha \langle \nabla f(x_k), p_k \rangle$  hacer
    |  $\alpha \leftarrow \rho \alpha$ ;
fin
Escoger  $\alpha_k = \alpha$ .

```

Algoritmo 1: *Backtracking*

Únicamente esta condición no es suficiente pues se pueden escoger tamaños de paso muy pequeños y el método se haría muy lento. Adicionar alguna de las siguientes dos condiciones buscan evitar esto.

Condición de Goldstein

Se busca un tamaño de paso α_k tal que

$$f(x_k) - f(x_{k+1}) \leq -c_2 \alpha_k \langle \nabla f(x_k), p_k \rangle,$$

para alguna constante $c_2 \in (c_1, 1)$. La figura 3 ilustra los tamaño de paso que satisfacen las condiciones de Armijo y Goldstein. Una desventaja de esta condición es que puede excluir los mínimos de ϕ . Ahora, por (3) tenemos que

$$f(x_k) - f(x_{k+1}) \geq -\alpha_k \langle \nabla f(x_k), p_k \rangle - \frac{L}{2} \alpha_k^2 \|p_k\|^2,$$

y combinando con la condición de Goldstein tenemos que

$$\alpha_k \geq \frac{2(c_2 - 1)}{L} \frac{\langle \nabla f(x_k), p_k \rangle}{\|p_k\|^2}. \quad (6)$$

Condición de Wolfe

Se busca un tamaño de paso α_k tal que

$$\langle \nabla f(x_{k+1}), p_k \rangle \geq c_2 \langle \nabla f(x_k), p_k \rangle,$$

para alguna constante $c_2 \in (c_1, 1)$. Notemos que el lado izquierdo de la desigualdad anterior es precisamente $\phi'(\alpha_k)$ y el lado derecho $c_2 \phi'(0) < \phi'(0)$. La figura 4 ilustra los tamaño de paso que satisfacen la condición de Wolfe. Un desventaja de esta condición es que podemos tener α_k tal que $\phi'(\alpha_k)$ es positiva muy grande. Ahora, la condición implica que

$$\langle \nabla f(x_{k+1}) - \nabla f(x_k), p_k \rangle \geq (c_2 - 1) \langle \nabla f(x_k), p_k \rangle.$$




Figura 3: Condición de Goldstein




Figura 4: Condición de Wolfe

Por otro lado, la condición de Lipschitz del gradiente implica que

$$\langle \nabla f(x_{k+1}) - \nabla f(x_k), p_k \rangle \leq \alpha_k L \|p_k\|^2,$$

y combinando estas dos desigualdades tenemos que

$$\alpha_k \geq \frac{c_2 - 1}{L} \frac{\langle \nabla f(x_k), p_k \rangle}{\|p_k\|^2}. \quad (7)$$

Nota. Notemos que la existencia de α_k que satisfaga la condición de Goldstein o la de Wolfe está garantizada pues f está acotada por debajo y es $C^1(\mathbb{R}^n)$.

Vamos a usar (6) y (7), junto con la condición de Armijo, para mostrar la convergencia. Para esto definimos θ_k el ángulo entre p_k y $-\nabla f(x_k)$, es decir

$$\cos \theta_k = \frac{-\langle \nabla f(x_k), p_k \rangle}{\|\nabla f(x_k)\| \|p_k\|}.$$

Así, obtenemos que

$$f(x_k) - f(x_{k+1}) \geq -\beta \frac{(\langle \nabla f(x_k), p_k \rangle)^2}{\|p_k\|^2} = \beta \cos^2 \theta_k \|\nabla f(x_k)\|^2,$$

donde $\beta = \frac{2c_1(1-c_2)}{L}$ para la condición de Goldstein y $\beta = \frac{c_1(1-c_2)}{L}$ para la de Wolfe. Notemos la similitud con (4), así que si sumamos sobre k , tenemos, como en (5), que

$$\beta \sum_{k=0}^N \cos^2 \theta_k \|\nabla f(x_k)\|^2 \leq f(x_0) - f(x_{N+1}) \leq f(x_0) - f^*,$$

luego $\cos^2 \theta_k \|\nabla f(x_k)\| \rightarrow 0$ cuando $k \rightarrow \infty$. Si se garantiza que $\cos \theta_k \geq \delta > 0$ para todo k , como en el descenso del gradiente, tenemos que $\|\nabla f(x_k)\| \rightarrow 0$.

Nota. Es importante notar que lo único que podemos garantizar es la convergencia de los gradientes a 0.

Supongamos ahora que $f \in C^2(\mathbb{R}^n)$ con matriz Hessiana $Hf(\cdot)$ Lipschitz con constante K . Adicionalmente suponemos que existe un óptimo del problema x^* y que la matriz Hessiana $Hf(x^*)$ es definida positiva con valores propios en el intervalo $[m, M]$. Veamos diferentes métodos (y sus pruebas de convergencia).

Nota. Recordemos que para matrices simétricas la norma espectral (la misma norma operador) está dada por

$$\|A\| = \sqrt{\lambda_{\max}(AA^T)} = \max_i |\lambda_i|$$

y satisface para todo $x \in \mathbb{R}^n$ que $\|Ax\| \leq \|A\|\|x\|$. Dadas A, B matrices simétricas notamos $A \preceq B$ si $B - A$ es semidefinida positiva.

Método del descenso del gradiente

Consideremos el método del descenso del gradiente. Como x^* es mínimo, tenemos que $\nabla f(x^*) = 0$, luego

$$\begin{aligned} \nabla f(x_k) &= \nabla f(x_k) - \nabla f(x^*) = \int_0^1 Hf(x^* + \alpha(x_k - x^*))(x_k - x^*) d\alpha \\ &=: G_k(x_k - x^*), \end{aligned}$$

luego

$$x_{k+1} - x^* = x_k - x^* - \alpha_k G_k(x_k - x^*) = (I - \alpha_k G_k)(x_k - x^*).$$

Queremos ahora estimar la norma espectral de $I - \alpha_k G_k$. Para esto vemos a usar los supuestos sobre f . Dados $x, y \in \mathbb{R}^n$ y $r := \|y - x\|$, por la condición de Lipschitz tenemos que

$$\|Hf(y) - Hf(x)\| \leq K\|y - x\| = Kr,$$

por lo tanto

$$Hf(x) - rKI \preceq Hf(y) \preceq Hf(x) + rKI. \quad (8)$$

Si tomamos $y = x^* - \alpha(x_k - x^*)$ y $x = x^*$ y definimos $r_k = \|x_k - x^*\|$, entonces

$$\begin{aligned} (m - \alpha Kr_k)I &\preceq Hf(x^*) - \alpha Kr_k I \\ &\preceq Hf(x^* - \alpha(x_k - x^*)) \\ &\preceq Hf(x^*) + \alpha Kr_k I \\ &\preceq (M + \alpha Kr_k)I. \end{aligned}$$

De la definición de G_k e integrado ambos extremos de las desigualdades anteriores tenemos que

$$\left(m - K\frac{r_k}{2}\right)I \preceq G_k \preceq \left(M + K\frac{r_k}{2}\right)I,$$

y por lo tanto

$$\left(1 - \alpha_k \left(M + K \frac{r_k}{2}\right)\right) I \preceq I - \alpha_k G_k \preceq \left(1 - \alpha_k \left(m - K \frac{r_k}{2}\right)\right) I.$$

Así que

$$\|I - \alpha_k G_k\| \leq \max \left\{ 1 - \alpha_k \left(m - K \frac{r_k}{2}\right), \alpha_k \left(M + K \frac{r_k}{2}\right) - 1 \right\} =: h(\alpha_k).$$

Notemos que si $r_k < \bar{r} = \frac{2m}{K}$, entonces $h(\alpha_k) < 1$ para α_k suficientemente pequeño y, además, h se minimiza cuando

$$1 - \alpha_k \left(m - K \frac{r_k}{2}\right) = \alpha_k \left(M + K \frac{r_k}{2}\right) - 1,$$

es decir, cuando $\alpha_k^* = \frac{2}{m+M}$, en este caso $h(\alpha_k^*) = \frac{M-m+Kr_k}{M+m} < 1$. Por lo tanto

$$\begin{aligned} r_{k+1} &= \|x_{k+1} - x^*\| = \|(I - \alpha_k G_k)(x_k - x^*)\| \\ &\leq \|I - \alpha_k G_k\| r_k \leq r_k \left(\frac{M - m + Kr_k}{M + m} \right). \end{aligned}$$

Finalmente, se puede mostrar con un poco de álgebra (ver pág. 31-32 de [N]) que si $r_0 < \bar{r}$, es decir, si el método se inicia en un punto cercano a x^* , entonces el método del descenso del gradiente converge con tamaño $\alpha_k = \frac{2}{m+M}$ converge con una tasa *lineal* dada por

$$r_k \leq \frac{r_0 \bar{r}}{\bar{r} - r_0} \left(1 - \frac{2m}{M + 3m} \right)^k.$$

Método de Newton

El método de Newton es un método muy usado para encontrar una solución a sistemas de ecuaciones no lineales. Si $F : \mathbb{R}^n \rightarrow \mathbb{R}^n$ es $C^1(\mathbb{R}^n)$ y hacemos la aproximación de F alrededor de x y $x^* \approx x + \delta x$ donde $F(x^*) = 0$, entonces tenemos el sistema lineal

$$F(x) + DF(x)\delta x = 0,$$

donde $DF(x)$ es el Jacobiano de F en x . Si este Jacobiano es no singular, tenemos entonces que $\delta x = -[DF(x)]^{-1}F(x)$, y esto genera el método iterativo dado por

$$x_{k+1} = x_k - [DF(x_k)]^{-1}F(x_k).$$

Sabemos que todo óptimo de nuestro problema de minimización debe ser un punto estacionario, es decir, debe satisfacer que $\nabla f(x^*) = 0$, luego, si aplicamos el método a $\nabla f(\cdot)$ obtenemos

$$x_{k+1} = x_k - [Hf(x_k)]^{-1}\nabla f(x_k). \quad (9)$$

Notemos que no tenemos necesariamente que $-[Hf(x_k)]^{-1}\nabla f(x_k)$ sea una dirección de descenso (la matriz Hessiana podría ser singular incluso), aún así, bajo los supuestos iniciales podemos garantizar la convergencia del método siempre que iniciemos lo suficientemente cerca de x^* . Como antes notamos $r_k = \|x_k - x^*\|$, entonces de (8) tenemos que

$Hf(x_k) \succeq Hf(x^*) - r_k KI \succeq (m - r_k K)I$, por lo tanto si $r_k < \frac{m}{K}$, entonces $Hf(x_k)$ es definida positiva y además

$$\|[Hf(x_k)]^{-1}\| \leq \frac{1}{m - r_k K}. \quad (10)$$

Para mostrar la convergencia del método vamos a seguir la misma idea que usamos en el método del descenso del gradiente. Tenemos que:

$$\begin{aligned} x_{k+1} - x^* &= x_k - x^* - [Hf(x_k)]^{-1} \nabla f(x_k) \\ &= x_k - x^* - [Hf(x_k)]^{-1} (\nabla f(x_k) - \nabla f(x^*)) \\ &= x_k - x^* - [Hf(x_k)]^{-1} \int_0^1 Hf(x^* + \alpha(x_k - x^*)) (x_k - x^*) d\alpha \\ &= [Hf(x_k)]^{-1} \int_0^1 (Hf(x_k) - Hf(x^* + \alpha(x_k - x^*))) (x_k - x^*) d\alpha \\ &=: [Hf(x_k)]^{-1} \tilde{G}_k(x_k - x^*). \end{aligned}$$

Ahora,

$$\begin{aligned} \|\tilde{G}_k\| &\leq \int_0^1 \|Hf(x_k) - Hf(x^* + \alpha(x_k - x^*))\| d\alpha \\ &\leq \int_0^1 K(1 - \alpha) \|x_k - x^*\| d\alpha = \frac{r_k}{2} K, \end{aligned}$$

y usando (10)

$$r_{k+1} \leq \frac{r_k K}{2(m - r_k K)} r_k < r_k,$$

siempre que $\frac{r_k K}{2(m - r_k K)} < 1$ o equivalentemente, siempre que $r_k < \frac{2m}{3K} < \frac{m}{K}$. Así que, si $r_0 < \frac{2m}{3K}$ el método converge a una tasa *cuadrática* dada por

$$r_{k+1} \leq \frac{3K r_k^2}{2m}.$$

Finalmente, para evitar que el método diverja se puede iniciar la búsqueda incluyendo un tamaño de paso en el método:

$$x_{k+1} = x_k - \alpha_k [Hf(x_k)]^{-1} \nabla f(x_k),$$

y en la etapa final tomar $\alpha_k = 1$.

Métodos Quasi-Newton

Lo que tenemos hasta ahora es un método que solo usa información de primer orden de

f con una tasa de convergencia lineal y un método que usa información de segundo orden (por lo tanto requiere más operaciones en cada iteración) con una tasa de convergencia cuadrática. Veamos ahora una familia de métodos que están en la mitad de los dos anteriores. Consideremos las siguientes aproximaciones cuadráticas de f alrededor de un punto $\bar{x} \in \mathbb{R}^n$:

$$\begin{aligned}\phi_1(x) &= f(\bar{x}) + \langle \nabla f(\bar{x}), x - \bar{x} \rangle + \frac{1}{2\alpha} \|x - \bar{x}\|^2, \quad \alpha > 0 \\ \phi_2(x) &= f(\bar{x}) + \langle \nabla f(\bar{x}), x - \bar{x} \rangle + \frac{1}{2} \langle Hf(\bar{x})(x - \bar{x}), x - \bar{x} \rangle\end{aligned}$$

Nota. Cuando $\alpha = \frac{1}{L}$ se tiene que ϕ_1 es la cota que se obtiene en (3).

Notemos que los únicos puntos críticos de estas aproximaciones son respectivamente

$$\begin{aligned}x_1 &= \bar{x} - \alpha \nabla f(\bar{x}) \\ x_2 &= \bar{x} - [Hf(\bar{x})]^{-1} \nabla f(\bar{x}),\end{aligned}$$

que son precisamente los pasos iterativos de los métodos anteriores. Lo anterior sugiere que a partir de diferentes aproximaciones cuadráticas podemos construir diferentes métodos. Dada B_k matriz definida positiva, si consideremos la aproximación

$$\phi_k(x) = f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{1}{2} \langle B_k(x - x_k), x - x_k \rangle, \quad (11)$$

cuyo mínimo es $x_k + p_k$, con $p_k = -B_k^{-1} \nabla f(x_k)$, la cual es una dirección de descenso (recuerde la nota al inicio de la sección). Tenemos entonces el proceso iterativo dado por

$$x_{k+1} = x_k + \alpha_k p_k$$

donde α_k se puede escoger con las condiciones y criterios vistos antes. La idea ahora es escoger B_{k+1} con dos criterios: a) que únicamente use información de primer orden, b) que sea fácil de calcular a partir de B_k . Consideremos la aproximación ϕ_{k+1} , queremos que el gradiente de esta aproximación coincida con el gradiente de f en los puntos x_k y x_{k+1} , entonces

$$\nabla \phi_{k+1}(x) = \nabla f(x_{k+1}) + B_{k+1}(x - x_{k+1})$$

y así $\nabla \phi_{k+1}(x_{k+1}) = \nabla f(x_{k+1})$ y $\nabla \phi_{k+1}(x_k) = \nabla f(x_{k+1}) + B_{k+1}(x_k - x_{k+1}) = \nabla f(x_k)$. Concluimos que $H_{k+1} := B_{k+1}^{-1}$ debe satisfacer la ecuación

$$H_{k+1} y_k = s_k,$$

donde $y_k = \nabla f(x_{k+1}) - \nabla f(x_k)$ y $s_k = x_{k+1} - x_k$. Una condición necesaria para poder satisfacer esta ecuación es que $\langle y_k, s_k \rangle > 0$, la cual se tiene si f es estrictamente convexa (recuerden el ejercicio 11 del cap. 5 de [G]), de lo contrario, escogiendo α_k tal que satisfaga la condición de Wolfe también se tiene (¿puede mostrarlo?). Una vez se garantice esta condición necesaria, hay infinitas formas de escoger H_{k+1} (o B_{k+1}), pero queremos algunas que estén

cerca de H_k (o B_k). El método más popular desde el punto de vista computacional es el BFGS (Broyden-Fletcher-Goldfarb-Shanno), y resulta de resolver el problema de optimización

$$\begin{aligned} \text{mín} \quad & \|H - H_k\|_* \\ \text{sujeto a} \quad & H = H^T \\ & Hy_k = s_k, \end{aligned}$$

donde $\|A\|_* = \|W^{1/2}AW^{1/2}\|_F$, $\|C\|_F = \sum_{i,j} C_{ij}^2$, llamada la norma de Frobenius, y W es definida positiva tal que $Ws_k = y_k$. En este caso se puede mostrar que la única solución del problema de optimización es

$$\begin{aligned} H_{k+1} &= (I - \rho_k s_k y_k^T) H_k (I - \rho_k y_k s_k^T) + \rho_k s_k s_k^T \\ &= H_k - \rho_k H_k y_k s_k^T - \rho_k s_k y_k^T H_k + \rho_k^2 s_k y_k^T H_k y_k s_k^T + \rho_k s_k s_k^T \\ &= H_k + \rho_k^2 (\langle y_k, s_k \rangle + \langle H_k y_k, y_k \rangle) s_k s_k^T - \rho_k (H_k y_k s_k^T + s_k y_k^T H_k), \end{aligned} \quad (12)$$

donde $\rho_k = \frac{1}{\langle y_k, s_k \rangle}$. Además, usando que

$$(A + UV^T)^{-1} = A^{-1} - A^{-1}U(I + V^T A U)^{-1}V^T A^{-1},$$

se puede mostrar que

$$B_{k+1} = B_k - \frac{B_k s_k s_k^T B_k}{\langle B_k s_k, s_k \rangle} + \rho_k y_k y_k^T. \quad (13)$$

Otras formas de calcular H_{k+1} las pueden ver en la la pág. 41 de [N]. Se puede mostrar también que la convergencia de este método es mejor que la del descenso del gradiente pero peor que la de Newton bajo las mismos supuestos iniciales de esta sección.

3.2. Método de región de confianza - Caso general suave

En este método se define una aproximación (cuadrática) de la función f , la cual llamamos modelo, y una región (un bola en realidad) alrededor de la iteración actual x_k sobre la cual se tiene suficiente *confianza* de que el modelo es adecuado, y luego escogemos como x_{k+1} el mínimo (o una aproximación de este) del modelo sobre la región. De acuerdo a qué tanto cambia la función en el nuevo punto con respecto a cambio en el modelo, se decide expandir o contraer la región de confianza alrededor del nuevo punto. Veamos los detalles de este método, para esto asumimos que $f \in C^1(\mathbb{R}^n)$ y que su gradiente es Lipschitz con constante L . Recordemos la aproximación de f dada en (11)

$$m_k(p) := \phi_k(x_k + p) = f(x_k) + \langle \nabla f(x_k), p \rangle + \frac{1}{2} \langle B_k p, p \rangle,$$

donde, en este caso, a B_k solo se pide que sea simétrica. Así, en cada iteración se busca resolver el problema

$$\begin{aligned} p_k := \text{mín} \quad & m_k(p) = f(x_k) + \langle \nabla f(x_k), p \rangle + \frac{1}{2} \langle B_k p, p \rangle \\ \text{sujeto a} \quad & \|p\| \leq \Delta_k, \end{aligned} \quad (14)$$

con $\Delta_k > 0$. Para resolver este problema debemos decidir dos cosas: a) B_k , el cual podría ser $Hf(x_k)$ en caso de que exista, y en este caso sería el método de Newton con región de confianza, o alguna de las matrices usadas en los métodos quasi-Newton. b) Δ_k , para esto definimos

$$\rho_k = \frac{f(x_k) - f(x_k + p_k)}{m_k(0) - m_k(p_k)}.$$

Notemos que el denominador siempre es positivo pues p_k es el óptimo del problemas. Ahora, si $\rho_k < 0$ la función en el nuevo punto es mayor que en x_k y por tanto debemos rechazarlo, si $\rho_k \approx 1$ entonces el modelo es una buena aproximación de la función y por lo tanto podemos expandir la región de confianza, y si $0 < \rho_k \ll 1$ el modelo no es tan confiable y debemos contraer la región. Así, tenemos el siguiente algoritmo:

```

Escoger  $\hat{\Delta} > 0$ ,  $\Delta_0 \in (0, \hat{\Delta})$  y  $\eta \in (0, \frac{1}{4})$ ;
para  $k = 0, 1, 2, \dots$  hacer
    Obtener  $p_k$  (o una aproximación);
    Calcular  $\rho_k$ ;
    si  $\rho_k < \frac{1}{4}$  entonces
         $\Delta_{k+1} = \frac{1}{4}\Delta_k$ ;
    fin
    en otro caso
        si  $\rho_k > \frac{3}{4}$  y  $\|p_k\| = \Delta_k$  entonces
             $\Delta_{k+1} = \min(2\Delta_k, \hat{\Delta})$ ;
        fin
        en otro caso
             $\Delta_{k+1} = \Delta_k$ ;
        fin
    fin
    si  $\rho_k > \eta$  entonces
         $x_{k+1} = x_k + p_k$ ;
    fin
    en otro caso
         $x_{k+1} = x_k$ ;
    fin
fin

```

Algoritmo 2: *Región de confianza*

Ahora, resolver el problema (14) en cada iteración puede ser muy costoso, y tampoco es necesario para mostrar la convergencia, como veremos más adelante. Una primera aproximación es el denominado *punto de Cauchy*, que denotamos con p_k^C . Primero vamos a considerar una aproximación lineal de f en lugar de la cuadrática y resolvemos el problema

$$\begin{aligned} \hat{p}_k := \min \quad & f(x_k) + \langle \nabla f(x_k), p \rangle \\ \text{sujeto a} \quad & \|p\| \leq \Delta_k, \end{aligned}$$

cuya solución está dada por

$$\hat{p}_k = -\frac{\Delta_k}{\|\nabla f(x_k)\|} \nabla f(x_k).$$

Notemos que esta dirección es la misma del descenso del gradiente. El siguiente paso es escoger un tamaño de paso que minimice el modelo dentro de la región de confianza, esto es, solucionar el problema

$$\begin{aligned} \tau_k &= \arg \min_{\tau \geq 0} \{m_k(\tau \hat{p}_k) : \|\tau \hat{p}_k\| \leq \Delta_k\} \\ &= \arg \min_{0 \leq \tau \leq 1} m_k(\tau \hat{p}_k) \\ &= \arg \min_{0 \leq \tau \leq 1} -\tau \Delta_k \|\nabla f(x_k)\| + \frac{\tau^2 \Delta_k^2}{2 \|\nabla f(x_k)\|^2} \langle B_k \nabla f(x_k), \nabla f(x_k) \rangle \\ &= \begin{cases} 1 & \text{si } \langle B_k \nabla f(x_k), \nabla f(x_k) \rangle \leq 0 \\ \min \left(1, \frac{\|\nabla f(x_k)\|^3}{\Delta_k \langle B_k \nabla f(x_k), \nabla f(x_k) \rangle} \right) & \text{de lo contrario.} \end{cases} \end{aligned}$$

Tenemos entonces que

$$p_k^C = -\frac{\tau_k \Delta_k}{\|\nabla f(x_k)\|} \nabla f(x_k).$$

La pregunta ahora es ¿qué tan bueno es el punto de Cauchy? Tratemos de dar una respuesta estimando $m_k(0) - m_k(p_k^C)$. Por simplicidad vamos a omitir el índice k y a definir $g = \nabla f(x)$. Supongamos que $\langle Bg, g \rangle \leq 0$, entonces

$$\begin{aligned} m(0) - m(p^C) &= f(x) - m\left(-\frac{\Delta}{\|g\|}g\right) \\ &= \Delta \|g\| - \frac{\Delta^2}{2\|g\|^2} \langle Bg, g \rangle \\ &\geq \Delta \|g\|. \end{aligned}$$

Consideremos ahora el caso $\langle Bg, g \rangle > 0$ y $\frac{\|g\|^3}{\Delta \langle Bg, g \rangle} \leq 1$, entonces

$$\begin{aligned} m(0) - m(p^C) &= \frac{\|g\|^4}{\langle Bg, g \rangle} - \frac{\|g\|^4}{2\langle Bg, g \rangle} \\ &= \frac{\|g\|^4}{2\langle Bg, g \rangle} \\ &\geq \frac{\|g\|^4}{2\|g\|^2\|B\|} = \frac{1}{2}\|g\| \frac{\|g\|}{\|B\|}. \end{aligned}$$

Y finalmente, si $\langle Bg, g \rangle > 0$ y $\frac{\|g\|^3}{\Delta \langle Bg, g \rangle} > 1$, entonces

$$\begin{aligned} m(0) - m(p^C) &= \Delta \|g\| - \frac{\Delta^2}{2\|g\|^2} \langle Bg, g \rangle \\ &\geq \Delta \|g\| - \frac{\Delta^2}{2\|g\|^2} \frac{\|g\|^3}{\Delta} \\ &= \frac{1}{2}\Delta \|g\|. \end{aligned}$$

Podemos concluir entonces que

$$m_k(0) - m_k(p_k^C) \geq \frac{1}{2} \|\nabla f(x_k)\| \min \left(\Delta_k, \frac{\|\nabla f(x_k)\|}{\|B_k\|} \right), \quad (15)$$

lo cual nos garantiza un decrecimiento mínimo del modelo en el punto de Cauchy. Veamos que cualquier solución aproximada de (14) que satisfaga este decrecimiento mínimo es suficiente para mostrar la convergencia del algoritmo 2.

Teorema. Supongamos que en el algoritmo 2, p_k satisface (15) y que $\|B_k\| \leq \beta$ para todo k . Entonces $\lim_{k \rightarrow \infty} \|\nabla f(x_k)\| = 0$.

Prueba. Sea $\{x_k\}_{k \geq 0}$ la sucesión generada por el algoritmo 2 y tomemos m tal que $0 < \|\nabla f(x_m)\| =: 2\epsilon$ y $R = \frac{\epsilon}{L}$. Entonces, si $\|x - x_m\| \leq R$ se tiene que

$$\|\nabla f(x)\| \geq \|\nabla f(x_m)\| - \|\nabla f(x) - \nabla f(x_m)\| \geq 2\epsilon - LR = \epsilon.$$

Supongamos que $\{x_k\}_{k \geq m} \subset \mathcal{B}_R(x_m)$, por lo tanto $\|\nabla f(x_k)\| \geq \epsilon$. De (3) y (15) tenemos que para todo $k \geq m$

$$\begin{aligned} |\rho_k - 1| &= \left| \frac{m_k(p_k) - f(x_k + p_k)}{m_k(0) - m_k(p_k)} \right| \\ &= \frac{|f(x_k) - f(x_k + p_k) - \langle \nabla f(x_k), p_k \rangle| + \frac{1}{2} |\langle B_k p_k, p_k \rangle|}{|m_k(0) - m_k(p_k)|} \\ &\leq \frac{\frac{L}{2} \|p_k\|^2 + \frac{\|B_k\|}{2} \|p_k\|^2}{\frac{1}{2} \|\nabla f(x_k)\| \min \left(\Delta_k, \frac{\|\nabla f(x_k)\|}{\|B_k\|} \right)} \\ &\leq \frac{\|p_k\|^2 (L + \|B_k\|)}{\epsilon \min \left(\Delta_k, \frac{\epsilon}{\|B_k\|} \right)} \\ &\leq \frac{\Delta_k^2 (L + \|B_k\|)}{\epsilon \min \left(\Delta_k, \frac{\epsilon}{\|B_k\|} \right)} \leq \frac{\Delta_k^2 (L + \beta)}{\epsilon \min \left(\Delta_k, \frac{\epsilon}{\beta} \right)}. \end{aligned} \quad (16)$$

Ahora, si $\Delta_k \leq \overline{\Delta} := \frac{1}{2} \frac{\epsilon}{L + \beta} < \frac{\epsilon}{\beta}$, entonces $|\rho_k - 1| \leq \frac{1}{2}$ y por lo tanto $\rho_k > \frac{1}{4}$ y del algoritmo obtenemos que $\Delta_{k+1} \geq \Delta_k$. Por otro lado, si $\Delta_{k+1} = \frac{1}{4} \Delta_k < \Delta_k$, del algoritmo tenemos que $\rho_k < \frac{1}{4}$ y por lo tanto $\Delta_k > \overline{\Delta}$. Lo anterior implica que para todo $k \geq m$ se tiene

$$\Delta_k \geq \min \left(\Delta_m, \frac{\overline{\Delta}}{4} \right). \quad (17)$$

Caso 1: Existe una subsucesión $\{k_j\}_{j \geq 0}$ tal que $\rho_{k_j} \geq \frac{1}{4}$, entonces, de la descripción del algoritmo y (15), tenemos que

$$\begin{aligned} f(x_{k_j}) - f(x_{k_j+1}) &= f(x_{k_j}) - f(x_{k_j} + p_{k_j}) \\ &= \rho_{k_j} (m_{k_j}(0) - m_{k_j}(p_{k_j})) \\ &\geq \frac{1}{4} \frac{1}{2} \epsilon \min \left(\Delta_{k_j}, \frac{\epsilon}{\beta} \right), \end{aligned}$$

lo que implica que $\Delta_{k_j} \rightarrow 0$, de lo contrario f no estaría acotada por debajo. Pero esto contradice (17).

Caso 2: $\rho_k < \frac{1}{4}$ para todo k suficientemente grande. Pero esto también implica que $\Delta_k \rightarrow 0$ y de nuevo es una contradicción.

Todo lo anterior implica que existe $l > m$ tal que $x_{l+1} \notin B_R(x_m)$ y además $\{x_k\}_{k=m}^l \subset B_R(x_m)$, luego, usando (15),

$$\begin{aligned} f(x_m) - f(x_{l+1}) &= \sum_{k=m}^l f(x_k) - f(x_{k+1}) \\ &\geq \sum_{x_k \neq x_{k+1}} \eta(m_k(0) - m_k(p_k)) \\ &\geq \frac{\eta}{2}\epsilon \sum_{x_k \neq x_{k+1}} \min\left(\Delta_k, \frac{\epsilon}{\beta}\right). \end{aligned}$$

Si $\Delta_k \leq \frac{\epsilon}{\beta}$ para todo $k = m, \dots, l$, entonces

$$\begin{aligned} f(x_m) - f(x_{l+1}) &\geq \frac{\eta}{2}\epsilon \sum_{x_k \neq x_{k+1}} \Delta_k \\ &\geq \frac{\eta}{2}\epsilon \sum_{x_k \neq x_{k+1}} \|x_k - x_{k+1}\| \\ &\geq \frac{\eta}{2}\epsilon R = \frac{\eta\epsilon^2}{2L}, \end{aligned}$$

y por otro lado, si $\Delta_k > \frac{\epsilon}{\beta}$ para algún k , entonces $f(x_m) - f(x_{l+1}) \geq \frac{\eta\epsilon^2}{2\beta}$. En cualquier caso

$$f(x_m) - f(x_{l+1}) \geq \frac{\eta}{4\max(L, \beta)} \|\nabla f(x_m)\| > 0,$$

y como esto se cumple para todo m tal que $\|\nabla f(x_m)\| > 0$, tenemos que $\|\nabla f(x_k)\| \rightarrow 0$. $\square$

Ahora, simplemente escoger el punto de Cauchy en cada iteración no es lo más eficiente, ni interesante pues tendríamos el método del descenso del gradiente con un tamaño de paso particular. Supongamos que B_k es definida positiva y notemos por $p_k^*(\Delta_k)$ el óptimo de (14) en función del tamaño de la región de confianza. Es claro que $p_k^B = -B_k^{-1}\nabla f(x_k)$ es el óptimo global del modelo y es también el óptimo del subproblema si $\|p_k^B\| \leq \Delta_k$. Si, por el contrario, Δ_k es muy pequeño, el término cuadrático de m_k es despreciable y por lo tanto $p_k^*(\Delta_k)$ estaría muy cercano al punto de Cauchy con $\tau_k = 1$. Para tamaños de Δ_k intermedios, $p_k^*(\Delta_k)$ sigue una trayectoria similar a la se ve en la figure 5. El método *dogleg* busca aproximar esta trayectoria por dos rectas. Como B_k es definida positiva, sabemos que el mínimo del modelo en la dirección $-\nabla f(x_k)$ está dado por

$$p_k^U = -\frac{\|\nabla f(x_k)\|^2}{\langle B_k \nabla f(x_k), \nabla f(x_k) \rangle} \nabla f(x_k),$$




Figura 5: Método *dogleg*

luego la primera recta va del origen a p_k^U y la segunda de p_k^U a p_k^B . Esta trayectoria la podemos parametrizar como

$$\tilde{p}_k(\tau) = \begin{cases} \tau p_k^U & \text{si } 0 \leq \tau \leq 1 \\ p_k^U + (\tau - 1)(p_k^B - p_k^U) & \text{si } 1 \leq \tau \leq 2. \end{cases} \quad (18)$$

Queremos ahora minimizar el modelo a lo largo de esta trayectoria sujeto a estar dentro de la región de confianza. Para esto veamos que $\|\tilde{p}_k(\tau)\|$ es creciente y $m_k(\tilde{p}_k(\tau))$ es decreciente. Esto es claro cuando $\tau \in [0, 1]$, así que solo vamos considerar $\tau \in [1, 2]$. En este caso

$$\begin{aligned} h(\tau) &:= \frac{1}{2} \|\tilde{p}_k(\tau)\|^2 \\ &= \frac{1}{2} \|p_k^U\|^2 + (\tau - 1) \langle p_k^B - p_k^U, p_k^U \rangle + \frac{1}{2} (\tau - 1)^2 \|p_k^B - p_k^U\|^2, \end{aligned}$$

luego

$$\begin{aligned} h'(\tau) &= \langle p_k^B - p_k^U, p_k^U \rangle + (\tau - 1) \|p_k^B - p_k^U\|^2 \\ &\geq \langle p_k^B - p_k^U, p_k^U \rangle \\ &= \frac{\|\nabla f(x_k)\|^2 \langle B_k^{-1} \nabla f(x_k), \nabla f(x_k) \rangle}{\langle B_k \nabla f(x_k), \nabla f(x_k) \rangle} - \frac{\|\nabla f(x_k)\|^6}{\langle B_k \nabla f(x_k), \nabla f(x_k) \rangle^2} \\ &= \frac{\|\nabla f(x_k)\|^2}{\langle B_k \nabla f(x_k), \nabla f(x_k) \rangle^2} (\langle B_k^{-1} \nabla f(x_k), \nabla f(x_k) \rangle \langle B_k \nabla f(x_k), \nabla f(x_k) \rangle - \|\nabla f(x_k)\|^4) \\ &\geq 0, \end{aligned}$$

donde la última desigualdad se sigue de

$$\begin{aligned} \|\nabla f(x_k)\|^4 &= \langle B_k^{1/2} \nabla f(x_k), B_k^{-1/2} \nabla f(x_k) \rangle^2 \\ &\leq \|B_k^{1/2} \nabla f(x_k)\|^2 \|B_k^{-1/2} \nabla f(x_k)\|^2 \\ &= \langle B_k^{-1} \nabla f(x_k), \nabla f(x_k) \rangle \langle B_k \nabla f(x_k), \nabla f(x_k) \rangle. \end{aligned}$$

Ahora, si notamos $\hat{h}(\tau) = m_k(\tilde{p}_k(\tau))$ y derivamos con respecto a τ , tenemos

$$\begin{aligned}\hat{h}'(\tau) &= \langle \nabla f(x_k), p_k^B - p_k^U \rangle + \langle B_k(p_k^U + (\tau - 1)(p_k^B - p_k^U)), p_k^B - p_k^U \rangle \\ &\leq \langle \nabla f(x_k), p_k^B - p_k^U \rangle + \langle B_k p_k^B, p_k^B - p_k^U \rangle \\ &= \langle \nabla f(x_k) + B_k p_k^B, p_k^B - p_k^U \rangle = 0.\end{aligned}$$

De lo anterior podemos concluir que la trayectoria $\tilde{p}_k(\tau)$ intersecta la frontera de la región de confianza a lo sumo en un solo punto. En caso de que $\|p_k^U\| < \Delta_k$ pero $\|p_k^B\| > \Delta_k$, podemos hallar el valor $\tau^* \in (1, 2)$ que minimiza el modelo dentro de la región de confianza resolviendo la ecuación cuadrática

$$\|p_k^U + (\tau^* - 1)(p_k^B - p_k^U)\|^2 = \Delta_k^2.$$

4. Conjuntos y funciones convexas

4.1. Conjuntos convexas

Definición. Un subconjunto $C \subset \mathbb{R}^n$ es un conjunto convexo si para todo $x, y \in C$ el segmento $[x, y] \subset C$, es decir, si para todo $\alpha \in [0, 1]$ se tiene que $\alpha x + (1 - \alpha)y \in C$.

Ejemplo. Algunos ejemplos son las rectas, subespacios vectoriales, semiespacios, el conjunto de las matrices semidefinidas positivas y el cono de segundo orden, este es el epígrafo de la función $\|x\|$, bolas.

Veamos algunas de propiedades de los conjuntos convexas (intente probar algunas de ellas):

1. Dada una familia de conjuntos convexas $\{C_i\}_{i \in I}$, entonces la intersección $\bigcap_{i \in I} C_i$ es también convexa.

Ejemplo. Un ejemplo importante de conjunto convexo son los poliedros $\{x : Ax \leq b\}$ pues son intersecciones de semiespacios. El conjunto de matrices semidefinidas es también una intersección (no contable) de semiespacios del tipo $\{X : \langle X, zz^T \rangle \geq 0\}$ con $z \neq 0$.

2. Dada una familia de conjuntos convexas $\{C_i\}_{i \in I}$, entonces el producto cartesiano $\prod_{i \in I} C_i$ es también convexo.
3. La unión de conjuntos convexas no es necesariamente convexa. Ejemplo??
4. Si $A \in \mathbb{R}^{m \times n}$ y $b \in \mathbb{R}^m$, y $C \subset \mathbb{R}^n$ es convexo, entonces $AC + b = \{Ax + b : x \in C\} \subset \mathbb{R}^m$ es convexo. Esto es, imagen de un convexo a través de una función afín es convexa. Esta propiedad permite mostrar que la suma de Minkowski de una colección finita de conjuntos convexas es convexa. También muestra que proyecciones de un conjunto convexo sobre algunas de sus coordenadas también es convexo.

5. Si C es convexo entonces su clausura también lo es.
6. Si C es convexo entonces su interior es convexo. Para ver esto sean $x, y \in \text{int}(C)$, entonces existe $r > 0$ tal que $\mathcal{B}_r(x) \subset C$ y $\mathcal{B}_r(y) \subset C$. Sea $\alpha \in [0, 1]$ y $\|z\| \leq r$, así que $x + z$ y $y + z$ están en C . Entonces

$$\alpha x + (1 - \alpha)y + z = \alpha(x + z) + (1 - \alpha)(y + z) \in C,$$

luego $\alpha x + (1 - \alpha)y \in \text{int}(C)$.

Definición. Un conjunto $A \subset \mathbb{R}^n$ es afín si dados $x, y \in A$, la recta que pasa por estos puntos está contenida en A , es decir, si para todo $\alpha \in \mathbb{R}$ se tiene que $\alpha x + (1 - \alpha)y \in A$.

Definición. Dado $B \subset \mathbb{R}^n$ definimos la envoltura afín y la envoltura convexa de B , respectivamente, como:

$$\begin{aligned} \blacksquare \text{ aff}(B) &= \left\{ \sum_{i=1}^k \alpha_i x_i : x_i \in B, \sum_{i=1}^k \alpha_i = 1, k \in \mathbb{N} \right\} \\ \blacksquare \text{ conv}(B) &= \left\{ \sum_{i=1}^k \alpha_i x_i : x_i \in B, \alpha_i \geq 0, \sum_{i=1}^k \alpha_i = 1, k \in \mathbb{N} \right\} \end{aligned}$$

Esto es, son las combinaciones afines y convexas, respectivamente, de elementos de B .

Es claro que $B \subset \text{conv}(B) \subset \text{aff}(B)$.

Proposición. Si $B \neq \emptyset$, entonces $\text{conv}(B)$ es convexo ($\text{aff}(B)$ es afín). Además, $\text{conv}(B)$ ($\text{aff}(B)$) es el conjunto convexo (afín) más pequeño que contiene a B .

Prueba. Veamos la prueba para la envoltura convexa pues el caso de la envoltura afín es similar. Sea $x = \sum_{i=1}^n \alpha_i x_i$ y $y = \sum_{j=1}^m \mu_j y_j$ en $\text{conv}(B)$, es decir, $x_i, y_j \in B$ y los α_i, μ_j forman una combinaciones convexas. Entonces, para $\lambda \in [0, 1]$ los escalares $\lambda \alpha_i, (1 - \lambda)\mu_j$ forman una combinación convexa con los vectores x_i, y_j con lo cual

$$\lambda x + (1 - \lambda)y = \sum_{i=1}^n \lambda \alpha_i x_i + \sum_{j=1}^m (1 - \lambda)\mu_j y_j \in \text{conv}(B).$$

Para la segunda parte, sea C convexo tal que $B \subset C$, queremos ver que $\text{conv}(B) \subset C$. Sea $x \in \text{conv}(B)$. Vamos a hacer inducción en el número de términos en la suma de la representación como combinación convexa x , esto es, si $x \in B$, entonces $x \in C$. Ahora, sea x como arriba con n términos en la suma y supongamos que todo elemento de $\text{conv}(B)$ con $n - 1$ términos está en C , entonces, tomando $\lambda = 1 - \alpha_n \in [0, 1]$, se tiene que

$$x = \lambda \left(\sum_{i=1}^{n-1} \frac{\alpha_i}{\lambda} x_i \right) + (1 - \lambda)x_n.$$

Como $\frac{\alpha_i}{\lambda}$ para $i = 1, \dots, n - 1$ forman una combinación convexa y C es convexo, entonces $x \in C$. $\square$

Lo anterior muestra entonces que si C es convexo entonces $\text{conv}(C) = C$, es decir, combinaciones convexas de elementos de C están en C , y análogamente para conjuntos afines.

Definición. Sean $\{x_1, \dots, x_k\} \subset \mathbb{R}^n$. Decimos que son afínmente independientes si para escalares $\alpha_1, \dots, \alpha_k$ tales que $\sum_{i=1}^k \alpha_i x_i = 0$ y $\sum_{i=1}^k \alpha_i = 0$, entonces todos los escalares son 0.

Lema. Los vectores $\{x_1, \dots, x_k\}$ son afínmente independientes si y solo si los $k - 1$ vectores $\{x_2 - x_1, \dots, x_k - x_1\}$ son linealmente independientes.

Prueba. Notemos que las condiciones $\sum_{i=1}^k \alpha_i x_i = 0$ y $\sum_{i=1}^k \alpha_i = 0$, son equivalentes a que $\sum_{i=2}^k \alpha_i (x_i - x_1) = 0$, con lo que se tiene el resultado. $\square$

El anterior lema nos permite mostrar un siguiente teorema debido a Carathéodory.

Teorema (Carathéodory). Sea $B \subset \mathbb{R}^n$. Todo elemento de $\text{conv}(B)$ se puede escribir como combinación convexa de elementos de B afínmente independientes. Por lo tanto, todo elemento de $\text{conv}(B)$ se puede escribir como combinación convexa de a lo más $n + 1$ elementos de B .

Prueba. Sea $x = \sum_{i=1}^k \alpha_i x_i$ con $\alpha_i > 0$, si los vectores x_i son afínmente independientes, entonces $k - 1 \leq n$ por el lema y por consiguiente $k \leq n + 1$. Ahora, supongamos que los vectores x_i no son linealmente independientes, luego existen escalares μ_i tales que $\sum_{i=1}^k \mu_i x_i = 0$, $\sum_{i=1}^k \mu_i = 0$ y no todos son 0. Entonces, para $\epsilon > 0$ se tiene que

$$x = \sum_{i=1}^k (\alpha_i - \epsilon \mu_i) x_i$$

y además $\sum_{i=1}^k (\alpha_i - \epsilon \mu_i) = 1$. Si $\mu_i \leq 0$, entonces $\alpha_i - \epsilon \mu_i \geq 0$, de lo contrario, si tomamos $\epsilon = \min\{\alpha_i / \mu_i : \mu_i > 0\} > 0$, se tiene que los escalares $\alpha_i - \epsilon \mu_i$ forman una combinación convexa y uno de ellos es 0, así que x se puede escribir como combinación convexa de $k - 1$ vectores. Continuando este proceso podemos obtener vectores afínmente independientes. $\square$

Notemos que si B es cerrado, $\text{conv}(B)$ no lo es necesariamente, pero sí se tiene el siguiente resultado.

Corolario. Si B es compacto, entonces $\text{conv}(B)$ también lo es.

Prueba. Para mostrar que $\text{conv}(B)$ es compacto es suficiente con mostrar que toda sucesión tiene una subsucesión convergente. Sea $\{x^k\} \subset \text{conv}(B)$, entonces cada elemento de la sucesión se puede escribir como

$$x^k = \sum_{i=1}^{n+1} \alpha_i^k x_i^k.$$

Como el simplex n -dimensional $\Delta_n = \{\alpha \in \mathbb{R}_+^{n+1} : \langle \alpha, \mathbf{1} \rangle = 1\}$, con $\mathbf{1}$ el vector de unos, es compacto, entonces $B^{n+1} \times \Delta_n$ es compacto, entonces $\{(x_1^k, \dots, x_{n+1}^k, \alpha^k)\}$ tiene una subsucesión convergente a $(x_1, \dots, x_{n+1}, \alpha)$. Luego $\{x^k\}$ tiene una subsucesión convergente a $\sum_{i=1}^{n+1} \alpha_i x_i \in \text{conv}(B)$. $\square$

No es difícil ver todo conjunto afín A es la translación de un subespacio, luego podemos definir $\dim(A)$ como la dimensión del subespacio asociado. De la misma forma podemos definir $\dim(B) = \dim(\text{aff}(B))$ para todo $B \subset \mathbb{R}^n$. Ahora, $\dim(B) = m < n$, entonces todo elemento de $\text{conv}(B)$ se puede escribir como combinación convexa de a lo más $m+1$ elementos de B .

Definición. Un conjunto $K \subset \mathbb{R}^n$ es un cono si para todo $x \in K$ y $\lambda > 0$ se tiene que $\lambda x \in K$. Dado $B \subset \mathbb{R}^n$ la envolvente cónica de B se define como

$$\text{cone}(B) = \left\{ \sum_{i=1}^k \lambda_i x_i : x_i \in B, \lambda_i > 0, k \in \mathbb{N} \right\}.$$

No todo cono es convexo, pero los convexos son los que nos interesan. Tenemos además resultados análogos a los anteriores para los conos, estos son:

- Si $B \neq \emptyset$, entonces $\text{cone}(B)$ es el cono convexo más pequeño que contiene a B .
- (Carathéodory) Sea $B \subset \mathbb{R}^n$. Todo elemento de $\text{cone}(B)$ se puede escribir como combinación positiva de elementos de B linealmente independientes. Por lo tanto, todo elemento de $\text{conv}(B)$ se puede escribir como combinación positiva de a lo más n elementos de B .

Ejemplo. Los ejemplos de conos más importantes son $\mathbb{R}_+^n$, las matrices semidefinidas positivas y el cono de segundo orden. Otro usando es el cono de matrices copositivas que contiene al cono de matrices semidefinidas positivas.

Ahora, si intersectamos alguno de los conos anteriores con espacios afines, tenemos conjuntos convexos sobre los cuales nos va a interesar optimizar funciones lineales, como veremos más adelante. Un ejemplo es el conjunto $\{x \in \mathbb{R}_+^n : Ax = b\}$ para alguna matriz $A \in \mathbb{R}^{m \times n}$ y algún vector $b \in \mathbb{R}^m$. De hecho este conjunto es un poliedro con dimensión típicamente menor a n .

4.2. Funciones convexas

En esta parte vamos a considerar funciones que toman valores en $\mathbb{R} \cup \{\infty\}$ y definimos el $\text{dom}(f)$ como el conjunto de valores que toma valor finito.

Definición. $f : \mathbb{R}^n \mapsto \mathbb{R} \cup \{\infty\}$ es una función convexa si para todo $x, y \in \mathbb{R}^n$ y $\alpha \in [0, 1]$ se tiene que

$$f(\alpha x + (1 - \alpha)y) \leq \alpha f(x) + (1 - \alpha)f(y),$$

y es estrictamente convexa si la desigualdad es estricta para todo $x \neq y$ y $\alpha \in (0, 1)$.

Es claro que si f es convexa entonces $\text{dom}(f)$ es un conjunto convexo. Algunos ejemplos de funciones convexas son las funciones afines y normas.

Algunas propiedades de las funciones convexas son las siguientes (intente probar algunas de ellas):

1. Combinación positiva de funciones convexas es convexa.
2. Conjuntos de nivel de funciones convexas son convexos. Note que el converso no es cierto.
3. Si f es convexa, entonces $f(Ax + b)$ es convexa.
4. f es convexa si y solo si $\text{epi}(f)$ es convexo.
5. Sea $\{f_i\}_{i \in I}$ colección de funciones convexas. Entonces $f(x) := \sup_{i \in I} f_i(x)$ es convexa.

Para ver esto notemos que

$$\text{epi}(f) = \bigcap_{i \in I} \text{epi}(f_i).$$

Así, el resultado se sigue de la propiedad anterior. Un ejemplo importante de esta propiedad es la llamada función de soporte de un conjunto $B \subset \mathbb{R}^n$ definida como

$$\sigma_B(x) = \sup_{y \in B} \langle y, x \rangle,$$

la cual es siempre convexa y semicontinua por debajo por el mismo argumento de antes.

6. Si $g : \mathbb{R}^{n+m} \mapsto \mathbb{R} \cup \{\infty\}$ es convexa, entonces $f(x) := \inf_{y \in \mathbb{R}^m} g(x, y)$ es convexa. Para ver esto tomemos $x_1, x_2 \in \text{dom}(f)$, luego existen $\{y_1^k\}$ y $\{y_2^k\}$ tales que $g(x_1, y_1^k) \downarrow f(x_1)$ y $g(x_2, y_2^k) \downarrow f(x_2)$. Luego, para $\alpha \in [0, 1]$

$$\begin{aligned} f(\alpha x_1 + (1 - \alpha)x_2) &\leq g(\alpha x_1 + (1 - \alpha)x_2, \alpha y_1^k + (1 - \alpha)y_2^k) \\ &\leq \alpha g(x_1, y_1^k) + (1 - \alpha)g(x_2, y_2^k) \downarrow \alpha f(x_1) + (1 - \alpha)f(x_2). \end{aligned}$$

El siguiente resultado se conoce como la desigualdad de Jensen.

Proposición. Sea f convexa, entonces

$$f\left(\sum_{i=1}^k \alpha_i x_i\right) \leq \sum_{i=1}^k \alpha_i f(x_i),$$

donde los α_i forman una combinación convexa.

Prueba. Puesto que $(x_i, f(x_i)) \in \text{epi}(f)$, que es convexo, entonces

$$\sum_{i=1}^k \alpha_i (x_i, f(x_i)) = \left(\sum_{i=1}^k \alpha_i x_i, \sum_{i=1}^k \alpha_i f(x_i) \right) \in \text{epi}(f),$$

y esto muestra el resultado. $\square$

Un corolario del resultados anterior es el siguiente: Sea $B = \{x_1, \dots, x_k\} \subset \text{dom}(f)$ y $M = \max_i f(x_i)$, entonces $f(x) \leq M$ para todo $x \in \text{conv}(B)$. En particular esto muestra que el máximo de una función convexa sobre un conjunto convexo cerrado siempre está en la frontera del conjunto.

Veamos ahora algunas propiedades y caracterizaciones de funciones convexas suaves. Primero, tenemos que las nociones de diferenciabilidad de Gâteaux y Fréchet son equivalentes en funciones convexas.

Teorema. Sea C convexo con interior no vacío y f convexa en C . Si $x \in C$ es Gâteaux diferenciable en x entonces f es Fréchet en x .

Prueba. Sea $g : \mathbb{R}^n \mapsto \mathbb{R}$ definida por $g(h) = f(x + h) - f(x) - \langle \nabla f(x), h \rangle$. Notemos que g es convexa y además $g(0) = 0$ y Gâteaux diferenciable en 0 con $\nabla g(0) = 0$. Ahora, usando la desigualdad de Jensen, para $h \in \mathbb{R}^n$ se tiene que

$$\begin{aligned} g(h) &= g\left(\frac{1}{n} \sum_{i=1}^n nh_i e_i\right) \leq \frac{1}{n} \sum_{i=1}^n g(nh_i e_i) \\ &= \sum_{h_i \neq 0} h_i \frac{g(nh_i e_i)}{nh_i} \\ &\leq \|h\| \left(\sum_{h_i \neq 0} \left(\frac{g(nh_i e_i)}{nh_i} \right)^2 \right)^{1/2} \\ &\leq \|h\| \sum_{h_i \neq 0} \left| \frac{g(nh_i e_i)}{nh_i} \right|, \end{aligned}$$

donde la penúltima desigualdad se sigue de la desigualdad de Cauchy-Schwarz y la última de la desigualdad de normas $\|\cdot\| \leq \|\cdot\|_1$. Por otro lado la convexidad de g implica que $0 = 2g(0) \leq g(-h) + g(h)$, por lo tanto

$$-\sum_{h_i \neq 0} \left| \frac{g(-nh_i e_i)}{nh_i} \right| \leq \frac{-g(-h)}{\|h\|} \leq \frac{g(h)}{\|h\|} \leq \sum_{h_i \neq 0} \left| \frac{g(nh_i e_i)}{nh_i} \right|.$$

Finalmente, como cada uno de los términos dentro de las sumas de los extremos converge a $\frac{\partial g}{\partial x_i}(0) = 0$ cuando $h_i \rightarrow 0$, entonces $g(h) = o(\|h\|)$ lo que es equivalente a que f es Fréchet en x . $\square$

Seguimos con una caracterización de primer orden.

Teorema. Sea $C \subset \mathbb{R}^n$ convexo y f Gâteaux diferenciable en un abierto U que contiene a C . Entonces f es convexa en C si y solo si para todo $x, y \in C$ se tiene que

$$f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle.$$

Lo que dice el teorema es que una función es convexa si y solo si la función siempre está por encima de su aproximación de primer orden en todo punto.

Prueba. Supongamos primero que f es convexa y sea $x \neq y \in C$. Sea $g : (0, 1] \mapsto \mathbb{R}$ dada por

$$g(t) = \frac{f(x + t(y - x)) - f(x)}{t}. \quad (19)$$

Veamos que g es una función creciente. Sean $0 < t_1 < t_2$, entonces

$$x + t_1(y - x) = \left(1 - \frac{t_1}{t_2}\right)x + \frac{t_1}{t_2}(x + t_2(y - x)),$$

luego

$$f(x + t_1(y - x)) \leq \left(1 - \frac{t_1}{t_2}\right) f(x) + \frac{t_1}{t_2} f(x + t_2(y - x)),$$

que es equivalente a que $g(t_1) \leq g(t_2)$. Así que

$$\langle \nabla f(x), y - x \rangle = \lim_{t \downarrow 0} g(t) \leq g(1) = f(y) - f(x).$$

Para el converso, sea $z = \alpha x + (1 - \alpha)y$ para $\alpha \in [0, 1]$, entonces

$$f(x) \geq f(z) + \langle \nabla f(z), x - z \rangle, \quad f(y) \geq f(z) + \langle \nabla f(z), y - z \rangle,$$

y multiplicando por α y $1 - \alpha$ respectivamente cada desigualdad, y sumándolas, se tiene que

$$\alpha f(x) + (1 - \alpha)f(y) \geq f(z) + \langle \nabla f(z), \alpha x + (1 - \alpha)y - z \rangle = f(z).$$

□

El resultado anterior también se cumple si consideramos funciones estrictamente convexas y cambiamos la desigualdad por una desigualdad estricta. Un corolario muy importante del resultado anterior es si $x \in C$ es un punto crítico, entonces x es mínimo global de f en C , esto es, una condición suficiente para mínimo global es ser punto crítico.

Ahora, si $f \in C^2$ podemos caracterizar las funciones convexas a partir de la matriz Hessiana.

Teorema. Sea $C \subset \mathbb{R}^n$ convexo y $f \in C^2(U)$ con U abierto que contiene a C . Entonces, f es convexa en C si y solo si $Hf(x) \succeq 0$ para todo $x \in C$.

Prueba. Sea f es convexa y sean $d \in \mathbb{R}^n$ y $x \in C$. Para $t > 0$ suficientemente pequeño, por el teorema anterior se tiene que

$$f(x) + t\langle \nabla f(x), d \rangle \leq f(x + td) = f(x) + t\langle \nabla f(x), d \rangle + \frac{t^2}{2}\langle Hf(x)d, d \rangle + o(t^2),$$

luego $\langle Hf(x)d, d \rangle + \frac{o(t^2)}{t^2} \geq 0$, y tomando $t \rightarrow 0$ se tiene que $\langle Hf(x)d, d \rangle \geq 0$. Para el converso, sean $x \neq y \in C$, entonces existe $z \in (x, y)$ tal que

$$f(y) = f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2}\langle Hf(z)(y - x), y - x \rangle \geq f(x) + \langle \nabla f(x), y - x \rangle,$$

luego f es convexa por el resultado anterior. □

Igual que en el caso anterior la función es estrictamente convexa si y solo si la Hessiana es definida positiva.

5. Optimización convexa suave

5.1. Método del descenso del gradiente - Caso C^1 convexo

Además de la convexidad, igual que en el caso general, vamos a asumir que su gradiente es Lipschitz con constante L . Igual que antes, tenemos que el paso óptimo es $\alpha = \frac{1}{L}$ y de (4) tenemos que

$$f(x_{k+1}) \leq f(x_k) - \frac{1}{2L}\|\nabla f(x_k)\|^2. \quad (20)$$

Veamos ahora un lema necesario para mostrar la convergencia.

Lema. Para todo $x, y \in \mathbb{R}^n$ se tiene

$$\langle \nabla f(y) - \nabla f(x), y - x \rangle \leq L \|y - x\|^2, \quad (21)$$

$$\langle \nabla f(x), y - x \rangle + \frac{1}{2L} \|\nabla f(x) - \nabla f(y)\|^2 \leq f(y) - f(x), \quad (22)$$

y

$$\frac{1}{L} \|\nabla f(x) - \nabla f(y)\|^2 \leq \langle \nabla f(y) - \nabla f(x), y - x \rangle. \quad (23)$$

Prueba. La desigualdad (21) se obtiene de sumar dos veces (3) intercambiando x y y . Ahora, sea $x \in \mathbb{R}^n$ arbitrario y $\phi(y) := f(y) - \langle \nabla f(x), y \rangle$. Es claro que ϕ es también una función convexa con gradiente Lipschitz con contante L . Además, $\nabla \phi(x) = 0$, luego x es un mínimo global de ϕ . Así que, usando (3), para todo $y \in \mathbb{R}^n$

$$\begin{aligned} f(x) - \langle \nabla f(x), x \rangle &= \phi(x) \leq \phi\left(y - \frac{1}{L} \nabla \phi(y)\right) \\ &\leq \phi(y) - \left\langle \nabla \phi(y), \frac{1}{L} \nabla \phi(y) \right\rangle + \frac{1}{2L} \|\nabla \phi(y)\|^2 \\ &= \phi(y) - \frac{1}{2L} \|\nabla \phi(y)\|^2 \\ &= f(y) - \langle \nabla f(x), y \rangle - \frac{1}{2L} \|\nabla f(x) - \nabla f(y)\|^2. \end{aligned}$$

La tercera desigualdad sale de sumar dos veces la segunda intercambiando x y y . □

Veamos ahora la convergencia del método, para esto definimos $r_k = \|x_k - x^*\|$, y para un tamaño de paso $0 < \alpha_k < \frac{2}{L}$ tenemos

$$\begin{aligned} r_{k+1}^2 &= \|x_k - x^* - \alpha_k \nabla f(x_k)\|^2 \\ &= r_k^2 - 2\alpha_k \langle \nabla f(x_k), x_k - x^* \rangle + \alpha_k^2 \|\nabla f(x_k)\|^2 \\ &= r_k^2 - 2\alpha_k \langle \nabla f(x_k) - \nabla f(x^*), x_k - x^* \rangle + \alpha_k^2 \|\nabla f(x_k)\|^2 \\ &\leq r_k^2 - \alpha_k \left(\frac{2}{L} - \alpha_k \right) \|\nabla f(x_k)\|^2, \end{aligned}$$

donde la última desigualdad se sigue de (23). Tenemos entonces que $r_k \leq r_0$. Ahora, por la convexidad de f tenemos también que

$$\delta_k := f(x_k) - f^* \leq \langle \nabla f(x_k), x_k - x^* \rangle \leq r_0 \|\nabla f(x_k)\|.$$

Tomemos ahora el paso óptimo $\alpha = \frac{1}{L}$, de (20) obtenemos

$$\delta_{k+1} \leq \delta_k - \frac{1}{2Lr_0^2} \delta_k^2 \leq \delta_k,$$

y dividiendo por $\delta_k \delta_{k+1}$ tenemos

$$\frac{1}{\delta_{k+1}} \geq \frac{1}{\delta_k} + \frac{1}{2Lr_0^2} \frac{\delta_k}{\delta_{k+1}} \geq \frac{1}{\delta_k} + \frac{1}{2Lr_0^2}.$$

Finalmente, si sumamos esta desigualdad entre 0 a k , llegamos a

$$\frac{1}{\delta_{k+1}} \geq \frac{1}{\delta_0} + \frac{k+1}{2Lr_0^2},$$

y puesto que (usando (3)) $f(x_0) \leq f^* + \frac{L}{2}\|x_0 - x^*\|^2$, obtenemos la cota

$$f(x_k) - f^* \leq \frac{2L(f(x_0) - f^*)\|x_0 - x^*\|^2}{2L\|x_0 - x^*\|^2 + k(f(x_0) - f^*)} \leq \frac{2L\|x_0 - x^*\|^2}{(k+4)}.$$

Este es un resultado mucho mejor que el que se obtiene en el caso general, donde no podemos garantizar la convergencia a un mínimo (local). En este caso siempre se converge a un óptimo (aunque a una tasa sublineal).

5.1.1. Caso fuertemente convexo

Recordemos que cuando $f \in C^2$, más otras condiciones adicionales, sí pudimos garantizar la convergencia al mínimo a una tasa lineal, siempre que iniciemos el método cerca de x^* . Veamos que en el caso convexo no tenemos que pedirle tanta regularidad a f pero si un tipo de convexidad más fuerte.

Definición. Una función $f \in C^1$ es *fuertemente* convexa si existe $\mu > 0$ tal que para todo $x, y \in \mathbb{R}^n$

$$f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle + \frac{\mu}{2}\|y - x\|^2. \quad (24)$$

Si sumamos dos veces (24), intercambiando x y y , tenemos que para todo $x, y \in \mathbb{R}^n$

$$\langle \nabla f(y) - \nabla f(x), y - x \rangle \geq \mu\|y - x\|^2, \quad (25)$$

y si además usamos que el gradiente de f es L -Lipschitz, usando (21) tenemos que

$$\mu\|y - x\|^2 \leq \langle \nabla f(y) - \nabla f(x), y - x \rangle \leq L\|y - x\|^2.$$

Definimos $Q_f = \frac{L}{\mu} \geq 1$. Definimos ahora la función

$$\phi(x) = f(x) - \frac{\mu}{2}\|x\|^2, \quad (26)$$

queremos ver que ϕ es convexa y su gradiente es $(L - \mu)$ -Lipschitz. Puesto que $\nabla \phi(x) = \nabla f(x) - \mu x$, (25) implica que

$$\langle \nabla \phi(y) - \nabla \phi(x), y - x \rangle = \langle \nabla f(y) - \nabla f(x), y - x \rangle - \mu\|y - x\|^2 \geq 0, \quad (27)$$

es decir, ϕ es convexa por ejercicio de la tarea. Ahora, usando (21) tenemos, para todo $x, y \in \mathbb{R}^n$, que

$$\langle \nabla \phi(y) - \nabla \phi(x), y - x \rangle \leq (L - \mu)\|y - x\|^2. \quad (28)$$

Si $L = \mu$, esto implica que $\nabla\phi$ es constante, luego es 0-Lipschitz, y además de (27) y (23) tenemos que

$$\begin{aligned} \frac{\mu L}{\mu + L} \|x - y\|^2 + \frac{1}{\mu + L} \|\nabla f(y) - \nabla f(x)\|^2 &= \frac{\mu}{2} \|x - y\|^2 + \frac{1}{2\mu} \|\nabla f(y) - \nabla f(x)\|^2 \\ &\leq \langle \nabla f(y) - \nabla f(x), y - x \rangle. \end{aligned}$$

Si $\mu < L$, (28) implica que

$$\begin{aligned} \phi(y) - \phi(x) - \langle \nabla\phi(x), y - x \rangle &= \int_0^1 \langle \nabla\phi(x + t(y - x)) - \nabla\phi(x), y - x \rangle dt \\ &\leq \int_0^1 (L - \mu)t \|y - x\|^2 dt = \frac{L - \mu}{2} \|y - x\|^2, \end{aligned}$$

es decir, ϕ satisface (3), que es condición suficiente para que también satisfaga (23) (ver prueba del Lema), luego

$$\frac{1}{L - \mu} \|\nabla\phi(x) - \nabla\phi(y)\|^2 \leq \langle \nabla\phi(y) - \nabla\phi(x), y - x \rangle \leq \|\nabla\phi(x) - \nabla\phi(y)\| \|y - x\|,$$

lo que muestra que $\nabla\phi$ es $(L - \mu)$ -Lipschitz. Además de (27) se tiene que

$$\begin{aligned} \langle \nabla f(y) - \nabla f(x), y - x \rangle - \mu \|y - x\|^2 &\geq \frac{1}{L - \mu} \|\nabla f(y) - \nabla f(x)\|^2 \\ &\quad - \frac{2\mu}{L - \mu} \langle \nabla f(y) - \nabla f(x), y - x \rangle + \frac{\mu^2}{L - \mu} \|y - x\|^2, \end{aligned}$$

que es equivalente a que

$$\frac{\mu L}{\mu + L} \|x - y\|^2 + \frac{1}{\mu + L} \|\nabla f(y) - \nabla f(x)\|^2 \leq \langle \nabla f(y) - \nabla f(x), y - x \rangle, \quad (29)$$

lo mismo que en el caso $\mu = L$.

Esto nos va a permitir encontrar la tasa de convergencia del método en este caso. Para una tamaño de paso $0 < \alpha \leq \frac{2}{L + \mu}$ tenemos de (29) que

$$\begin{aligned} r_{k+1}^2 &= \|x_k - x^* - \alpha \nabla f(x_k)\|^2 \\ &= r_k^2 - 2\alpha \langle \nabla f(x_k) - f(x^*), x_k - x^* \rangle + \alpha^2 \|\nabla f(x_k)\|^2 \\ &\leq r_k^2 \left(1 - \frac{2\alpha\mu L}{L + \mu} \right) - \alpha \left(\frac{2}{L + \mu} - \alpha \right) \|\nabla f(x_k)\|^2, \end{aligned}$$

con lo cual, si $\alpha = \frac{2}{L + \mu}$ se tiene que

$$r_k \leq \left(\frac{L - \mu}{L + \mu} \right) r_{k-1} \leq \left(\frac{Q_f - 1}{Q_f + 1} \right)^k r_0,$$

y usando (3)

$$f(x_k) - f^* \leq \frac{L}{2} r_k^2 \leq \left(\frac{Q_f - 1}{Q_f + 1} \right)^{2k} r_0^2,$$

es decir, tenemos una convergencia con tasa lineal con cualquier punto inicial.

5.2. Método acelerado de Nesterov

Vamos a asumir que f es convexa y que su gradiente es Lipschitz con constante L . Bajo estos supuestos es posible construir un método del tipo búsqueda lineal que tiene una tasa mejor que $o(1/k)$, que fue la que obtuvimos antes. Se puede mostrar que el método que vamos a analizar ahora es óptimo en términos de la tasa de convergencia $o(1/k^2)$. La idea es hacer una búsqueda lineal con el método del gradiente con paso constante, pero considerando un paso anterior en la iteración.

Iniciar $\lambda_0 = 0$ y obtener las sucesiones: $\lambda_{k+1} \leftarrow \frac{1+\sqrt{1+4\lambda_k^2}}{2}$ y $\gamma_k \leftarrow \frac{1-\lambda_k}{\lambda_{k+1}}$;
 Iniciar $x_1 = y_1$ arbitrario;
para $k = 1, 2, \dots$ **hacer**
 $y_{k+1} \leftarrow x_k - \frac{1}{L}\nabla f(x_k)$;
 $x_{k+1} \leftarrow (1 - \gamma_k)y_{k+1} + \gamma_k y_k$;
fin

Algoritmo 3: *Acelerado de Nesterov*

Notemos que $\gamma_k \leq 0$ y que $\lambda_k^2 = \lambda_{k+1}^2 - \lambda_{k+1}$ para todo k . Usando inducción podemos ver que $\lambda_k > \frac{k-1}{2}$, en efecto, $\lambda_2 = \frac{1+\sqrt{5}}{2} > \frac{1}{2}$ y, $\lambda_{k+1}^2 - \lambda_{k+1} > \frac{(k-1)^2}{4}$, lo que implica que $\lambda_{k+1} > \frac{k}{2}$ pues $\frac{k^2}{4} - \frac{k}{2} < \frac{(k-1)^2}{4}$ y la función $x \mapsto x^2 - x$ es estrictamente creciente después de $\frac{1}{2}$.

Analicemos ahora la convergencia del algoritmo 3. Primero, de (3) y la convexidad de f , para $x, y \in \mathbb{R}^n$ se tiene que

$$\begin{aligned} f\left(x - \frac{1}{L}\nabla f(x)\right) - f(y) &\leq f\left(x - \frac{1}{L}\nabla f(x)\right) - f(x) - \langle \nabla f(x), y - x \rangle \\ &\leq \langle \nabla f(x), x - y \rangle - \frac{1}{2L}\|\nabla f(x)\|^2. \end{aligned}$$

Tomando $x = x_k$ y $y = y_k$, y $x = x_k$ y $y = x^*$ en la desigualdad de arriba tenemos que

$$\begin{aligned} f(y_{k+1}) - f(y_k) &\leq \langle \nabla f(x_k), x_k - y_k \rangle - \frac{1}{2L}\|\nabla f(x_k)\|^2 \\ &= -L\langle y_{k+1} - x_k, x_k - y_k \rangle - \frac{L}{2}\|y_{k+1} - x_k\|^2 \end{aligned}$$

y

$$f(y_{k+1}) - f(x^*) \leq -L\langle y_{k+1} - x_k, x_k - x^* \rangle - \frac{L}{2}\|y_{k+1} - x_k\|^2.$$

Multiplicando la primera desigualdad por $(\lambda_k - 1)$, sumando a la segunda y denotando $\delta_k = f(y_k) - f(x^*)$, tenemos

$$\lambda_k \delta_{k+1} - (\lambda_k - 1)\delta_k \leq -L\langle y_{k+1} - x_k, \lambda_k x_k - (\lambda_k - 1)y_k - x^* \rangle - \frac{L\lambda_k}{2}\|y_{k+1} - x_k\|^2.$$

Multiplicando esta desigualdad por λ_k y usando la relación entre λ_k y λ_{k-1} tenemos

$$\begin{aligned}\lambda_k^2 \delta_{k+1} - \lambda_{k-1}^2 \delta_k &\leq -\frac{L}{2} (\|\lambda_k(y_{k+1} - x_k)\|^2 + 2\langle \lambda_k(y_{k+1} - x_k), \lambda_k x_k - (\lambda_k - 1)y_k - x^* \rangle) \\ &= -\frac{L}{2} (\|\lambda_k y_{k+1} - (\lambda_k - 1)y_k - x^*\|^2 - \|\lambda_k x_k - (\lambda_k - 1)y_k - x^*\|^2) \\ &= \frac{L}{2} (\|\lambda_k x_k - (\lambda_k - 1)y_k - x^*\|^2 - \|\lambda_{k+1} x_{k+1} - (\lambda_{k+1} - 1)y_{k+1} - x^*\|^2),\end{aligned}$$

donde la última igualdad viene de la definición de x_{k+1} y γ_k en el algoritmo. Si definimos $r_k = \|\lambda_k x_k - (\lambda_k - 1)y_k - x^*\|$, tenemos que

$$\lambda_k^2 \delta_{k+1} - \lambda_{k-1}^2 \delta_k \leq \frac{L}{2} (r_k^2 - r_{k+1}^2),$$

y sumando estas desigualdades de $k = 1, \dots, N$, obtenemos

$$\delta_{N+1} \leq \frac{L}{2\lambda_N^2} (r_1^2 - r_{N+1}^2) \leq \frac{2L}{(N-1)^2} r_1^2.$$

5.3. Método de (Quasi-)Newton

5.3.1. Caso fuertemente convexo C^2

Vamos a ahora a suponer que $f \in C^2$. Si detallamos con cuidado la forma como se mostró la convergencia cuadrática del método de Newton en el caso general, las condiciones importantes sobre f son: a) Hf es K -Lipschitz y b) $Hf(x) \succeq \mu I$ para todo x suficientemente cerca a x^* y algún $\mu > 0$. Bien, la condición b) se tiene para todo $x \in \mathbb{R}^n$ si f es fuertemente convexa. En efecto, recordemos que ϕ definida en (26) es convexa, luego

$$0 \preceq H\phi(x) = Hf(x) - \mu I.$$

Así que el método de Newton en este caso sigue con la misma convergencia cuadrática iniciando desde cualquier punto.

Ahora, la definición de convexidad fuerte implica que f es coerciva, luego los conjuntos de nivel son convexos y acotados y por lo tanto, para $x_0 \in \mathbb{R}^n$ arbitrario el conjunto $\mathcal{L} = \{x \in \mathbb{R}^n : f(x) \leq f(x_0)\}$ es convexo y compacto. Además, como Hf es continua se tiene que existe $M > 0$ tal que para todo $x \in \mathcal{L}$

$$\mu I \preceq Hf(x) \preceq MI.$$

Esto es suficiente para mostrar que el método BFGS converge a x^* a una tasa superlineal (ver teoremas 6.5 y 6.6 en [NW]).

5.3.2. Caso *self-concordant*

Ver libro de Nesterov.

6. Conceptos básicos de análisis convexo

Vimos antes que puntos críticos de funciones convexas son óptimos globales. Si f no es diferenciable no es posible hablar de puntos críticos, aún así tenemos el siguiente resultado.

Teorema. Sea $f : C \mapsto \mathbb{R}$ con C convexo y f convexa. Entonces si x es un mínimo local de f en C , entonces es mínimo global.

Prueba. Sea $y \in C$ y $\alpha \in (0, 1)$ suficientemente pequeño de tal forma que

$$f(x) \leq f(x + \alpha(y - x)) \leq \alpha f(y) + (1 - \alpha)f(x),$$

es decir, $f(x) \leq f(y)$. □

Veamos ahora algunas propiedades de regularidad de las funciones convexas generales. Es claro que no tienen que ser C^1 .

Recordemos que un corolario de la desigualdad de Jensen es que si f convexa está definida en el conjunto $\left\{x \in \mathbb{R}^n : \sum_{i=1}^n |x_i| \leq 1\right\}$, esto es, la bola de radio 1 centrada en el origen con la norma ℓ_1 , entonces f alcanza su máximo en la bola. Esto implica que si f es convexa definida en la bola $\mathcal{B}_r(x)$, para algún $r > 0$, entonces existe $m \in \mathbb{R}$ tal que $f(x) \leq m$ para todo $y \in \mathcal{B}_r(x)$. Asumiendo $x = 0$ sin pérdida de generalidad, tenemos entonces que para todo $y \in \mathcal{B}_r(0)$ se tiene que $0 = \frac{1}{2}y + \frac{1}{2}(-y)$, luego

$$f(0) \leq \frac{1}{2}f(y) + \frac{1}{2}f(-y) \leq \frac{1}{2}f(y) + \frac{1}{2}m,$$

esto es, $f(y) \geq 2f(0) - m$ y por lo tanto $|f(y)| \leq 2|f(0)| + |m|$. Con lo anterior tenemos el siguiente resultado.

Lema. Sea f convexa definida en la bola $\mathcal{B}_r(x)$. Entonces existe $M > 0$ tal que $|f(y)| \leq M$ para todo $y \in \mathcal{B}_r(x)$.

El anterior lema nos permite mostrar lo siguiente:

Teorema. Sea f convexa definida en la bola $\mathcal{B}_r(\bar{x})$. Entonces f es Lipschitz sobre la bola $\mathcal{B}_{r-\epsilon}(\bar{x})$ para todo $0 < \epsilon < r$.

Prueba. Sin pérdida de generalidad podemos asumir $\bar{x} = 0$. Sean $x, y \in \mathcal{B}_{r-\epsilon}(0)$, definimos

$$z = y + \frac{\epsilon}{\|x - y\|}(y - x) \in \mathcal{B}_r(0).$$

Notemos que

$$y = \frac{\epsilon}{\epsilon + \|x - y\|}x + \frac{\|x - y\|}{\epsilon + \|x - y\|}z,$$

luego

$$f(y) \leq \frac{\epsilon}{\epsilon + \|x - y\|}f(x) + \frac{\|x - y\|}{\epsilon + \|x - y\|}f(z),$$

que es equivalente a

$$\epsilon(f(y) - f(x)) \leq \|x - y\|(f(z) - f(y)).$$

Finalmente, por el lema anterior e intercambiando los x y y , tenemos que

$$|f(x) - f(y)| \leq \frac{2M}{\epsilon} \|x - y\|.$$

□

Corolario. Si f es convexa, entonces f es continua en el interior de su dominio.

La conclusión del teorema anterior es que toda función convexa es localmente Lipschitz continua, con lo cual se tiene que la función es diferenciable en casi todo punto por el teorema de Rademacher. De hecho se puede mostrar que las derivadas direccionales existen en todo punto. En efecto, dado $d \in \mathbb{R}^n$ y x en el interior del dominio de f consideremos la función $t \mapsto \frac{f(x+td)-f(x)}{t}$ (ver (19)). Por un lado, si $s > 0$, entonces

$$f(x) \leq \frac{s}{t+s} f(x+td) + \frac{t}{s+t} f(x-sd),$$

que es equivalente a que

$$\frac{f(x) - f(x-sd)}{s} \leq \frac{f(x+td) - f(x)}{t},$$

esto es, la función es acotada por debajo para todo $t > 0$. Por otro lado sabemos que la función es creciente, luego la derivada direccional existe y está dada por

$$f'(x; d) = \inf_{t>0} \frac{f(x+td) - f(x)}{t}.$$

Ahora, esto no implica que la f es Gâteaux diferenciable pues no sabemos si la derivada direccional es lineal, aunque sí es positivamente homogénea y convexa (ejercicio). Finalmente, sea y en el dominio de la función y $\alpha \in (0, 1)$, entonces

$$f(x + \alpha(y - x)) \leq \alpha f(y) + (1 - \alpha)f(x),$$

que es equivalente a

$$f(y) \geq f(x + \alpha(y - x)) + (1 - \alpha) \left(\frac{f(x + \alpha(y - x)) - f(x)}{\alpha} \right),$$

y tomando $\alpha \downarrow 0$, la continuidad de f implica que

$$f(y) \geq f(x) + f'(x, y - x). \quad (30)$$

Esto nos recuerda la caracterización de funciones convexas que son Gâteaux diferenciables y motiva la siguiente definición central en el estudio de funciones convexas.

Definición. Sea f convexa. Decimos que $g \in \mathbb{R}^n$ es un subgradiente de f en $x \in \text{dom}(f)$ si para todo $x \in \text{dom}(f)$ se tiene que

$$f(y) \geq f(x) + \langle g, y - x \rangle.$$

El conjunto de todos los subgradientes de f en x lo llamamos subdiferencial y lo notamos como $\partial f(x)$.

En lo que resta de esta sección alternaremos resultados sobre subgradientes y teoremas de separación.

6.1. Subgradientes I

Notemos que

$$\begin{aligned}\partial f(x) &= \{g : \langle g, y - x \rangle \leq f(y) - f(x) \quad \forall y \in \text{dom}(f)\} \\ &= \bigcap_{y \in \text{dom}(f)} \{g : \langle g, y - x \rangle \leq f(y) - f(x)\},\end{aligned}$$

esto es, es la intersección de conjuntos convexos y cerrados, luego $\partial f(x)$ es convexo y cerrado.

Proposición. Sean f convexa y $x \in \text{int}(\text{dom}(f))$. Entonces $\partial f(x)$ es compacto.

Prueba. Ya sabemos que es cerrado, falta ver que es acotado. Como toda función convexa es localmente Lipschitz, existen $\epsilon > 0$ y $M > 0$ tales que

$$|f(y) - f(x)| \leq M\|y - x\|$$

para todo $y \in \mathcal{B}_\epsilon(x)$. Sea $g \in \partial f(x)$ distinto de 0, entonces tomando $y = x + \epsilon \frac{g}{\|g\|} \in \mathcal{B}_\epsilon(x)$, se tiene que

$$\epsilon\|g\| = \langle g, y - x \rangle \leq f(y) - f(x) \leq M\|y - x\| = \epsilon M,$$

esto es $\|g\| \leq M$. □

Ejemplo. ■ Si f es Gâteaux en x , es claro que $\nabla f(x) \in \partial f(x)$.

- Sea $f(x) = -\sqrt{x}$ para $x \geq 0$. Se tiene que $\partial f(0)$ es vacío.
- Dado C convexo definimos la función $\chi_C(x) = 0$ si $x \in C$ y de lo contrario se asigna el valor ∞ . Es claro que esta es una función convexa. Si $x \notin C$ es claro que $\partial \chi_C(x)$ es vacío. Ahora, para $x \in C$ si $g \in \partial \chi_C(x)$ entonces para todo y

$$\chi_C(y) \geq \chi_C(x) + \langle g, y - x \rangle,$$

es decir, $\langle g, y - x \rangle \leq 0$ para todo $y \in C$. A este conjunto se le llama el cono normal a C en x .

- Dada una norma $\|\cdot\|$ en $\mathbb{R}^n$, podemos definir su norma dual como

$$\|y\|_* = \max_{\|x\| \leq 1} \langle x, y \rangle.$$

Además, la norma dual de la dual es la norma original, es decir,

$$\|x\| = \max_{\|y\|_* \leq 1} \langle x, y \rangle.$$

Se tiene que la norma dual de la norma euclidiana es la misma norma euclidiana y la norma dual de la norma ℓ_1 es la norma ℓ_∞ . Se tiene además que para todo $x, y \in \mathbb{R}^n$ se cumple la desigualdad

$$\langle x, y \rangle \leq \|x\| \|y\|_*.$$

Vamos ahora a calcular el subdiferencial de la función $\|\cdot\|$. Sea $x \in \mathbb{R}^n$ y $g \in \partial\|x\|$, entonces para todo d con $\|d\| \leq 1$ se tiene que

$$\langle g, d \rangle + \|x\| \leq \|x + d\| \leq \|x\| + \|d\| \leq \|x\| + 1,$$

por lo tanto $\langle g, d \rangle \leq 1$, y como esto vale para todo d en la esfera unitaria, entonces $\|g\|_* \leq 1$. Ahora, tomando $y = 0$ en la desigualdad del subgradiente se tiene que $-\langle g, x \rangle + \|x\| \leq 0$, lo que implica que

$$\|x\| \leq \langle g, x \rangle \leq \|g\|_* \|x\| \leq \|x\|.$$

Conversamente, sea g tal que $\|g\|_* \leq 1$ y además $\langle g, x \rangle = \|x\|$. Entonces, para todo y se tiene que

$$\langle g, y - x \rangle + \|x\| = \langle g, y \rangle \leq \|g\|_* \|y\| \leq \|y\|,$$

luego $g \in \partial\|x\|$.

Sabemos que en el caso suave ser punto crítico es equivalente a ser mínimo global. En el caso general se tiene un resultado análogo.

Teorema. x es mínimo global de $\mathbb{R}^n$ para f convexa si y solo si $0 \in \partial f(x)$.

Prueba. Si $0 \in \partial f(x)$, entonces para todo $y \in \mathbb{R}^n$ se tiene $f(y) \geq f(x) + \langle 0, y - x \rangle = f(x)$. Ahora, si x es mínimo global de f entonces para todo $y \in \mathbb{R}^n$ $f(y) \geq f(x) = f(x) + \langle 0, y - x \rangle$. $\square$

Si queremos optimizar sobre un conjunto convexo tenemos el siguiente resultado.

Proposición. Si $g \in \partial f(x)$ es tal que $\langle g, y - x \rangle \geq 0$ para todo $y \in C$, entonces x es mínimo global de f en C .

Prueba. Para todo $y \in C$ se tiene que $f(y) \geq f(x) + \langle g, y - x \rangle \geq f(x)$. $\square$

Veamos algunas aplicaciones del resultado anterior:

- Consideremos minimizar f convexa y suave sobre el conjunto $C = \{x : Ax = b\}$, con A matriz de $m \times n$ y $b \in \mathbb{R}^m$. C es entonces un conjunto afín. Buscamos $x^* \in C$ tal que $\langle \nabla f(x^*), y - x^* \rangle \geq 0$ para todo $y \in C$. Como $x^*, y \in C$, entonces $A(x^* - y) = 0$, luego necesitamos que $\langle \nabla f(x^*), z \rangle \geq 0$ para todo z en el espacio nulo de A , pero como esto es un subespacio de $\mathbb{R}^n$, esto quiere decir que $\langle \nabla f(x^*), z \rangle = 0$ para todo z en el espacio nulo de A . Ahora, como el ortogonal del espacio nulo de A es el rango de A^T , entonces una condición necesaria para que x^* sea mínimo es que exista $\lambda \in \mathbb{R}^m$ tal que

$$\nabla f(x^*) - \lambda^T A = 0.$$

- Consideremos ahora minimizar $f(x) = \langle a, x \rangle$ con $a \neq 0$ sobre $C = \mathcal{B}_r(0)$. Este problema surgió anteriormente en el método de regiones de confianza. En este caso la condición para la optimalidad de x^* es que $\langle a, y - x^* \rangle \geq 0$ para todo $y \in \mathcal{B}_r(0)$. Usando la desigualdad de Cauchy-Schwartz es fácil ver que $x^* = -\frac{r}{\|a\|}a$ satisface la desigualdad.

6.2. Teoremas de separación I

En algunos ejemplos vimos casos donde el subdiferencial puede ser vacío. Los siguientes resultados serán una herramienta importante para ver cuándo no sucede esto.

Sean $z \in \mathbb{R}^n$ y $C \subset \mathbb{R}^n$ cerrado y convexo, consideremos el problema de minimizar $f(x) = \frac{1}{2}\|x - z\|^2$ sobre C . Como f es coerciva y continua entonces los subconjuntos de nivel son compactos y por lo tanto su intersección con C también lo son. Esto implica que existe un mínimo global de f sobre C . Además f es estrictamente convexa pues $Hf \equiv I$, esto implica que el mínimo global es único x^* . Podemos entonces dar la siguiente definición:

Definición. Dado $C \subset \mathbb{R}^n$ cerrado y convexo, y $z \in \mathbb{R}^n$, definimos la proyección de z sobre C como

$$\pi_C(z) = \arg \min_{x \in C} \|x - z\|.$$

Es claro que si $z \in C$ su proyección es el mismo z . También es fácil de ver que si C es un subespacio, la proyección coincide con la proyección ortogonal usual.

Ahora, como $\nabla f(x) = x - z$, una condición suficiente para encontrar $\pi_C(z)$ es que

$$\langle \pi_C(z) - z, x - \pi_C(z) \rangle \geq 0$$

para todo $x \in C$. Esta desigualdad en realidad caracteriza la proyección.

Proposición. Dado $C \subset \mathbb{R}^n$ cerrado y convexo, y $z \in \mathbb{R}^n$. Entonces

$$\langle \pi_C(z) - z, x - \pi_C(z) \rangle \geq 0$$

Prueba. Sea $x \in C$ y $\alpha \in (0, 1]$, entonces $\alpha x + (1 - \alpha)\pi_C(z) \in C$, luego

$$\begin{aligned} \|\pi_C(z) - z\|^2 &\leq \|\alpha x + (1 - \alpha)\pi_C(z) - z\|^2 \\ &= \|\pi_C(z) - z + \alpha(x - \pi_C(z))\|^2 \\ &= \|\pi_C(z) - z\|^2 + \alpha^2\|x - \pi_C(z)\|^2 + 2\alpha\langle \pi_C(z) - z, x - \pi_C(z) \rangle, \end{aligned}$$

esto es

$$-\frac{\alpha}{2}\|x - \pi_C(z)\|^2 \leq \langle \pi_C(z) - z, x - \pi_C(z) \rangle,$$

y tomando $\alpha \downarrow 0$ se tiene el resultado. □

Esta caracterización permite mostrar que la función proyección sobre C es Lipschitz continua.

Corolario. La función $\pi_C : \mathbb{R}^n \mapsto C$ es Lipschitz continua con constante 1.

Prueba. Sean $x_1, x_2 \in \mathbb{R}^n$, entonces la desigualdad variacional anterior dice que

$$\begin{aligned} \langle x_1 - \pi_C(x_1), \pi_C(x_2) - \pi_C(x_1) \rangle &\leq 0 \\ \langle x_2 - \pi_C(x_2), \pi_C(x_1) - \pi_C(x_2) \rangle &\leq 0, \end{aligned}$$

y sumándolas se tiene que

$$\langle x_1 - x_2 + \pi_C(x_2) - \pi_C(x_2), \pi_C(x_2) - \pi_C(x_1) \rangle \leq 0,$$

luego

$$\|\pi_C(x_2) - \pi_C(x_1)\|^2 \leq \langle x_2 - x_1, \pi_C(x_2) - \pi_C(x_1) \rangle \leq \|x_2 - x_1\| \|\pi_C(x_2) - \pi_C(x_1)\|.$$

□

La proyección sobre conjuntos convexos cerrados nos permite llegar a los llamados teoremas de separación.

Teorema (Separación estricta de puntos). Sea C conjunto no vacío, convexo y cerrado y $z \notin C$. Entonces existe un hiperplano que separa estrictamente C de z , esto es, existe $a \neq 0$ tal que

$$\langle a, z \rangle > \sup_{x \in C} \langle a, x \rangle (= \sigma_C(a)).$$

Prueba. Sea $a = z - \pi_C(z) \neq 0$ pues $z \notin C$, así que la desigualdad variacional implica que para todo $x \in C$ vale

$$0 \geq \langle a, x - \pi_C(z) \rangle = \langle a, x - z + a \rangle = \langle a, x - z \rangle + \|a\|^2,$$

luego

$$\langle a, z \rangle \geq \langle a, x \rangle + \|a\|^2.$$

□

Teorema (Hiperplanos de soporte). Sea C conjunto no vacío, cerrado y convexo y $z \in C \setminus \text{int}(C) = \partial(C)$. Entonces existe un hiperplano de soporte C en z , esto es, existe $a \neq 0$ tal que para todo $x \in C$

$$\langle a, z - x \rangle \geq 0.$$

Prueba. Sea $\{x_k\} \subset C^C$ que converge a z , es decir una sucesión que converge a z desde afuera de C , por lo tanto $\pi_C(x_k) \neq x_k$. Sea

$$a_k = \frac{x_k - \pi_C(x_k)}{\|x_k - \pi_C(x_k)\|},$$

entonces la desigualdad variacional implica que para todo $x \in C$

$$\langle a_k, \pi_C(x_k) - x \rangle \geq 0.$$

Como la sucesión $\{a_k\}$ está en un compacto, tiene una subsucesión convergente a $a \neq 0$ pues tiene norma 1. Puesto que $\pi_C(x_k) \rightarrow \pi_C(z) = z$, al tomar el límite de la subsucesión a infinito se tiene que

$$0 \leq \langle a, z - x \rangle,$$

lo que muestra el resultado.

□

6.3. Subgradiientes II

Podemos ahora seguir con la discusión sobre los subdiferenciales. Recordemos que estos son siempre convexos y compactos.

Teorema. Sean f convexa y semicontinua por debajo, y $x \in \text{int}(\text{dom}(f))$. Entonces $\partial f(x)$ es no vacío.

Prueba. Sabemos que $(x, f(x)) \in \partial(\text{epi}(f))$, la frontera de $\text{epi}(f)$ que es un conjunto convexo y cerrado. Entonces existe un hiperplano de soporte del epigrafo en $(x, f(x))$, es decir, existen un vector a y un escalar γ con $\|a\|^2 + \gamma^2 = 1$ tales que

$$\langle a, x - y \rangle \geq \gamma(t - f(x)),$$

para todo $(y, t) \in \text{epi}(f)$. Si $t > f(x)$ entonces $(x, t) \in \text{epi}(f)$, luego $\gamma \leq 0$. Si $\gamma < 0$, tomando $g = -\frac{a}{\gamma}$, y $(y, f(y)) \in \text{epi}(f)$ y dividiendo por γ en la desigualdad de arriba se tiene que

$$f(y) \geq f(x) + \langle g, y - x \rangle,$$

luego $g \in \partial f(x)$. Veamos entonces que γ no puede ser 0. Como toda función convexa es localmente Lipschitz, existen $\epsilon > 0$ y $M > 0$ tales que

$$|f(y) - f(x)| \leq M\|y - x\|$$

para todo $y \in \mathcal{B}_\epsilon(x)$, y puesto que $\gamma \leq 0$, se tiene que

$$\langle a, x - y \rangle \geq \gamma(f(y) - f(x)) \geq \gamma M\|x - y\|.$$

Tomando $y = x + \epsilon a \in \mathcal{B}_\epsilon(x)$, tenemos que $\gamma \leq -\frac{\|a\|}{M}$, lo que implica que $\gamma < 0$. □

En realidad no es necesario que la función sea semicontinua para tener el resultado. Veamos ahora la relación entre derivadas direccionales funciones de soporte de subdiferenciales.

Teorema. Sean f convexa, $x \in \text{int}(\text{dom}(f))$ y $d \in \mathbb{R}^n$. Entonces

$$f'(x; d) = \max_{g \in \partial f(x)} \langle g, d \rangle = \sigma_{\partial f(x)}(d).$$

Prueba. Sea $g \in \partial f(x)$, entonces para todo $t > 0$ se tiene $f(x + td) \geq f(x) + t\langle g, d \rangle$, luego

$$\langle g, d \rangle \leq \frac{f(x + td) - f(x)}{t},$$

y tomando $t \downarrow 0$ se tiene que $f'(x; d) \geq \langle g, d \rangle$, así que $f'(x; d) \geq \max_{g \in \partial f(x)} \langle g, d \rangle$. Para mostrar la otra desigualdad vamos usar dos resultados auxiliares. Recordemos que la función $f'(x; \cdot)$ es convexa sobre todo $\mathbb{R}^n$.

- $\partial f(x) = \partial f'(x; 0)$. En efecto, puesto que $f'(x; 0) = 0$, y por el mismo argumento de arriba $f'(x; h) \geq \langle g, h \rangle$ para todo $g \in \partial f(x)$ y todo $h \in \mathbb{R}^n$, entonces

$$f'(x; h) \geq \langle g, h \rangle = f'(x; 0) + \langle g, h \rangle,$$

luego $\partial f(x) \subset \partial f'(x; 0)$. Para la otra contención, sea $g \in \partial f'(x; 0)$ y sea $y \in \text{dom}(f)$, entonces $f'(x; y - x) \geq \langle g, y - x \rangle$, luego, por (30)

$$f(y) \geq f(x) + f'(x; y - x) \geq f(x) + \langle g, y - x \rangle,$$

esto es, $g \in \partial f(x)$.

- $\partial f'(x; h) \subset \partial f'(x; 0)$ para todo $h \in \mathbb{R}^n$. Sea $g \in \partial f'(x; h)$, entonces, para todo $b \in \mathbb{R}^n$ se tiene que

$$f'(x; b) \geq f'(x; h) + \langle g, b - h \rangle$$

y para todo $\tau > 0$, por la homogeneidad positiva, se tiene que

$$\tau f'(x; b) = f'(x; \tau b) \geq f'(x; h) + \langle g, \tau b - h \rangle,$$

esto es,

$$f'(x; b) \geq \frac{f'(x; h) - \langle g, h \rangle}{\tau} + \langle g, b \rangle \quad (31)$$

y tomando $\tau \rightarrow \infty$ se tiene que $f'(x; b) \geq \langle g, b \rangle$, luego $g \in \partial f'(x; 0)$.

Volviendo a la desigualdad que queremos, para esto debemos encontrar un $g_d \in \partial f(x)$ tal que $f'(x; d) \leq \langle g_d, d \rangle$. Sea $g_d \in \partial f'(x; d) \subset \partial f(x)$ (y los subdiferenciales son no vacíos), entonces (31) se convierte en

$$f'(x; b) \geq \frac{f'(x; d) - \langle g_d, d \rangle}{\tau} + \langle g_d, b \rangle$$

y tomando $\tau \downarrow 0$ obtenemos que $f'(x; d) \leq \langle g_d, d \rangle$. □

Este teorema tiene como corolarios varios resultados importantes.

Corolario. f es Gâteaux diferenciable en $x \in \text{int}(\text{dom}(f))$ si y solo si $|\partial f(x)| = 1$. En este caso $\partial f(x) = \{\nabla f(x)\}$.

Prueba. Supongamos que f es Gâteaux diferenciable en x y $g \in \partial f(x)$, entonces para todo $d \in \mathbb{R}^n$ se tiene que $\langle \nabla f(x), d \rangle = f'(x; d) \geq \langle g, d \rangle$. Tomando $-d$ en la desigualdad anterior tenemos entonces que $\langle \nabla f(x), d \rangle = \langle g, d \rangle$ para todo d , lo que implica que $g = \nabla f(x)$ y $\partial f(x) = \{\nabla f(x)\}$. Conversamente, si $\partial f(x) = \{g\}$, entonces $f'(x; d) = \langle g, d \rangle$ para todo d , luego la derivada direccional es lineal y por lo tanto f es Gâteaux diferenciable en x con $g = \nabla f(x)$. □

Definición. Sea $f : \mathbb{R}^n \mapsto \mathbb{R} \cup \{\infty\}$ y $C \subset \text{dom}(f)$. Definimos la norma de Lipschitz de f con respecto a C como

$$\|f\|_{\text{Lip}, C} = \sup_{x, y \in \text{int}(C)} \frac{|f(x) - f(y)|}{\|x - y\|}.$$

Proposición. Sea f función convexa y Lipschitz en $C \subset \text{dom}(f)$ con C convexo. Entonces

$$\|f\|_{\text{Lip}, C} = \sup_{x \in \text{int}(C), g \in \partial f(x)} \|g\|_*.$$

Demostración. Sea $x \in \text{int}(C)$ y $d \in \mathbb{R}^n$ con $\|d\| \leq 1$, para $t > 0$ suficientemente pequeño se tiene que

$$f(x + td) - f(x) \leq t\|f\|_{\text{Lip}, C}\|d\|,$$

luego

$$\frac{f(x + td) - f(x)}{t} \leq \|f\|_{\text{Lip}, C},$$

es decir, $f'(x; d) \leq \|f\|_{\text{Lip}, C}$. Ahora, del teorema tenemos que

$$\max_{g \in \partial f(x)} \langle g, d \rangle \leq \|f\|_{\text{Lip}, C}.$$

Tomando el máximo sobre $x \in \text{int}(C)$ y $\|d\| \leq 1$ tenemos la primera desigualdad por la definición de norma dual. Ahora, para la desigualdad contraria, sean $x, y \in C$ con $g_x \in \partial(x)$ y $g_y \in \partial(y)$, entonces

$$f(y) \geq f(x) + \langle g_x, y - x \rangle,$$

luego

$$f(x) - f(y) \leq \langle g_x, x - y \rangle \leq \|g_x\|_* \|x - y\| \leq \left(\sup_{x \in \text{int}(C), g \in \partial f(x)} \|g\|_* \right) \|x - y\|.$$

Análogamente,

$$f(y) - f(x) \leq \langle g_y, y - x \rangle \leq \|g_y\|_* \|y - x\| \leq \left(\sup_{x \in \text{int}(C), g \in \partial f(x)} \|g\|_* \right) \|y - x\|.$$

Combinando las dos desigualdades tenemos que

$$|f(x) - f(y)| \leq \left(\sup_{x \in \text{int}(C), g \in \partial f(x)} \|g\|_* \right) \|x - y\|.$$

Dado que x, y son arbitrarios se tiene finalmente que

$$\|f\|_{\text{Lip}, C} \leq \sup_{x \in \text{int}(C), g \in \partial f(x)} \|g\|_*.$$

□

6.3.1. Cálculo con subgradientes

La siguiente es la herramienta principal para hacer cálculo con subgradientes.

Proposición. Sean C_1, C_2 conjuntos no vacíos cerrados y convexos.

1. Si $\sigma_{C_1} \leq \sigma_{C_2}$, entonces $C_1 \subset C_2$.
2. Si $\sigma_{C_1} = \sigma_{C_2}$, entonces $C_1 = C_2$.

Prueba.

1. Supongamos que $x \in C_1 \setminus C_2$, entonces existe un hiperplano que separa estrictamente x de C_2 , esto es, existen $a \neq 0$ y γ tales que

$$\langle a, x \rangle > \gamma \geq \langle a, y \rangle \quad \forall y \in C_2.$$

Esto implica que $\sigma_{C_2}(a) < \langle a, x \rangle \leq \sigma_{C_1}(a)$ que es una contradicción. Luego $C_1 \subset C_2$,

2. Se sigue del anterior.

□

Proposición. Sean f convexa con dominio en $\mathbb{R}^m$, $A \in \mathbb{R}^{m \times n}$, $b \in \mathbb{R}^m$. Definimos la función convexa $\varphi(x) = f(Ax + b)$. Entonces para $x \in \text{int}(\text{dom}(\varphi))$ se tiene que

$$\partial\varphi(x) = A^T \partial f(Ax + b).$$

Prueba. Es claro que φ es convexa. Sea $y = Ax + b$, entonces para $d \in \mathbb{R}^n$ se tiene que

$$\begin{aligned} \sigma_{\partial\varphi(x)}(d) &= \varphi'(x; d) = f'(y; Ad) \\ &= \max_{g \in \partial f(y)} \langle g, Ad \rangle = \max_{g \in \partial f(y)} \langle A^T g, d \rangle \\ &= \max_{h \in A^T \partial f(y)} \langle h, d \rangle = \sigma_{A^T \partial f(y)}(d). \end{aligned}$$

□

Proposición. Sean f_1, f_2 funciones convexas y α_1, α_2 reales no negativos. Si $\varphi = \alpha_1 f_1 + \alpha_2 f_2$ y $x \in \text{int}(\text{dom}(\varphi))$, entonces

$$\partial\varphi(x) = \alpha_1 \partial f_1(x) + \alpha_2 \partial f_2(x).$$

Prueba. De nuevo, sabemos que φ es convexa. Además, $x \in \text{int}(\text{dom}(f_1)) \cap \text{int}(\text{dom}(f_2))$. Entonces, para $d \in \mathbb{R}^n$ se tiene que

$$\begin{aligned} \sigma_{\partial\varphi(x)}(d) &= \varphi'(x; d) = \alpha_1 f'_1(x; d) + \alpha_2 f'_2(x; d) \\ &= f'_1(x; \alpha_1 d) + f'_2(x; \alpha_2 d) \\ &= \max_{g_1 \in \partial f_1(x)} \langle g_1, \alpha_1 d \rangle + \max_{g_2 \in \partial f_2(x)} \langle g_2, \alpha_2 d \rangle \\ &= \max_{g_1 \in \partial f_1(x), g_2 \in \partial f_2(x)} \langle \alpha_1 g_1 + \alpha_2 g_2, d \rangle \\ &= \max_{h \in \alpha_1 \partial f_1(x) + \alpha_2 \partial f_2(x)} \langle h, d \rangle = \sigma_{\alpha_1 \partial f_1(x) + \alpha_2 \partial f_2(x)}(d). \end{aligned}$$

□

Se puede mostrar que el resultado también es cierto para todo $x \in \text{dom}(\varphi)$ siempre que $\text{int}(\text{dom}(f_1)) \cap \text{int}(\text{dom}(f_2)) \neq \emptyset$.

Recordemos que al minimizar una función convexa sobre un conjunto convexo, una condición suficiente para un mínimo local es la existencia de $g \in \partial f(x)$ es tal que $\langle g, y - x \rangle \geq 0$ para todo $y \in C$, veamos que también es una condición necesaria.

Corolario. Sean f convexa y $C \subset \text{dom}(f)$ convexo con interior no vacío, entonces $x \in C$ es mínimo global de f sobre C si y solo si existe $g \in \partial f(x)$ tal que $\langle g, y - x \rangle \geq 0$ para todo $y \in C$.

Prueba. Consideremos $\varphi = f + \chi_C$. Entonces para $x \in C$ se tiene que $\partial\varphi(x) = \partial f(x) + \partial\chi_C(x)$. Ahora, x es un mínimo global de f sobre C si y solo si es un mínimo de φ , que es equivalente a que $0 \in \partial\varphi(x) = \partial f(x) + N_C(x)$, que es equivalente a que exista $g \in \partial f(x)$ tal que

$-g \in N_C(x)$, que es equivalente a que exista $g \in \partial f(x)$ tal que $\langle g, y - x \rangle \geq 0$ para todo $y \in C$. $\square$

Si f es Gâteaux diferenciable, el resultado anterior nos dice que x es mínimo de f sobre C si y solo si $\langle \nabla f(x), y - x \rangle \geq 0$ para todo $y \in C$.

Proposición. Sean $\{f_i\}_{i \in I}$ funciones convexas y $\varphi(x) = \sup_{i \in I} f_i(x)$. Si $x \in \text{dom}(\varphi)$, entonces

$$\text{conv}\{\partial f_i(x) : i \in I(x)\} \subset \partial \varphi(x),$$

donde $I(x) = \{i \in I : \varphi(x) = f_i(x)\}$.

Prueba. Sea $i \in I(x)$ y $g \in \partial f_i(x)$, entonces para $y \in \text{dom}(f_i)$ se tiene que,

$$\varphi(y) \geq f_i(y) \geq f_i(x) + \langle g, y - x \rangle = \varphi(x) + \langle g, y - x \rangle,$$

luego $g \in \partial \varphi(x)$. Puesto que $\varphi(x)$ es convexo, se tiene el resultado. $\square$

Ahora, cuando se toma el máximo de finitas funciones este resultado se puede mejorar.

Proposición. Sea $\varphi(x) = \max_{1 \leq i \leq m} f_i(x)$ con f_i convexa, y sea $x \in \text{int}(\text{dom}(\varphi))$. Entonces

$$\text{conv}\{\partial f_i(x) : i \in I(x)\} = \partial \varphi(x),$$

con $I(x)$ igual que antes.

Prueba. Supongamos, sin pérdida de generalidad, que $I(x) = \{1, \dots, k\}$. Sea $d \in \mathbb{R}^n$, entonces se tiene que (ejercicio)

$$\varphi'(x; d) = \max_{1 \leq i \leq k} f'_i(x; d).$$

Luego, como $x \in \text{int}(\text{dom}(f_i))$ para todo i ,

$$\begin{aligned} \sigma_{\partial \varphi(x)}(d) &= \max_{1 \leq i \leq k} \max_{g_i \in \partial f_i(x)} \langle g_i, d \rangle \\ &= \max_{\lambda \in \Delta_k} \sum_{i=1}^k \lambda_i \max_{g_i \in \partial f_i(x)} \langle g_i, d \rangle \\ &= \max \left\{ \sum_{i=1}^k \langle \lambda_i g_i, d \rangle : g_i \in \partial f_i(x), \lambda \in \Delta_k \right\} \\ &= \max \left\{ \langle g, d \rangle : g = \sum_{i=1}^k \lambda_i g_i, g_i \in \partial f_i(x), \lambda \in \Delta_k \right\} \\ &= \max \{ \langle g, d \rangle : g \in \text{conv}\{\partial f_i(x) : i \in I(x)\} \}. \end{aligned}$$

$\square$

La siguiente es una consecuencia muy útil del resultado anterior.

Corolario (Condiciones de KKT). Sean $f, f_1, \dots, f_m$ funciones convexas y Gâteaux diferenciables en $\mathbb{R}^n$. Supongamos que existe $\bar{x}$ tal que $f_i(\bar{x}) < 0$ para $i = 1, \dots, m$ (conocida como la condición de Slater). Entonces x^* es óptimo del problema de optimización

$$\begin{aligned} f^* &= \min && f(x) \\ \text{sujeto a} &&& f_i(x) \leq 0, \quad i = 1, \dots, m \\ &&& x \in \mathbb{R}^n, \end{aligned}$$

si y solo si $f_i(x^*) \leq 0$ para todo i y además existen $\lambda_i \geq 0$ para $i \in I = \{i : f_i(x^*) = 0\}$ tales que

$$\nabla f(x^*) + \sum_{i \in I} \nabla f_i(x^*) = 0.$$

Prueba. Sea $\varphi(x) = \max\{f(x) - f^*, f_1(x), \dots, f_m(x)\}$, entonces $\varphi \geq 0$ y además x^* es óptimo del problema de optimización si y solo si x^* es mínimo global de φ con $\varphi(x^*) = 0$, si y solo si $0 \in \partial\varphi(x^*)$, si y solo si $0 \in \text{conv}\{\nabla f(x^*), \nabla f_i(x^*), i \in I\}$. $\square$

6.4. Teoremas de separación II

Veamos en esta parte algunas aplicaciones de los teoremas de separación principales que vimos antes, estos son el teorema de separación estricta de un punto fuera de un convexo cerrado y el teorema del hiperplano de soporte.

Teorema (Separación fuerte de conjuntos convexas). Sean A, B conjuntos convexas, cerrados y disjuntos. Si uno de ellos es acotado entonces existen $a \neq 0$ y $\alpha \in \mathbb{R}$ tales que

$$\inf_{x \in A} \langle a, x \rangle > \alpha > \sup_{y \in B} \langle a, y \rangle.$$

Prueba. Asumamos que B es compacto, en ese caso podemos cambiar el sup por máx. Sea $C = A - B$, entonces C es convexo y además no contiene al 0 pues A y B son disjuntos. Veamos que C es cerrado. Sea $z_k = x_k - y_k \rightarrow z$ sucesión convergente de elementos en C . Como B es compacto tenemos una subsucesión de los y_k convergente a $y \in B$. Pasando a la subsucesión tenemos entonces que $x_k \rightarrow y + z =: x$, y como A es cerrado, entonces $y + z \in A$, luego $z = x - y \in C$. Así que $0 \notin C$ convexo y cerrado, luego existe $a \neq 0$ tal que $\langle a, z \rangle \geq \|a\|^2 > 0$ para todo $z \in C$, es decir, $\langle a, x - y \rangle \geq \|a\|^2$ para todo $x \in A$ y $y \in B$. Tomando $\alpha = \frac{\|a\|^2}{2} + \max_{y \in B} \langle a, y \rangle$ se tiene el resultado. $\square$

Teorema. Sea C convexo y cerrado. Entonces C es la intersección de todos los semiespacios cerrados que lo contienen.

Prueba. Dados $a \neq 0 \in \mathbb{R}^n$ y $\alpha \in \mathbb{R}$, sea $H_{a,\alpha} = \{y : \langle a, y \rangle \geq \alpha\}$. Definimos $D := \bigcap_{C \subset H_{a,\alpha}} H_{a,\alpha}$, es decir, la intersección de todos los semiespacios que contienen a C . Es claro que D es cerrado y convexo y además que $C \subset D$. Supongamos que $x \in D \setminus C$, entonces existen $a \neq 0$ y α tales que $\langle a, x \rangle < \alpha < \langle a, y \rangle$ para todo $y \in C$, luego $x \notin H_{a,\alpha}$ y $C \subset H_{a,\alpha}$ y por lo tanto $D \subset H_{a,\alpha}$, lo que contradice que $x \in D$. $\square$

Corolario. Sea $C \subset \mathbb{R}^{n+1}$ convexo y cerrado tal que no contiene rectas verticales, es decir, rectas con dirección $(0, \gamma)$, $\gamma \neq 0$. Entonces existe un semiespacio no vertical que lo contiene, es decir, existen a , $\beta \neq 0$ y α tales que

$$\langle a, x \rangle + \beta x_{n+1} \geq \alpha$$

para todo $(x, x_{n+1}) \in C$.

Prueba. Supongamos que todo semiespacio que contiene a C es vertical, es decir, todos los semiespacios que contienen a C tiene vector director de la forma $(a, 0)$ y por lo tanto si $(x, x_{n+1}) \in C$, luego está en todos los semiespacios verticales, entonces la recta $\{(x, t\gamma + x_{n+1}) : t \in \mathbb{R}\}$, con $\gamma \neq 0$ está en todos los semiespacios que contienen a C , luego está en C y tenemos una contradicción. $\square$

Definición. Sea $C \subset \mathbb{R}^n$ no vacío. El cono dual de C , denotado como C^* se define como

$$C^* = \{y \in \mathbb{R}^n : \langle x, y \rangle \geq 0 \quad \forall x \in C\}.$$

Notemos que

$$C^* = \bigcap_{x \in C} \{y : \langle x, y \rangle \geq 0\},$$

luego es intersección de semiespacios cerrados y por lo tanto es un cono convexo y cerrado. Ahora, para todo $x \in C$ se tiene que $\langle x, y \rangle \geq 0$ para todo $y \in C^*$, luego $x \in C^{**}$, esto es, $C \subset C^{**}$.

Teorema. Sea C un cono convexo y cerrado, entonces $C^{**} = C$.

Prueba. Ya tenemos una dirección. Supongamos que $x \in C^{**} \setminus C$, entonces, como $x \notin C$ existe un hiperplano que separa estrictamente x de C , esto es, $a \neq 0$ tal que para todo $z \in C$ se tiene que

$$\langle a, x \rangle < \langle a, z \rangle.$$

Como C es un cono la desigualdad anterior vale para tz con $t > 0$ y $z \in C$, luego $\langle a, z \rangle \geq 0$ para todo z , esto es $a \in C^*$, y como $x \in C^{**}$, se debe cumplir que $\langle a, x \rangle \geq 0$, lo que contradice la desigualdad anterior tomando $z = 0 \in C$. $\square$

6.5. Funciones conjugadas

Dada $f : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{\infty\}$, definimos la conjugada convexa de f como:

$$f^*(y) = \sup_{x \in \mathbb{R}^n} \langle x, y \rangle - f(x).$$

Puesto que f^* es el supremo de funciones convexas y cerradas, entonces f^* es convexa y cerrada. Ahora, de la definición de f^* tenemos que para todo $x, y \in \mathbb{R}^n$ se tiene que

$$f^*(y) \geq \langle x, y \rangle - f(x) \iff f(x) \geq \langle x, y \rangle - f^*(y),$$

y tomando el supremo sobre y se tiene que $f(x) \geq f^{**}(x)$. Ahora, si f es convexa y cerrada podemos mostrar la desigualdad contraria. En efecto, supongamos que existe x tal

que $f^{**}(x) < f(x)$, como $\text{epi}(f)$ es convexo, cerrado y no contiene rectas verticales, por el corolario de antes, existe un hiperplano no vertical que separa estrictamente $(x, f^{**}(x))$ de $\text{epi}(f)$, esto es, existen $a, \beta \neq 0$ y α tales que

$$\langle a, z \rangle + \beta t < \alpha < \langle a, x \rangle + \beta f^{**}(x),$$

para todo $(z, t) \in \text{epi}(f)$. Puesto que t puede ser arbitrariamente grande se tiene que $\beta < 0$, luego podemos tomarlo como -1 con lo que obtenemos que

$$\langle a, z \rangle - f(z) < \alpha < \langle a, x \rangle - f^{**}(x),$$

y tomando el supremo sobre z tenemos que $f^*(a) < \langle a, x \rangle - f^{**}(x)$ lo que contradice la definición de $f^{**}(x)$. Veamos un teorema importante que relaciona las funciones conjugadas con los subgradietes.

Teorema (Igualdad de Fenchel-Young). Sea $f : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{\infty\}$ cerrada y convexa. Entonces los siguientes son equivalentes:

- (i) $\langle x, y \rangle = f(x) + f^*(y)$,
- (ii) $y \in \partial f(x)$,
- (iii) $x \in \partial f^*(y)$.

Prueba. De la definición de f^* es claro que $\langle x, y \rangle \leq f(x) + f^*(y)$, luego el contenido de este resultado es la desigualdad contraria. Supongamos que $\langle x, y \rangle \geq f(x) + f^*(y)$, entonces para todo z se tiene que

$$\langle x, y \rangle \geq f(x) + \langle z, y \rangle - f(z) \iff f(z) \geq f(x) + \langle y, z - x \rangle,$$

es decir, $y \in \partial f(x)$. Supongamos ahora que $y \in \partial f(x)$, es decir, para todo z se tiene que $\langle x, y \rangle \geq f(x) + \langle z, y \rangle - f(z)$ y tomando supremos sobre z se tiene que $\langle x, y \rangle \geq f(x) + f^*(y)$. Mostramos entonces la equivalencia de las dos primeras afirmaciones. Ahora, como f es cerrada y convexa, la primera afirmación se puede escribir como $\langle y, x \rangle = f^*(y) + f^{**}(x)$, luego aplicando la equivalencia anterior a la función f^* se tiene la equivalencia de (i) y (iii). $\square$

7. Optimización convexa no suave

7.1. Método del subgradiente

En este caso vamos a considerar f convexa, pero no suave y resolver el problema

$$\min_{x \in \mathbb{R}^n} f(x).$$

Asumimos que para cada $x \in \text{dom}(f)$ podemos encontrar $g(x) \in \partial f(x)$, recordemos que este conjunto es no vacío y acotado. Siguiendo la misma idea del método del descenso del gradiente, en el método del subgradiente generamos una sucesión dada por

$$x_{k+1} = x_k - \alpha_k g(x_k),$$

donde, como antes, α_k es el tamaño del paso. Una diferencia importante con el método del descenso del gradiente es que un subgradiente no es necesariamente una dirección de descenso, pero escogiendo un tamaño de paso adecuado se puede lograr la convergencia del método, como veremos más adelante. Sea x^* óptimo global de f , y notando $r_k = \|x_k - x^*\|$, entonces

$$\begin{aligned} r_{k+1}^2 &= \|x_k - x^* - \alpha_k g(x_k)\|^2 \\ &= r_k^2 + \alpha_k^2 \|g(x_k)\|^2 - 2\alpha_k \langle g(x_k), x_k - x^* \rangle \\ &\leq r_k^2 + \alpha_k^2 \|g(x_k)\|^2 - 2\alpha_k (f(x_k) - f(x^*)). \end{aligned}$$

Si iniciamos con $x_1 \in B_R(x^*)$ y sumamos la desigualdad obtenemos que

$$\sum_{i=1}^k \alpha_i (f(x_i) - f(x^*)) \leq \frac{R^2}{2} + \frac{1}{2} \sum_{i=1}^k \alpha_i^2 \|g(x_i)\|^2.$$

Vamos a asumir ahora que f es L -Lipschitz, luego para todo x se tiene que

$$\|g(x)\| \leq L,$$

y por lo tanto

$$\sum_{i=1}^k \alpha_i (f(x_i) - f(x^*)) \leq \frac{R^2}{2} + \frac{L^2}{2} \sum_{i=1}^k \alpha_i^2.$$

Ahora, como no tenemos un descenso garantizado podemos guardar el registro de los mejores puntos y para esto definimos

$$f_k^* = \min_{0 \leq i \leq k} f(x_i),$$

y con esto llegamos a

$$f_k^* - f(x^*) \leq \frac{R^2 + L^2 \sum_{i=1}^k \alpha_i^2}{2 \sum_{i=1}^k \alpha_i}.$$

Tomando entonces una sucesión $\{\alpha_k\}_{k \geq 1}$ tal que $\alpha_k \rightarrow 0$ y además su serie diverja, $\sum_k \alpha_k = \infty$, tenemos que $f_k^* \rightarrow f(x^*)$. El problema con esta forma de escoger el tamaño de los pasos es que la convergencia es muy lenta. Otra forma de escoger el tamaño del paso es fijando un número de iteraciones N y tomando $\alpha_k = \frac{R}{L\sqrt{N}}$ obtenemos la cota

$$f_N^* - f^* \leq \frac{LR}{\sqrt{N}}.$$

Puesto que L puede ser difícil de estimar, tomar $\alpha_k = \frac{R}{\|g(x_k)\|\sqrt{N}}$ da la misma cota. En este caso no podemos garantizar la convergencia pero sí garantizar una mejor cota para la diferencia. Ahora, de la desigualdad

$$r_{k+1}^2 \leq r_k^2 + \alpha_k^2 \|g(x_k)\|^2 - 2\alpha_k (f(x_k) - f(x^*)),$$

podemos ver que la mejor forma de escoger el tamaño de paso, si conoces $f(x^*)$ (o lo podemos estimar), es

$$\alpha_k = \frac{f(x_k) - f(x^*)}{\|g(x_k)\|^2},$$

conocido como el tamaño de paso de Polyak, con lo que obtenemos que

$$r_{k+1}^2 \leq r_k^2 - \frac{(f(x_k) - f(x^*))^2}{\|g(x_k)\|^2},$$

y sumando, finalmente llegamos a que

$$\sum_{i=1}^k (f(x_i) - f(x^*))^2 \leq R^2 L^2.$$

Esta desigualdad garantiza que para todo k

$$f_k^* - f(x^*) \leq \frac{LR}{\sqrt{k}},$$

por lo tanto se tiene convergencia a la mejor tasa posible.

Consideremos ahora el problema con restricciones de la forma

$$f^* = \min_{x \in C} f(x),$$

con C convexo y cerrado y sea $x^* \in C$ mínimo. En este caso tenemos el método del subgradiente proyectado en el cual

$$x_{k+1} = \pi_C(x_k - \alpha_k g(x_k)).$$

El éxito del método radica en la eficiencia computacional de la proyección, y esto depende del conjunto C . Algunos casos de conjuntos cuya proyección es sencilla son las bolas respecto a la norma euclídea o respecto a la norma ℓ_∞ , o de forma más general, el producto de intervalos cerrados.

Veamos ahora la convergencia del método. Puesto que

$$r_{k+1}^2 = \|\pi_C(x_k - \alpha_k g(x_k)) - x^*\|^2 = \|\pi_C(x_k - \alpha_k g(x_k)) - \pi_C(x^*)\|^2 \leq \|x_k - \alpha_k g(x_k) - x^*\|^2,$$

pues la función proyección es 1-Lipschitz, entonces podemos hacer el mismo análisis que en el método del subgradiente. Ahora, si que C es compacto, esto es, existe R tal que $\|x - x^*\| \leq R$ para todo $x \in C$, podemos hacer un análisis distinto. Bajo este supuesto además existe $L > 0$ tal que f es L -Lipschitz sobre C . Además vamos a asumir que la sucesión $\{\alpha_k\}$ es no creciente. Igual que antes tenemos que

$$r_{k+1}^2 \leq r_k^2 + \alpha_k^2 \|g(x_k)\|^2 - 2\alpha_k (f(x_k) - f(x^*)),$$

luego

$$f(x_k) - f^* \leq \frac{1}{2\alpha_k} (r_k^2 - r_{k+1}^2) + \frac{\alpha_k}{2} \|g(x_k)\|^2,$$

y sumando

$$\sum_{i=1}^k (f(x_i) - f(x^*)) \leq \sum_{i=1}^k \frac{1}{2\alpha_i} (r_i^2 - r_{i+1}^2) + \frac{1}{2} \sum_{i=1}^k \alpha_i \|g(x_i)\|^2.$$

Podemos organizar el primer sumando del lado derecho de tal forma que

$$\begin{aligned} \sum_{i=1}^k \frac{1}{2\alpha_i} (r_i^2 - r_{i+1}^2) &= \sum_{i=2}^k \left(\frac{1}{2\alpha_i} - \frac{1}{2\alpha_{i-1}} \right) r_i^2 + \frac{1}{2\alpha_1} r_1^2 - \frac{1}{2\alpha_k} r_{k+1}^2 \\ &\leq \sum_{i=2}^k \left(\frac{1}{2\alpha_i} - \frac{1}{2\alpha_{i-1}} \right) R^2 + \frac{1}{2\alpha_1} R^2 \\ &= \frac{R^2}{2\alpha_k} \end{aligned}$$

donde la desigualdad se tiene pues $\alpha_i \leq \alpha_{i-1}$. Finalmente tenemos la desigualdad

$$f_k^* - f^* \leq \frac{R^2}{2k\alpha_k} + \frac{L^2}{2k} \sum_{i=1}^k \alpha_i.$$

Tomando $\alpha_k = \frac{\alpha}{\sqrt{k}}$ con $\alpha > 0$ y usando que $\sum_{i=1}^k \frac{1}{\sqrt{i}} \leq 2\sqrt{k}$, tenemos que

$$f_k^* - f^* \leq \frac{R^2}{2\alpha\sqrt{k}} + \frac{L^2\alpha}{\sqrt{k}}.$$

Tomando $\alpha = \frac{R}{L}$ se logra la cota $\frac{3RL}{2\sqrt{k}}$.

7.2. Método del (sub)gradiente estocástico

El método del subgradiente, aunque con una convergencia lenta, es muy útil en problemas de gran escala por ser muy sencillos de implementar y esto lo hace muy robusto a posible ruido en cada una de las iteraciones. Esto se hace evidente en el método del subgradiente estocástico que veremos a continuación.

Definición. Dada $f : \mathbb{R}^n \mapsto \mathbb{R} \cup \{\infty\}$ convexa un subgradiente estocástico de f en x es una tupla $(\Omega, \mathfrak{F}, \mathcal{P}, g)$ tal que $(\Omega, \mathfrak{F}, \mathcal{P})$ es un espacio de probabilidad, $g : \mathbb{R}^n \times \Omega \mapsto \mathbb{R}^n$ y para cada $x \in \text{dom}(f)$ se tiene que

$$\mathbb{E}_{\mathcal{P}}[g(x)] = \int_{\Omega} g(x, \omega) d\mathcal{P}(\omega) \in \partial f(x).$$

De acuerdo con la definición anterior tenemos que $g(x, \cdot)$ es un vector aleatorio cuyo valor esperado bajo la distribución $\mathcal{P}$ es un subgradiente de f en x . Usualmente escribiremos simplemente $g(x)$ para referirnos a este vector aleatorio.

Ejemplo. Sea $f(x) = \frac{1}{N} \sum_{i=1}^N f_i(x)$ donde f_i es una función convexa y diferenciable para cada i . Podemos tomar $\Omega = \{1, \dots, N\}$, $\mathcal{P}$ la distribución uniforme sobre Ω y $g(x, i) = \nabla f_i(x)$. Así,

$$\mathbb{E}_{\mathcal{P}}[g(x)] = \frac{1}{N} \sum_{i=1}^N \nabla f_i(x) = \nabla f(x),$$

luego esto define una gradiente estocástico. Esto es, si escogemos un índice i aleatoriamente y calculamos $\nabla f_i(x)$ entonces tenemos un gradiente estocástico de f en x . Si las funciones no son diferenciables podemos escoger un subgradiente fijo en $\partial f_i(x)$.

El método del subgradiente estocástico consiste entonces en escoger en cada iteración $g(x_k)$ y definir

$$x_{k+1} = \pi_C(x_k - \alpha_k g(x_k)).$$

De esta forma tenemos un proceso estocástico $\{x_k\}$. Para analizar la convergencia del método vamos a asumir, igual que antes, que C está contenido en una bola de radio R centrada en el origen y que para todo x se tiene que $\mathbb{E}_{\mathcal{P}}[\|g(x)\|^2] \leq M^2$. Para facilitar el análisis vamos a notar $f'(x) = \mathbb{E}_{\mathcal{P}}[g(x)] \in \partial f(x)$. Igual que en el método del subgradiente proyectado se tiene que

$$r_{k+1}^2 = \|x_{k+1} - x^*\|^2 \leq r_k^2 - 2\alpha_k \langle g(x_k), x_k - x^* \rangle + \alpha_k^2 \|g(x_k)\|^2,$$

donde esta desigualdad se tiene con probabilidad 1. Puesto que $g(x_k)$ no es un verdadero subgradiente vamos a sumar y restar el término $2\alpha_k \langle f'(x_k), x_k - x^* \rangle$. Notemos que $f'(x_k)$ es un vector aleatorio pues x_k también lo es. Entonces, si denotamos $\xi_k = g(x_k) - f'(x_k)$, se tiene que

$$\begin{aligned} r_{k+1}^2 &\leq r_k^2 - 2\alpha_k \langle f'(x_k), x_k - x^* \rangle + \alpha_k^2 \|g(x_k)\|^2 - 2\alpha_k \langle \xi_k, x_k - x^* \rangle \\ &\leq r_k^2 - 2\alpha_k (f(x_k) - f^*) + \alpha_k^2 \|g(x_k)\|^2 - 2\alpha_k \langle \xi_k, x_k - x^* \rangle. \end{aligned}$$

Reorganizando y sumando igual que antes, se obtiene con probabilidad 1 que

$$\sum_{i=1}^k (f(x_i) - f^*) \leq \frac{R^2}{2\alpha_k} + \frac{1}{2} \sum_{i=1}^k \alpha_i \|g(x_i)\|^2 - \sum_{i=1}^k \langle \xi_i, x_i - x^* \rangle.$$

Ahora, como

$$\begin{aligned} \mathbb{E}_{\mathcal{P}}[\langle \xi_i, x_i - x^* \rangle] &= \mathbb{E}_{\mathcal{P}}[\mathbb{E}_{\mathcal{P}}[\langle g(x_i) - f'(x_i), x_i - x^* \rangle | x_i]] \\ &= \mathbb{E}_{\mathcal{P}}[\langle \mathbb{E}_{\mathcal{P}}[g(x_i) | x_i] - f'(x_i), x_i - x^* \rangle] = 0 \end{aligned}$$

entonces

$$\mathbb{E}_{\mathcal{P}}[f_k^* - f^*] \leq \frac{R^2}{2k\alpha_k} + \frac{M^2}{2k} \sum_{i=1}^k \alpha_i,$$

y tomando $\alpha_k = \frac{R}{M\sqrt{k}}$ se tiene

$$\mathbb{E}_{\mathcal{P}}[f_k^* - f^*] \leq \frac{3RM}{2\sqrt{k}}.$$

La desigualdad anterior muestra también, usando la desigualdad de Markov, que $f_k^* \rightarrow f^*$ en probabilidad. Usando la desigualdad de Azuma y asumiendo que todos los gradientes estocásticos están acotados, entonces se puede mostrar que $f_k^* - f^*$ se puede acotar con alta probabilidad.

7.3. Método del gradiente proximal

Sea $h : \mathbb{R}^n \rightarrow \mathbb{R}$ una función convexa y semicontinua por debajo, entonces para todo x la función $z \mapsto h(z) + \frac{1}{2}\|z - x\|^2$ es coerciva y estrictamente convexa, luego tiene un único mínimo, así que podemos definir el *operador proximal* como

$$\text{prox}_h(x) = \arg \min_{z \in \mathbb{R}^n} h(z) + \frac{1}{2}\|x - z\|^2.$$

Ahora, si $\alpha > 0$, entonces $\text{prox}_{\alpha h}(x)$ satisface que $0 \in \alpha \partial h(\text{prox}_{\alpha h}(x)) - (x - \text{prox}_{\alpha h}(x))$, luego

$$\frac{x - \text{prox}_{\alpha h}(x)}{\alpha} \in \partial h(\text{prox}_{\alpha h}(x)). \quad (32)$$

Ahora, encontrar este mínimo no siempre es fácil, depende de la función h , veamos algunos ejemplos.

- $h(x) = 0$. En este caso $\text{prox}_h(x) = x$.
- $h(x) = \mathbf{I}_C(x)$, la función indicadora de un conjunto C convexo y cerrado. En este caso $\text{prox}_h(x) = \arg \min_{z \in C} \|x - z\| = \Pi_C(x)$, la proyección de x sobre C .
- $h(x) = \alpha \|x\|_1$, con $\alpha > 0$. Sea $\text{prox}_h(x) = z^*$, de (32) tenemos que $\frac{x - z^*}{\alpha} \in \partial(\|z^*\|_1)$. Así que

- si $z_i^* < 0$, entonces $\frac{x_i - z_i^*}{\alpha} = -1$, luego $z_i^* = x_i + \alpha$,
- si $z_i^* > 0$, entonces $\frac{x_i - z_i^*}{\alpha} = 1$, luego $z_i^* = x_i - \alpha$,
- si $z_i^* = 0$, entonces $\frac{x_i}{\alpha} \in [-1, 1]$, luego $|x_i| \leq \alpha$.

Finalmente, tenemos que

$$z_i^* = \begin{cases} x_i - \alpha & \text{si } x_i > \alpha \\ 0 & \text{si } |x_i| \leq \alpha \\ x_i + \alpha & \text{si } x_i < -\alpha. \end{cases}$$

Consideremos ahora el problema

$$g^* = \min_{x \in \mathbb{R}^n} g(x) := f(x) + h(x)$$

donde $f \in C^1$, las dos funciones son convexas y h es cerrada. Funciones de esta forma son ahora muy populares, especialmente cuando f es una función de error y h como en el tercer ejemplo de arriba.

Veamos cómo usamos el operador proximal para construir el método del gradiente proximal. Recordemos que una forma de interpretar el método del descenso gradiente es minimizar una aproximación cuadrática de la función de la forma

$$\phi(z) = f(x_k) + \langle \nabla f(x_k), z - x_k \rangle + \frac{1}{2\alpha_k} \|z - x_k\|^2.$$

Así que si hacemos la misma aproximación en la parte diferenciable de g podemos encontrar el siguiente paso del método como

$$\begin{aligned} x_{k+1} &= \arg \min_{z \in \mathbb{R}^n} \phi(z) + h(z) \\ &= \arg \min_{z \in \mathbb{R}^n} f(x_k) + \langle \nabla f(x_k), z - x_k \rangle + \frac{1}{2\alpha_k} \|z - x_k\|^2 + h(z) \\ &= \arg \min_{z \in \mathbb{R}^n} \langle \nabla f(x_k), z - x_k \rangle + \frac{1}{2\alpha_k} \|z - x_k\|^2 + h(z) \\ &= \arg \min_{z \in \mathbb{R}^n} h(z) + \frac{1}{2\alpha_k} \|z - (x_k - \alpha_k \nabla f(x_k))\|^2 \\ &= \text{prox}_{\alpha_k h}(x_k - \alpha_k \nabla f(x_k)). \end{aligned}$$

Notemos que si $h = 0$ recuperamos el método del descenso del gradiente. Si $h = \mathbf{I}_C$, con C conjunto convexo y cerrado, obtenemos el método del *gradiente proyectado*

$$x_{k+1} = \Pi_C(x_k - \alpha_k \nabla f(x_k))$$

para resolver el problema $\min_{x \in C} f(x)$. Veamos otro ejemplo, el problema de *matrix completion*. Sea A una matriz de $m \times n$ de la cual sólo se conocen algunas de sus entradas dadas por el conjunto Ω , se quiere completar la matriz de tal forma que tengo el menor rango posible. Así que, idealmente, se quiere resolver el problema

$$\begin{aligned} \min \quad & \rho(X) \\ \text{sujeto a} \quad & X_{ij} = A_{ij} \quad \forall (i, j) \in \Omega. \end{aligned}$$

La función rango ρ es una función que no es convexa y bastante difícil de optimizar, así que se suele aproximar por la norma nuclear $\|\cdot\|_*$: Dada una matriz X de $m \times n$ con $\rho(X) = r$, siempre la podemos factorizar de la forma $X = U\Sigma V^T$, donde Σ es una matriz diagonal de $r \times r$ con los valores singulares de X , $\sigma_i(X)$, (es decir, la raíz cuadrada de los valores propios positivos de $X^T X$) y U, V son matrices con columnas ortonormales con las dimensiones apropiadas, así $\|X\|_* = \sum_i \sigma_i(X)$. Tenemos entonces que el problema anterior se reemplaza por

$$\min_X \quad \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - A_{ij})^2 + \lambda \|X\|_* = \frac{1}{2} \|\Pi_\Omega(X) - \Pi_\Omega(A)\|_F^2 + \lambda \|X\|_*,$$

donde Π_Ω es la proyección sobre el subespacio definido por Ω , $\|X\|_F^2 = \text{tr}(X^T X)$ y $\lambda > 0$ es un parámetro de regularización. Ahora, se puede mostrar que si X tiene la factorización descrita arriba, entonces

$$\text{prox}_{\lambda \|\cdot\|_*}(X) = \arg \min_Z \lambda \|Z\|_* + \frac{1}{2} \|Z - X\|_F^2 = U \hat{\Sigma} V^T,$$

donde $\hat{\Sigma}_{ii} = \max\{\Sigma_{ii} - \lambda, 0\}$. Aplicando el método del gradiente proximal a esta función vemos que las iteraciones toman la forma (con tamaño de paso 1)

$$X_{k+1} = \text{prox}_{\lambda\|\cdot\|_*}(X - \Pi_\Omega(X) - \Pi_\Omega(A)) = \text{prox}_{\lambda\|\cdot\|_*}(\Pi_{\Omega^c}(X) - \Pi_\Omega(A)).$$

Si definimos $G_\alpha(x) = \frac{x - \text{prox}_{\alpha h}(x - \alpha \nabla f(x))}{\alpha}$, entonces podemos escribir el método como

$$x_{k+1} = x_k - \alpha_k G_{\alpha_k}(x_k).$$

De (32) tenemos entonces que para $\alpha > 0$

$$\begin{aligned} G_\alpha(x) - \nabla f(x) &= \frac{x - \alpha \nabla f(x) - (x - \alpha G_\alpha(x))}{\alpha} \\ &= \frac{x - \alpha \nabla f(x) - \text{prox}_{\alpha h}(x - \alpha \nabla f(x))}{\alpha} \\ &\in \partial h(x - \alpha G_\alpha(x)), \end{aligned} \tag{33}$$

así que $G_\alpha(x) \in \partial h(x - \alpha G_\alpha(x)) + \nabla f(x)$, y si x^* satisface que $G_\alpha(x^*) = 0$ entonces $0 \in \partial h(x^*) + \nabla f(x^*)$, luego x^* minimiza g . Ahora $G_\alpha(x^*) = 0$ es equivalente a que $\text{prox}_{\alpha h}(x^* - \alpha \nabla f(x^*)) = x^*$ y por lo tanto un criterio de parada del método puede ser $\|G_{\alpha_k}(x_k)\| \leq \frac{\epsilon}{\alpha_k}$.

Veamos ahora la convergencia del método. Asumamos ahora que f tiene gradiente L -Lipschitz, usando (3), y tomando $\alpha \leq \frac{1}{L}$, tenemos que

$$\begin{aligned} f(x - \alpha G_\alpha(x)) &\leq f(x) - \alpha \langle \nabla f(x), G_\alpha(x) \rangle + \frac{\alpha^2 L}{2} \|G_\alpha(x)\|^2 \\ &\leq f(x) - \alpha \langle \nabla f(x), G_\alpha(x) \rangle + \frac{\alpha}{2} \|G_\alpha(x)\|^2. \end{aligned} \tag{34}$$

Nota. La desigualdad anterior se puede usar para escoger el tamaño del paso usando *backtracking*. Notemos que cada vez que se evalúa un nuevo α hay que calcular un nuevo punto con el operador proximal.

Ahora, usando (34), la convexidad de f y h y (33), tenemos que para todo $x, z \in \mathbb{R}^n$ se cumple

$$\begin{aligned} g(x - \alpha G_\alpha(x)) &\leq f(x) - \alpha \langle \nabla f(x), G_\alpha(x) \rangle + \frac{\alpha}{2} \|G_\alpha(x)\|^2 + h(x - \alpha G_\alpha(x)) \\ &\leq f(z) - \langle \nabla f(x), z - x \rangle - \alpha \langle \nabla f(x), G_\alpha(x) \rangle + \frac{\alpha}{2} \|G_\alpha(x)\|^2 + h(x - \alpha G_\alpha(x)) \\ &\leq f(z) - \langle \nabla f(x), z - x - \alpha G_\alpha(x) \rangle + \frac{\alpha}{2} \|G_\alpha(x)\|^2 + h(z) \\ &\quad - \langle G_\alpha(x) - \nabla f(x), z - x + \alpha G_\alpha(x) \rangle \\ &= g(z) - \langle G_\alpha(x), z - x \rangle - \frac{\alpha}{2} \|G_\alpha(x)\|^2. \end{aligned}$$

Si tomamos $x = z = x_k$, entonces

$$g(x_{k+1}) \leq g(x_k) - \frac{\alpha_k}{2} \|G_{\alpha_k}(x_k)\|,$$

luego el método es un método de descenso (compare con (4)), y si tomamos $x = x_k$ y $z = x^*$, entonces

$$\begin{aligned} g(x_{k+1}) - g^* &\leq \langle G_{\alpha}(x_k), x_k - x^* \rangle - \frac{\alpha_k}{2} \|G_{\alpha_k}(x_k)\|^2 \\ &= \frac{1}{2\alpha_k} (\|x_k - x^*\|^2 - \|x_k - x^* - \alpha_k G_{\alpha_k}(x_k)\|^2) \\ &= \frac{1}{2\alpha_k} (\|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2). \end{aligned}$$

Sumando estas desigualdades tomando el tamaño de paso constante $\frac{1}{L}$, y usando que g va decreciendo en las iteraciones, obtenemos que

$$\begin{aligned} g(x_k) - g^* &\leq \frac{1}{k} \sum_{i=1}^k (g(x_i) - g^*) \\ &\leq \frac{L}{2k} \sum_{i=1}^k (\|x_{i-1} - x^*\|^2 - \|x_i - x^*\|^2) \\ &\leq \frac{L}{2k} \|x_0 - x^*\|^2, \end{aligned}$$

que es la misma velocidad de convergencia del método del descenso del gradiente. También se puede definir el método proximal acelerado el cual tiene una tasa igual que la del método del gradiente acelerado.

8. Programación lineal

Tal vez la clase de problemas de optimización convexa más estudiada y usada en la práctica es la programación lineal, es decir, minimizar/maximizar una función lineal sobre un poliedro. Así que entender la geometría de los poliedros es fundamental para analizar los algoritmos usados para resolver estos problemas

8.1. Conos y poliedros

Definición. Sean $\{a_i, i = 1, \dots, k\}$ vectores en $\mathbb{R}^n$.

- Un cono $K \subset \mathbb{R}^n$ es un cono poliedral si tiene la forma

$$K = \bigcap_{i=1}^k \{x : \langle a_i, x \rangle \geq 0\}.$$

- Un cono $K \subset \mathbb{R}^n$ es finitamente generado si tiene la forma

$$K = \left\{ \sum_{i=1}^k t_i a_i : t_i \geq 0 \right\} = \text{cone}(\{a_i, i = 1, \dots, k\}) \cup \{0\}.$$

Es claro que un cono poliedral es cerrado pues es intersección de semiespacios cerrados. Veamos que pasa lo mismo con los conos finitamente generados.

Lema. Un cono K finitamente generado es cerrado.

Prueba. Por el teorema de Carathéodry para conos sabemos que cada elemento de K se puede escribir como combinación positiva de vectores linealmente independientes en $\{a_1, \dots, a_k\}$, como hay una cantidad finita de estos subconjuntos de vectores linealmente independientes, tenemos que K la unión finita de conos finitamente generados por vectores linealmente independientes. Así que es suficiente mostrar que cada uno de estos conos es cerrado. Sea $S = \{a_1, \dots, a_k\}$ vectores linealmente independientes, luego el cono generado por S está dado por $\{Ay : y \in \mathbb{R}_+^k\}$, con A la matriz con columnas dadas por los elementos de S , vamos a ver que este conjunto es cerrado. Sea $\{x_k\}$ sucesión que converge a x , queremos ver que existe $y \in \mathbb{R}_+^k$ tal que $x = Ay$. Sean $\{y_k\} \subset \mathbb{R}_+^k$ tales que $x_k = Ay_k$, entonces

$$y_k = (A^T A)^{-1} A^T x_k,$$

y tomando el límite cuando $k \rightarrow \infty$ tenemos que $y_k \rightarrow y = (A^T A)^{-1} A^T x \in \mathbb{R}_+^k$, y por lo tanto $x = Ay$ como queríamos. $\square$

Veamos ahora la relación entre conos poliedrales y conos finitamente generados.

Teorema. Sea $K = \text{cone}(\{a_i, i = 1, \dots, k\}) \cup \{0\}$ y $L = \bigcap_{i=1}^k \{x : \langle a_i, x \rangle \geq 0\}$, entonces $K^* = L$ y $L^* = K$.

Prueba. Veamos la primera igualdad. Sea $x \in L$, entonces $\left\langle \sum_{i=1}^k t_i a_i, x \right\rangle \geq 0$ para todo $t_i \geq 0$, luego $x \in K^*$. Si $x \in K^*$, entonces tomando $t_i = 1$ y los demás 0 se tiene que $\langle a_i, x \rangle \geq 0$, luego $x \in L$. Ahora, tomando duales tenemos que $K = (K^*)^* = L^*$, pues K es un cono convexo y cerrado. $\square$

Otra forma de escribir el resultado anterior es dada A matriz de $n \times k$, los conos $K = \{Ay : y \geq 0\}$ y $L = \{x : x^T A \geq 0\}$, donde la desigualdad es componente por componente, son duales uno del otro. El siguiente resultado, conocido como Lema de Farkas es otra forma de enunciar el resultado anterior.

Teorema (Lema de Farkas). Sea A una matriz de $n \times k$ y $b \in \mathbb{R}^n$. Entonces exactamente una de las siguientes dos alternativas se satisface:

1. Existe $y \geq 0$ tal que $Ay = b$, es decir, $b \in K$.
2. Existe x tal que $x^T A \geq 0$ y $\langle x, b \rangle < 0$, es decir, $b \notin L^*$.

El siguiente es el resultado más importante sobre los conos que estamos estudiando.

Teorema. Todo cono K finitamente generado es poliedral y viceversa

Prueba. Sea $K \subset \mathbb{R}^n$ un cono finitamente generado, vamos a probar que es poliedral por inducción en la cantidad de vectores que lo generan. Si $k = 1$ entonces $K = \{ta : t \geq 0\}$ y consideremos dos casos. Si $a = 0$ entonces $K = \{0\}$ el cual es un cono poliedral dado por los vectores $\{\pm e_i\}_{i=1}^n$ donde los vectores e_i son los canónicos en $\mathbb{R}^n$. Si $a \neq 0$ entonces K es

media recta y en este caso podemos escoger una base de R^n $\{u_i\}_{i=1}^n$ tal que $u_1 = a$ y $\{u_i\}_{i=2}^n$ son ortogonales a a , de tal forma que

$$K = \{x : \langle x, u_1 \rangle \geq 0, \langle x, \pm u_i \rangle \geq 0, i = 2, \dots, n\}.$$

Supongamos ahora que el resultado es cierto para $k - 1$. Sean K el cono generado por $\{a, a_1, \dots, a_{k-1}\}$ y K_1 el cono generado por $\{a_1, \dots, a_{k-1}\}$, así que dado $x \in K$ existen $y \in K_1$ y $t \geq 0$ tal que $x = y + ta$. Esto implica que

$$K = \{x : \exists t \geq 0, x - ta \in K_1\}.$$

Sabemos también que

$$K_1 = \{x : \langle x, b_j \rangle \geq 0, j = 1, \dots, m\}.$$

Así que

$$\begin{aligned} K &= \{x : \exists t \geq 0, \langle x - ta, b_j \rangle \geq 0, j = 1, \dots, m\} \\ &= \{x : \exists t \geq 0, \langle x, b_j \rangle \geq t \langle a, b_j \rangle, j = 1, \dots, m\} \\ &= \left\{ x : \exists t \geq 0, \frac{\langle x, b_i \rangle}{\langle a, b_i \rangle} \geq t \geq \frac{\langle x, b_j \rangle}{\langle a, b_j \rangle}, \langle x, b_l \rangle \geq 0, i \in I^+, j \in I^-, l \in I^0 \right\}, \end{aligned}$$

donde $I^+ = \{i : \langle a, b_i \rangle > 0\}$, $I^- = \{j : \langle a, b_j \rangle < 0\}$ y $I^0 = \{l : \langle a, b_l \rangle = 0\}$. Ahora, existe $t \geq 0$ que satisfaga lo de arriba si $\frac{\langle x, b_i \rangle}{\langle a, b_i \rangle} \geq \frac{\langle x, b_j \rangle}{\langle a, b_j \rangle}$ para todo $i \in I^+, j \in I^-$ y además si $\min_{i \in I^+} \frac{\langle x, b_i \rangle}{\langle a, b_i \rangle} \geq 0$, es decir, si $\langle x, b_i \rangle \geq 0$ para todo $i \in I^+$. Finalmente tenemos que

$$K = \left\{ x : \frac{\langle x, b_i \rangle}{\langle a, b_i \rangle} \geq \frac{\langle x, b_j \rangle}{\langle a, b_j \rangle}, \langle x, b_l \rangle \geq 0, i \in I^+, j \in I^-, l \in I^+ \cup I^0 \right\},$$

luego K es un cono poliedral. Para el converso, si K es un cono poliedral, entonces K^* es finitamente generado y por lo anterior se tiene que K^* es también poliedral, luego $(K^*)^* = K$ es finitamente generado. $\square$

Con este resultado podemos ahora probar el teorema fundamental de polidros convexos conocido como el teorema de Minkowski-Weyl.

Teorema. Un conjunto $P \subset \mathbb{R}^n$ es un poliedro si y solo si existen vectores $\{v_i\}_{i=1}^m$ y $\{r_j\}_{j=1}^k$ tales que

$$\begin{aligned} P &= \text{conv}(\{v_i\}_{i=1}^m) + (\text{cone}(\{r_j\}_{j=1}^k) \cup \{0\}) \\ &= \left\{ \sum_{i=1}^m \lambda_i v_i + \sum_{j=1}^k \mu_j r_j : \sum_{i=1}^m \lambda_i = 1, \lambda_i \geq 0, \mu_j \geq 0 \right\}. \end{aligned}$$

Prueba. Sea P un poliedro, es decir, se puede escribir como

$$P = \{x : \langle x, a_i \rangle \geq b_i, i = 1, \dots, l\}.$$

Definimos el cono poliedral

$$K = \{(x, t) \in \mathbb{R}^n \times \mathbb{R} : \langle x, a_i \rangle - tb_i \geq 0, t \geq 0, i = 1, \dots, l\},$$

luego K es un cono finitamente generado por vectores de la forma $\{(v_i, 1)\}_{i=1}^m$ y $\{(r_j, 0)\}_{j=1}^k$. Puesto que $P = \{x : (x, 1) \in K\}$, entonces P se puede escribir como en el enunciado del teorema. Ahora, si P tiene la forma como en el enunciado entonces definimos K como el cono finitamente generado por los vectores $\{(v_i, 1)\}_{i=1}^m$ y $\{(r_j, 0)\}_{j=1}^k$. Puesto que K es un cono poliedral con la forma como la de arriba, con un argumento similar al anterior se tiene que P es un poliedro. $\square$

8.2. Dualidad

Veamos ahora cómo usamos estos resultados en problemas de optimización lineal. Consideremos el problema

$$\begin{array}{ll} \text{mín} & \langle c, x \rangle \\ \text{sujeto a} & Ax \geq b, \end{array} \quad (\text{P-LP})$$

es decir, minimizar una función lineal sobre el poliedro $P = \{x : \langle x, a_i \rangle \geq b_i, i = 1, \dots, l\}$. Sabemos entonces que P lo podemos escribir como $P = \text{conv}(\{v_i\}_{i=1}^m) + (\text{cone}(\{r_j\}_{j=1}^k) \cup \{0\})$ y por lo tanto podemos reescribir el problema de optimización lineal como

$$\text{mín} \left\{ \sum_{i=1}^m \lambda_i \langle c, v_i \rangle + \sum_{j=1}^k \mu_j \langle c, r_j \rangle : \sum_{i=1}^m \lambda_i = 1, \lambda_i \geq 0, \mu_j \geq 0 \right\}.$$

Supongamos que el problema es acotado, es decir, que existe M tal que $\langle c, x \rangle \geq M$ para todo $x \in P$. Entonces para todo v_i, r_j y $t \geq 0$ se tiene que $\langle c, v_i \rangle + t \langle c, r_j \rangle \geq M$, lo cual implica que $\langle c, r_j \rangle \geq 0$ para todo j . Ahora, si se tiene que $\langle c, r_j \rangle \geq 0$ para todo j , entonces el problema de optimización resulta en

$$\text{mín} \left\{ \sum_{i=1}^m \lambda_i \langle c, v_i \rangle : \sum_{i=1}^m \lambda_i = 1, \lambda_i \geq 0 \right\} = \min_{1 \leq i \leq m} \langle c, v_i \rangle,$$

luego el problema es acotado y el óptimo se alcanza en el conjunto $\{v_i\}_{i=1}^m$. Ahora, en la práctica los problemas de optimización lineal se escribe P a partir de desigualdades y encontrar los vectores v 's y r 's no es una tarea fácil.

A cada problema lineal de la forma de (P-LP) se le puede asociar otro problema lineal al que llamaremos problema dual. Veamos cómo encontrarlo: Lo primero es reescribir (P-LP) de la siguiente forma:

$$\text{mín}_x \max_{y \geq 0} \langle c, x \rangle + \langle y, b - Ax \rangle.$$

En efecto, si $x \notin P$, entonces existe una coordenada i tal que $b_i - \langle x, a_i \rangle > 0$, luego escogiendo $y \geq 0$ con y_i muy grande tenemos que $\langle y, b - Ax \rangle$ puede ser tan grande como queramos,

luego $\max_{y \geq 0} \langle c, x \rangle + \langle y, b - Ax \rangle$ es $+\infty$ si $x \notin P$ y es $\langle c, x \rangle$ de lo contrario. Definimos ahora la siguiente función conocida como Lagrangeano:

$$\mathcal{L}(x, y) = \langle c, x \rangle + \langle y, b - Ax \rangle.$$

Es claro que para todo $x, y \geq 0$ se tiene que $\max_{y \geq 0} \mathcal{L}(x, y) \geq \mathcal{L}(x, y)$, luego $\min_x \max_{y \geq 0} \mathcal{L}(x, y) \geq \min_x \mathcal{L}(x, y)$ para todo $y \geq 0$ y finalmente tenemos la siguiente desigualdad conocida como dualidad débil:

$$\min_x \max_{y \geq 0} \mathcal{L}(x, y) \geq \max_{y \geq 0} \min_x \mathcal{L}(x, y).$$

El problema dual lo definimos entonces como $\max_{y \geq 0} \min_x \mathcal{L}(x, y)$ y veamos que también es un problema lineal. Notemos que $\mathcal{L}(x, y) = \langle y, b \rangle + \langle c - A^T y, x \rangle$ y al minimizar sobre x debemos tener que $c - A^T y = 0$ de lo contrario se obtiene $-\infty$. Así que obtenemos el problema lineal

$$\begin{array}{ll} \text{máx} & \langle y, b \rangle \\ \text{sujeto a} & A^T y = c, \\ & y \geq 0. \end{array} \quad (\text{D-LP})$$

El conjunto factible del problema dual $Q = \{y : A^T y = c, y \geq 0\}$ es también un poliedro y se puede llevar fácilmente a su forma estándar. Tenemos entonces que la dualidad débil se puede escribir como: Dados $x \in P$, factible para (P-LP), y $y \in Q$, factible para (D-LP), entonces $\langle c, x \rangle \geq \langle y, b \rangle$. Vamos ahora a mostrar que existen soluciones factibles que alcanzan la igualdad y por lo tanto son óptimas.

Teorema (Dualidad fuerte). Sea $x^* \in P$ solución óptima de (P-LP). Entonces existe $y^* \in Q$ tal que $\langle c, x^* \rangle = \langle y^*, b \rangle$ y por lo tanto solución óptima de (D-LP).

Prueba. Sea $I = \{i : \langle a_i, x^* \rangle = b_i\}$ y supongamos que para z se tiene que $\langle a_i, z \rangle \geq 0$ para todo $i \in I$. Sea $\epsilon > 0$ y consideremos el vector $x^* + \epsilon z$. Entonces $\langle a_i, x^* + \epsilon z \rangle \geq \langle a_i, x^* \rangle = b_i$ para todo $i \in I$, y para $i \notin I$, puesto que $\langle a_i, x^* \rangle > b_i$ se puede escoger ϵ suficientemente pequeño tal que $x^* + \epsilon z \in P$. Puesto que x^* es óptimo, esto implica que $\langle c, z \rangle \geq 0$. Ahora, el Lema de Farkas implica que existen escalares $y_i^* \geq 0$ para $i \in I$ tales que $\sum_{i \in I} y_i^* a_i = c$, y definiendo $y_i^* = 0$ para $i \notin I$ tenemos que existe $y^* \geq 0$ tal que $A^T y^* = c$, luego $y^* \in Q$. Además

$$\langle y^*, b \rangle = \sum_{i \in I} y_i^* b_i = \sum_{i \in I} y_i^* \langle a_i, x^* \rangle = \left\langle \sum_{i \in I} y_i^* a_i, x^* \right\rangle = \langle c, x^* \rangle.$$

□

Dada (x, y) , pareja de soluciones factible de los problemas lineales, llamamos brecha de dualidad a

$$0 \leq \langle c, x \rangle - \langle y, b \rangle = \langle A^T y, x \rangle - \langle y, b \rangle = \langle y, Ax - b \rangle.$$

Por el resultado anterior tenemos que la pareja es óptima si y solo si la brecha de dualidad es 0, y puesto que $y \geq 0$ y $Ax - b \geq 0$, este se tiene si y solo si $y_i(\langle a_i, x \rangle - b_i) = 0$ para todo i , es decir, si y solo si, $y_i = 0$ o $\langle a_i, x \rangle = b_i$ para todo i . A esta condición la llamamos holgura complementaria.

9. Problemas convexos generales

Vamos a considerar problemas de optimización de la siguiente forma

$$\begin{aligned} \text{mín} \quad & f(x) \\ \text{sujeto a} \quad & g_i(x) \leq 0, \quad i = 1, \dots, r \\ & h_j(x) = 0, \quad j = 1, \dots, m \\ & x \in C \subset \mathbb{R}^n. \end{aligned} \tag{P}$$

Decimos que $x \in \mathbb{R}^n$ es factible para (P) si $x \in C$ y además satisface las restricciones del problema. Igual que en el caso de optimización lineal, a cada problema (P), llamado primal, se le asocia una función, llamada Lagrangiano, que se define como:

$$\mathcal{L}(x, y, z) = f(x) + \sum_{i=1}^r y_i g_i(x) + \sum_{j=1}^m z_j h_j(x), \tag{L}$$

con dominio $C \times \mathbb{R}_+^r \times \mathbb{R}^m$. Notemos que para $x \in C$

$$\sup_{y_i \geq 0} y_i g_i(x) = \begin{cases} 0 & \text{si } g_i(x) \leq 0 \\ +\infty & \text{de lo contrario} \end{cases}$$

y

$$\sup_{z_j \in \mathbb{R}} z_j h_j(x) = \begin{cases} 0 & \text{si } h_j(x) = 0 \\ +\infty & \text{de lo contrario.} \end{cases}$$

Por lo tanto, para cada $x \in C$, se tiene que

$$\sup_{y \geq 0, z} \mathcal{L}(x, y, z) = \begin{cases} f(x) & \text{si } x \text{ es factible para (P)} \\ +\infty & \text{de lo contrario,} \end{cases}$$

luego el problema (P) se puede reescribir como

$$\inf_{x \in C} \sup_{y \geq 0, z} \mathcal{L}(x, y, z). \tag{P}$$

Ahora, definimos el problema dual asociado al problema (P) como:

$$\sup_{y \geq 0, z} \inf_{x \in C} \mathcal{L}(x, y, z). \tag{D}$$

Notemos ahora que la función

$$q(y, z) := \inf_{x \in C} \mathcal{L}(x, y, z)$$

es el ínfimo de funciones lineales en λ y μ , y por lo tanto es una función cóncava, luego el problema dual consiste en maximizar una función cóncava con restricciones lineales y lo podemos escribir como

$$\begin{aligned} \text{máx} \quad & q(y, z) \\ \text{sujeto a} \quad & y \geq 0 \end{aligned} \tag{D}$$

Decimos que un problema de optimización es convexo si consiste en minimizar una función convexa sobre un conjunto convexo. Así que el problema (P) es convexo si las funciones f y g_i , $i = 1, \dots, r$ son convexas, las funciones h_j , $j = 1, \dots, m$ son afines y C es un conjunto convexo.

Nota. Todo problema dual es convexo sin importar si el primal lo es.

9.1. Ejemplos

Ya vimos el primer ejemplo con el problema de optimización lineal. Veamos otros ejemplos.

9.1.1. Programación cuadrática

Sean $0 \prec Q \in S^n$, una matriz simétrica de $n \times n$ definida positiva, A una matriz de $m \times n$, $c \in \mathbb{R}^n$ y $b \in \mathbb{R}^m$. Un programa cuadrático convexo tiene la forma

$$\begin{aligned} \text{mín} \quad & \frac{1}{2} \langle Qx, x \rangle + \langle c, x \rangle \\ \text{sujeto a} \quad & Ax = b \\ & x \geq 0. \end{aligned} \tag{P-QP}$$

Definimos entonces la función Lagrangiana, con dominio $\mathbb{R}^n \times \mathbb{R}_+^n \times \mathbb{R}^m$, está dada por

$$\begin{aligned} \mathcal{L}(x, y, z) &= \frac{1}{2} \langle Qx, x \rangle + \langle c, x \rangle - \langle y, x \rangle + \langle z, b - Ax \rangle \\ &= \langle b, \mu \rangle + \frac{1}{2} \langle Qx, x \rangle - \langle A^T z + y - c, x \rangle, \end{aligned}$$

y por lo tanto

$$\begin{aligned} q(y, z) &= \langle b, z \rangle + \min_x \left\{ \frac{1}{2} \langle Qx, x \rangle - \langle A^T z + y - c, x \rangle \right\} \\ &=: \langle b, z \rangle + \min_x h(x) \end{aligned}$$

Notemos que h es una función cuadrática y estrictamente convexa con

$$\nabla h(x) = Qx - (A^T z + y - c),$$

luego $Q^{-1}(A^T z + y - c)$ es el único minimizador de h . Así que

$$\begin{aligned} q(y, z) &= \langle b, z \rangle + \frac{1}{2} \langle A^T z + y - c, Q^{-1}(A^T z + y - c) \rangle - \langle A^T z + y - c, Q^{-1}(A^T z + y - c) \rangle \\ &= \langle b, z \rangle - \frac{1}{2} \langle A^T z + y - c, Q^{-1}(A^T z + y - c) \rangle. \end{aligned}$$

Finalmente, tenemos que el problema dual está dado por

$$\begin{aligned} \text{máx} \quad & \langle b, z \rangle - \frac{1}{2} \langle A^T z + y - c, Q^{-1}(A^T z + y - c) \rangle \\ \text{sujeto a} \quad & y \geq 0. \end{aligned} \tag{D-QP}$$

9.1.2. Programación cónica

Programación cónica es una generalización de la programación lineal. Sea V un espacio vectorial de dimensión finita con producto interno $\langle \cdot, \cdot \rangle_V$. Sea $K \subset V$ un cono convexo cerrado con interior no vacío que no contiene líneas. Consideremos ahora una transformación lineal $\mathcal{A} : V \rightarrow W$, donde W es un espacio vectorial con producto interno $\langle \cdot, \cdot \rangle_W$, $c \in V$ y $b \in W$. Un problema cónico es, entonces, minimizar (o maximizar) un funcional lineal sobre un conjunto convexo que se obtiene de intersectar un cono con un espacio afín, es decir, tiene la forma

$$\begin{array}{ll} \text{mín} & \langle c, x \rangle_V \\ \text{sujeto a} & \mathcal{A}x = b \\ & x \in K. \end{array} \quad (\text{P-CP})$$

Notamos por $\mathcal{A}^* : W \rightarrow V$ la transformación adjunta de $\mathcal{A}$ y recordemos el cono dual definido como

$$K^* = \{y \in V : \langle x, y \rangle_V \geq 0 \text{ para todo } x \in K\}.$$

Sabemos que K^* es también un cono convexo cerrado, además como K no contiene líneas y tiene interior no vacío, K^* tampoco (trate de convencerse de eso). Encontremos ahora el problema dual asociado. Definimos la función Lagrangiana con dominio $K \times W$ como:

$$\mathcal{L}(x, y) = \langle c, x \rangle_V + \langle b - \mathcal{A}x, y \rangle_W = \langle b, y \rangle_W + \langle c - \mathcal{A}^*y, x \rangle_V.$$

Igual que antes, tenemos que (P-CP) se puede escribir como

$$\inf_{x \in K} \sup_{y \in W} \mathcal{L}(x, y).$$

El problema dual es entonces

$$\begin{aligned} \sup_{y \in W} \inf_{x \in K} \mathcal{L}(x, y) &= \sup_{y \in W} \left\{ \langle b, y \rangle_W + \inf_{x \in K} \langle c - \mathcal{A}^*y, x \rangle_V \right\} \\ &= \sup_{y \in W} \{ \langle b, y \rangle_W : c - \mathcal{A}^*y \in K^* \}. \end{aligned}$$

Para ver la última igualdad, note que si $c - \mathcal{A}^*y \notin K^*$, entonces existe $x \in K$ tal que $\langle c - \mathcal{A}^*y, x \rangle_V < 0$, y tomando múltiplos arbitrariamente grandes de x tenemos que $\inf_{x \in K} \langle c - \mathcal{A}^*y, x \rangle_V = -\infty$. De lo contrario el ínfimo es 0. Así que podemos escribir el problema dual como

$$\begin{array}{ll} \text{máx} & \langle b, y \rangle_W \\ \text{sujeto a} & \mathcal{A}^*y + s = c \\ & s \in K^*. \end{array} \quad (\text{D-CP})$$

Algunos ejemplos importante de programación cónica son los siguientes:

- Si $V = \mathbb{R}^n$, $K = \mathbb{R}_+^n$, $W = \mathbb{R}^m$, entonces $K^* = K$ y obtenemos un programa lineal.

- Programación semidefinida: Sea $V = S^n$, el espacio vectorial de las matrices simétricas de $n \times n$. y $K = S_+^n$ el conjunto de matrices semidefinidas positivas. Tomemos $W = \mathbb{R}^m$ y la transformación $\mathcal{A}$ tal que para $X \in V$

$$(\mathcal{A}X)_i := \langle X, A_i \rangle = \text{tr}(XA_i), \quad i = 1, \dots, m,$$

donde $A_i \in S^n$. Calculemos la transformación adjunta $\mathcal{A}^* : \mathbb{R}^m \rightarrow S^n$. Si $y \in \mathbb{R}^m$, entonces

$$\langle \mathcal{A}X, y \rangle = \sum_{i=1}^m y_i \langle X, A_i \rangle = \left\langle X, \sum_{i=1}^m y_i A_i \right\rangle =: \langle X, \mathcal{A}^*y \rangle,$$

luego $\mathcal{A}^*y = \sum_{i=1}^m y_i A_i \in S^n$. Finalmente, como $K^* = K$, tenemos que el par primal-dual en programación semidefinida es de la forma

$$\begin{array}{llll} \text{mín} & \langle C, X \rangle & \text{máx} & \langle b, y \rangle \\ \text{sujeto a} & \mathcal{A}X = b & \text{sujeto a} & \sum_{i=1}^m y_i A_i + S = C \\ & X \succeq 0 & & S \succeq 0 \end{array} \quad \begin{array}{l} \text{(P-SDP)} \\ \text{(D-SDP)} \end{array}$$

Ejemplo. Ejemplo del problema del MAX-CUT

9.1.3. Programación seminfinita - Problema de momentos

Este es un ejemplo distinto a los anteriores pues en este caso el conjunto convexo sobre el que vamos a optimizar está en un espacio vectorial de dimensión infinita. Sea $M \subset \mathbb{R}^n$ compacto $\mathcal{M}(M)_+$, el conjunto de medidas no-negativas soportadas en M . Sean f_i , $i = 0, 1, \dots, m$ en $C(M)$, el conjunto de funciones continuas sobre M , y $b \in \mathbb{R}^m$. Definimos el problema de momentos como

$$\begin{array}{ll} \text{mín} & \int_M f_0(x) d\varphi(x) \\ \text{sujeto a} & \int_M f_i(x) d\varphi(x) \leq b_i, \quad i = 1, \dots, m \\ & \varphi \in \mathcal{M}(M)_+. \end{array} \quad \text{(PM)}$$

Nota. Si imponemos la restricción $\int_M d\varphi(x) = 1$, podemos optimizar sobre el conjunto de medidas de probabilidad soportadas en M .

Definimos el Lagrangiano, con dominio $\mathcal{M}(M)_+ \times \mathbb{R}_+^m$, está dada por

$$\begin{aligned} \mathcal{L}(\varphi, y) &= \int_M f_0(x) d\varphi(x) + \sum_{i=1}^m y_i \left(\int_M f_i(x) d\varphi(x) - b_i \right) \\ &= \langle b, y \rangle + \int_M \left(f_0(x) + \sum_{i=1}^m y_i f_i(x) \right) d\varphi(x), \end{aligned}$$

así que

$$q(y) = \langle b, y \rangle + \inf_{\varphi \in \mathcal{M}(M)_+} \int_M \left(f_0(x) + \sum_{i=1}^m y_i f_i(x) \right) d\varphi(x)$$

$$= \begin{cases} \langle b, y \rangle & \text{si } f_0(x) + \sum_{i=1}^m y_i f_i(x) \geq 0 \text{ para todo } x \in M \\ -\infty & \text{de lo contrario.} \end{cases}$$

Si usamos la notación $\langle f, \varphi \rangle := \int_M f d\varphi$, entonces el par primal-dual tiene la forma

$$\begin{array}{llll} \text{mín} & \langle f_0, \varphi \rangle & \text{máx} & \langle b, y \rangle \\ \text{sujeto a} & \langle f_i, \varphi \rangle \leq b_i, i = 1, \dots, m & \text{(PM)} & \text{sujeto a} \quad f_0 + \sum_{i=1}^m y_i f_i \geq 0 \quad \text{(PS)} \\ & \varphi \in \mathcal{M}(M)_+ & & y \geq 0. \end{array}$$

El problema (PS) se llama programa seminfinito pues tiene infinitas restricciones, una por cada $x \in M$, y se optimiza sobre un espacio de dimensión finita.

9.2. Puntos de silla y condiciones KKT

Vamos ahora a ver algunas propiedades de la función Lagrangiana ($\mathcal{L}$) y concluir las llamadas condiciones Karush-Kuhn-Tucker que deben satisfacer los óptimos de (P). Por ahora consideremos una función $\mathcal{L} : A \times B \rightarrow \mathbb{R}$ arbitraria, donde A, B son conjuntos arbitrarios. A esta función le podemos asociar un par de problemas primal-dual:

$$\inf_{x \in A} \sup_{y \in B} \mathcal{L}(x, y) \quad \text{(P-}\mathcal{L}\text{)}$$

$$\sup_{y \in B} \inf_{x \in A} \mathcal{L}(x, y) \quad \text{(D-}\mathcal{L}\text{)}$$

En adelante vamos a notar como $\text{val}(\cdot)$ al valor óptimo del problema $(\cdot)$.

Teorema (Dualidad débil).

$$\text{val}(\text{D-}\mathcal{L}) \leq \text{val}(\text{P-}\mathcal{L}).$$

Prueba. Es claro que para todo $z \in A$ y $y \in B$ se tiene que

$$\inf_{x \in A} \mathcal{L}(x, y) \leq \mathcal{L}(z, y),$$

luego, para todo $z \in A$ se tiene que

$$\text{val}(\text{D-}\mathcal{L}) = \sup_{y \in B} \inf_{x \in A} \mathcal{L}(x, y) \leq \sup_{y \in B} \mathcal{L}(z, y),$$

y tomando $\inf$ sobre $z \in A$

$$\text{val}(\text{D-}\mathcal{L}) = \sup_{y \in B} \inf_{x \in A} \mathcal{L}(x, y) \leq \inf_{z \in A} \sup_{y \in B} \mathcal{L}(z, y) = \text{val}(\text{P-}\mathcal{L}).$$

□

Corolario. Si el problema (P- $\mathcal{L}$) es no acotado, entonces para todo $y \in B$ se tiene que $\inf_{x \in A} \mathcal{L}(x, y) = -\infty$. Similarmente, si el problema (D- $\mathcal{L}$) es no acotado, entonces para todo $x \in A$ se tiene que $\sup_{y \in B} \mathcal{L}(x, y) = \infty$.

Prueba. Notemos que (P- $\mathcal{L}$) es no acotado si y solo si $\text{val}(\text{P-}\mathcal{L}) = -\infty$, luego $\text{val}(\text{D-}\mathcal{L}) = -\infty$ y se tiene el primer resultado. El segundo es similar. $\square$

Definición. Un punto $(x^*, y^*) \in A \times B$ es un punto de silla de $\mathcal{L}$ si para todo $(x, y) \in A \times B$ se tiene que

$$\mathcal{L}(x^*, y) \leq \mathcal{L}(x^*, y^*) \leq \mathcal{L}(x, y^*).$$

Teorema (Teorema del punto de silla). Los siguientes son equivalentes:

1. $(x^*, y^*) \in A \times B$ es un punto de silla de $\mathcal{L}$.
2. x^* es un punto óptimo de (P- $\mathcal{L}$), y^* es un punto óptimo de (D- $\mathcal{L}$), y $\text{val}(\text{P-}\mathcal{L}) = \text{val}(\text{D-}\mathcal{L})$.

Además, si ambos enunciados son ciertos, entonces $\text{val}(\text{P-}\mathcal{L}) = \text{val}(\text{D-}\mathcal{L}) = \mathcal{L}(x^*, y^*)$.

Prueba. Suponga que 1. es cierto. Entonces

$$\sup_{y \in B} \mathcal{L}(x^*, y) = \max_{y \in B} \mathcal{L}(x^*, y) = \mathcal{L}(x^*, y^*) = \min_{x \in A} \mathcal{L}(x, y^*) = \inf_{x \in A} \mathcal{L}(x, y^*).$$

Entonces,

$$\begin{aligned} \text{val}(\text{P-}\mathcal{L}) &\leq \sup_{y \in B} \mathcal{L}(x^*, y) = \mathcal{L}(x^*, y^*) \\ &= \inf_{x \in A} \mathcal{L}(x, y^*) \leq \text{val}(\text{D-}\mathcal{L}) \\ &\leq \text{val}(\text{P-}\mathcal{L}), \end{aligned}$$

donde la última desigualdad se sigue de dualidad débil, y tenemos que se cumple 2. Supongamos ahora que 2. vale, entonces

$$\mathcal{L}(x^*, y^*) \leq \sup_{y \in B} \mathcal{L}(x^*, y) = \text{val}(\text{P-}\mathcal{L}) = \text{val}(\text{D-}\mathcal{L}) = \inf_{x \in A} \mathcal{L}(x, y^*) \leq \mathcal{L}(x^*, y^*),$$

y esto implica que (x^*, y^*) es un punto de silla, y además que $\text{val}(\text{P-}\mathcal{L}) = \text{val}(\text{D-}\mathcal{L}) = \mathcal{L}(x^*, y^*)$. $\square$

Nota. Se sigue del teorema anterior que el conjunto de puntos de silla tiene la forma $A_0 \times B_0$, donde $A_0 \subset A$ y $B_0 \subset B$.

Consideremos de ahora en adelante $\mathcal{L}$ definida en $(\mathcal{L})$ con $A = C$ y $B = \mathbb{R}_+^r \times \mathbb{R}^m$. Veamos qué dice el teorema del punto de silla en este caso: El punto (x^*, y^*, z^*) es un punto de silla si y solo si satisface

1. x^* es óptimo para (P),
2. (y^*, z^*) es óptimo para (D),

$$3. \text{ val(P)} = \text{val(D)},$$

y además, si (x^*, y^*, z^*) es un punto de silla, se tiene que

$$\text{val(P)} = \text{val(D)} = \mathcal{L}(x^*, y^*, z^*),$$

lo que implica que

$$f(x^*) = \mathcal{L}(x^*, y^*, z^*) = f(x^*) + \sum_{i=1}^r y_i^* g_i(x^*) + \sum_{j=1}^m z_j^* h_j(x^*) = f(x^*) + \sum_{i=1}^r y_i^* g_i(x^*),$$

pues x^* es factible para (P) y por lo tanto $h_j(x^*) = 0, j = 1, \dots, m$. Así que si (x^*, y^*, z^*) es un punto de silla, o equivalentemente, si (x^*, y^*, z^*) son óptimos para (P) y (D) y además se tiene dualidad fuerte, es decir, $\text{val(P)} = \text{val(D)}$, entonces

$$\sum_{i=1}^r y_i^* g_i(x^*) = 0,$$

y como $y_i^* \geq 0$ y $g_i(x^*) \leq 0$, se tiene que $y_i^* g_i(x^*) = 0$ para todo $i = 1, \dots, m$. A esto lo llamamos la condición de complementaridad. Adicionalmente, supongamos que las funciones f, g_i y h_j , para $i = 1, \dots, r, j = 1, \dots, m$, son Gâteaux diferenciables, y que $C = \mathbb{R}^n$. En este caso, si (x^*, y^*, z^*) es un punto de silla, entonces x^* minimiza la función $x \mapsto \mathcal{L}(x, y^*, z^*)$ sobre $\mathbb{R}^n$ y por lo tanto

$$0 = \nabla_x \mathcal{L}(x^*, y^*, z^*) = \nabla f(x^*) + \sum_{i=1}^r y_i^* \nabla g_i(x^*) + \sum_{j=1}^m z_j^* \nabla h_j(x^*).$$

Supongamos ahora que los conjuntos A y B son convexos y que la función $\mathcal{L}$ es convexa-cóncava, es decir, es convexa en x y cóncava en y . Usando la nota anterior, tenemos el siguiente resultado.

Teorema. El conjunto de puntos de silla $A_0 \times B_0$ satisface que A_0 y B_0 son convexos. Además, si son no vacíos y $\mathcal{L}$ es estrictamente convexa (cóncava), entonces $A_0(B_0)$ solo tiene un elemento.

Prueba. Sea $y^* \in B_0$. Sean $x_1, x_2 \in A_0$ y $\alpha \in (0, 1)$. Definimos $x_\alpha = \alpha x_1 + (1 - \alpha)x_2$, queremos ver que (x_α, y^*) es un punto de silla. Como (x_1, y^*) y (x_2, y^*) son puntos de silla, y por lo tanto $\mathcal{L}(x_1, y^*) = \mathcal{L}(x_2, y^*)$, y usando la convexidad de $\mathcal{L}$ tenemos, para todo $y \in B$, que

$$\begin{aligned} \mathcal{L}(x_\alpha, y) &\leq \alpha \mathcal{L}(x_1, y) + (1 - \alpha) \mathcal{L}(x_2, y) \\ &\leq \alpha \mathcal{L}(x_1, y^*) + (1 - \alpha) \mathcal{L}(x_2, y^*) = \mathcal{L}(x_1, y^*) \\ &\leq \mathcal{L}(x_\alpha, y^*). \end{aligned}$$

Para ver la otra desigualdad, de nuevo usando la convexidad de $\mathcal{L}$ y que (x_1, y^*) y (x_2, y^*) son puntos de silla, tenemos, para todo $x \in A$, que

$$\begin{aligned} \mathcal{L}(x_\alpha, y^*) &\leq \alpha \mathcal{L}(x_1, y^*) + (1 - \alpha) \mathcal{L}(x_2, y^*) \\ &\leq \alpha \mathcal{L}(x, y^*) + (1 - \alpha) \mathcal{L}(x, y^*) \\ &= \mathcal{L}(x, y^*). \end{aligned}$$

Entonces (x_α, y^*) es un punto de silla y por lo tanto A_0 es convexo. Supongamos ahora que $\mathcal{L}$ es estrictamente convexa y que $x_1 \neq x_2$. Entonces

$$\mathcal{L}\left(\frac{x_1 + x_2}{2}, y^*\right) < \frac{\mathcal{L}(x_1, y^*)}{2} + \frac{\mathcal{L}(x_2, y^*)}{2} = \mathcal{L}(x_1, y^*),$$

y esto es una contradicción pues (x_1, y^*) es un punto de silla. La prueba para B_0 es análoga. $\square$

9.3. Dualidad fuerte

Vamos ahora a presentar el resultado más importante sobre problemas de optimización convexa. Consideremos de nuevo el problema (P) dado por

$$\begin{aligned} \text{mín} \quad & f(x) \\ \text{sujeto a} \quad & g_i(x) \leq 0, \quad i = 1, \dots, r \\ & h_j(x) = 0, \quad j = 1, \dots, m \\ & x \in C \subset \mathbb{R}^n, \end{aligned} \tag{P}$$

donde las funciones f y g_i , $i = 1, \dots, r$ son convexas, las funciones h_j , $j = 1, \dots, m$ son afines y C es un conjunto convexo. Además, vamos a asumir que para $i = 1, \dots, r$, $\text{dom}(g_i) \supseteq C$, y que $\text{dom}(f) \supseteq C$. Finalmente, vamos a suponer que $f^* := \text{val}(\text{P})$ es finito. Recordemos también la función Lagrangiana asociada

$$\mathcal{L}(x, y, z) = f(x) + \sum_{i=1}^r y_i g_i(x) + \sum_{j=1}^m z_j h_j(x), \tag{L}$$

con dominio $C \times \mathbb{R}_+^r \times \mathbb{R}^m$ y el problema dual

$$\begin{aligned} \text{máx} \quad & q(y, z) \\ \text{sujeto a} \quad & y \geq 0 \\ & z \in \mathbb{R}^m, \end{aligned} \tag{D}$$

donde

$$q(y, z) := \inf_{x \in C} \mathcal{L}(x, y, z).$$

Nuestro objetivo es mostrar que, bajo la condición de Slater que veremos más adelante, existe (y^*, z^*) óptimo para (D) y además $\text{val}(\text{P}) = \text{val}(\text{D})$, es decir, se satisface dualidad fuerte.

Nota. No se está asumiendo la existencia de un óptimo para (P), solamente que f^* sea finito.

Igual que en el caso de programación lineal, la dualidad fuerte es consecuencia de un teorema de alternativas, como el Lema de Farkas, pero en este caso con sistemas de desigualdades dadas por funciones convexas. Necesitamos la siguiente definición.

Definición. Sea $C \subset \mathbb{R}^n$, el interior relativo de C está dado por

$$\text{ri}(C) = \{x \in C : \exists \epsilon > 0, B_\epsilon(x) \cap \text{aff}(C) \subset C\},$$

con $\text{aff}(C)$ la envolvente afín de C .

Consideremos ahora el siguiente teorema:

Teorema (de Transposición Convexa). Sean g_i , $i = 1, \dots, r$ funciones convexas, h_j , $j = 1, \dots, m$ afines y C un conjunto convexo tales que para $i = 1, \dots, r$, $\text{dom}(g_i) \supseteq C$. Supongamos además que existe

($\diamond$) $\bar{x} \in \text{ri}(C)$ tal que $h_j(\bar{x}) = 0$, para todo $j = 1, \dots, m$.

Entonces, exactamente uno de los siguientes sistemas se satisface:

1. $\exists x \in C: g_i(x) < 0, h_j(x) = 0, \forall i = 1, \dots, r, j = 1, \dots, m,$
2. $\exists y \geq 0, z: \sum_{i=1}^r y_i g_i(x) + \sum_{j=1}^m z_j h_j(x) \geq 0, \forall x \in C.$

La demostración de este teorema requiere varios resultados preliminares y la vamos a hacer luego, por ahora veamos cómo se usa para mostrar el resultado principal. Para esto vamos a enunciar la condición de Slater:

- $\exists \bar{x} \in \text{ri}(C)$ tal que $g_i(\bar{x}) < 0, h_j(\bar{x}) = 0, \forall i = 1, \dots, r, j = 1, \dots, m.$

Consideremos el sistema

$$\begin{aligned} f(x) - f^* &< 0, \\ g_i(x) &< 0, \quad i = 1, \dots, r \\ h_j(x) &= 0, \quad j = 1, \dots, m \\ x &\in C. \end{aligned}$$

Como f^* es el ínfimo, por el teorema anterior, el sistema anterior es inconsistente, luego existen $(y_0^*, y^*) \geq 0$ y z^* tales que para todo $x \in C$

$$y_0^*(f(x) - f^*) + \sum_{i=1}^r y_i^* g_i(x) + \sum_{j=1}^m z_j^* h_j(x) \geq 0.$$

Supongamos que $y_0^* = 0$, entonces $y^* \geq 0$ y para todo $x \in C$

$$\sum_{i=1}^r \lambda_i^* g_i(x) + \sum_{j=1}^m \mu_j^* h_j(x) \geq 0,$$

y el teorema anterior implica que el sistema

$$\begin{aligned} g_i(x) &< 0, \quad i = 1, \dots, r \\ h_j(x) &= 0, \quad j = 1, \dots, m \\ x &\in C, \end{aligned}$$

es inconsistente, pero esto contradice la condición de Slater. Así que $y_0^* > 0$ y podemos tomarlo como 1. Por lo tanto, para todo $x \in C$ se tiene que

$$f^* \leq f(x) + \sum_{i=1}^r y_i^* g_i(x) + \sum_{j=1}^m z_j^* h_j(x) = \mathcal{L}(x, y^*, z^*),$$

luego

$$f^* \leq \inf_{x \in C} \mathcal{L}(x, y^*, z^*) = q(y^*, z^*) \leq \text{val}(D) \leq \text{val}(P) = f^*,$$

y esto es lo que se quería mostrar. Si además existe x^* óptimo para (P), entonces (x^*, y^*, z^*) es un punto de silla para $\mathcal{L}$.

Un corolario importante de lo anterior es que el problema dual siempre alcanza un óptimo a diferencia del problema primal.

9.3.1. Prueba del teorema

Vamos ahora a la prueba del teorema. Primero necesitamos un lema sencillo.

Lema. Sea l una función afín no-negativa sobre un conjunto convexo $C \subset \mathbb{R}^n$. Si existe $\bar{x} \in \text{ri}(C)$ tal que $l(\bar{x}) = 0$, entonces l se anula en todo el C .

Prueba. Sea $x_0 \in C$ tal que $l(x_0) > 0$. Como $\bar{x} \in \text{ri}(C)$, existe $x_1 \in C$ tal que $\bar{x} \in (x_0, x_1)$, el segmento abierto que une x_0 con x_1 , es decir, existe $\alpha \in (0, 1)$ tal que $\bar{x} = (1 - \alpha)x_0 + \alpha x_1$. Luego

$$0 = l(\bar{x}) = (1 - \alpha)l(x_0) + \alpha l(x_1) \geq (1 - \alpha)l(x_0) > 0,$$

y tenemos una contradicción. □

Supongamos primero que los sistemas 1. y 2. son consistentes, sean $(\hat{x}, \hat{y}, \hat{z})$ factibles para ambos sistemas. Entonces se tiene la contradicción

$$0 \leq \sum_{i=1}^r \hat{y}_i g_i(\hat{x}) + \sum_{j=1}^m \hat{z}_j h_j(\hat{x}) = \sum_{i=1}^r \hat{y}_i g_i(\hat{x}) < 0,$$

pues $\hat{y} \not\geq 0$. Supongamos ahora que 1. es inconsistente, vamos a ver que 2. es consistente. Definimos los conjuntos

$$D = \{(\lambda, \mu) \in \mathbb{R}^r \times \mathbb{R}^m : \exists x \in C, g_i(x) < \lambda_i, h_j(x) = \mu_j, \quad \forall i, j\}$$

y $N = \mathbb{R}_-^r \times \{0\} \subset \mathbb{R}^r \times \mathbb{R}^m$. Como $C \subseteq \text{dom}(g_i)$ para todo $i = 1, \dots, r$, D es un conjunto convexo no vacío, al igual que N . Como 1. es inconsistente, D y N son disjuntos. Sabemos, entonces, que existe un hiperplano que separa estos dos conjuntos, pero vamos a necesitar que este hiperplano cumpla una propiedad importante:

($\star$) D no puede estar contenido en el hiperplano.

Supongamos entonces que el hiperplano $H_{y,z,\alpha}$ separa D de N y que satisface ($\star$), luego para todo $(\lambda, \mu) \in D$ y todo $(u, 0) \in N$, es decir $u \leq 0$, se tiene que

$$\langle \lambda, y \rangle + \langle \mu, z \rangle \geq \alpha \geq \langle u, y \rangle,$$

o equivalentemente, para todo $x \in C$, $0 < s \in \mathbb{R}^r$ y $u \leq 0$, se tiene que

$$\sum_{i=1}^r y_i(g_i(x) + s_i) + \sum_{j=1}^m z_j h_j(x) \geq \alpha \geq \langle u, y \rangle,$$

y además, por la propiedad $(\star)$, existe $\hat{x} \in C$ y $\hat{s} > 0$ tales que la primera desigualdad es estricta. Ahora, tomando $u = 0$ tenemos que $\alpha \geq 0$. Ahora, si $y_i < 0$ para algún i , tomando $u = -te_i$ y haciendo $t \rightarrow \infty$, se tendría una contradicción con la segunda desigualdad, luego $y \geq 0$. Finalmente, tomando $s_i \rightarrow 0$, tenemos que para todo $x \in C$ se cumple que

$$l(x) := \sum_{i=1}^r y_i g_i(x) + \sum_{j=1}^m z_j h_j(x) \geq 0.$$

Falta mostrar que $y \neq 0$. Supongamos que lo es, entonces l se convierte en una función afín no negativa sobre C , y como $\bar{x}$ satisface $(\diamond)$, $l(\bar{x}) = 0$. Además, $l(\hat{x}) > 0$ esto contradice el lema anterior, luego $\lambda \gneq 0$.

Para terminar la prueba nos resta ver la existencia de un hiperplano que satisface $(\star)$. Si $\text{aff}(D) = \mathbb{R}^r \times \mathbb{R}^m$, entonces todo hiperplano que separa D de N satisface la condición.

Nota. ¿Qué condiciones sobre el problema de optimización garantizan que $\text{aff}(D) = \mathbb{R}^r \times \mathbb{R}^m$?

Si este no es el caso, mostrar la existencia de tal hiperplano no es evidente. Considere el siguiente ejemplo en $\mathbb{R}^2$: $A = (0, 1) \times \{0\}$ y $B = \{0\} \times (-1, 1)$. Claramente son disjuntos, pero no existe ningún hiperplano que los separe que no contenga a B .

Nota. El conjunto N es un poliedro.

El teorema de separación de Rockafellar garantiza su existencia.

Teorema. Sean C y P dos conjuntos convexos donde P es un poliedro. Entonces existe un hiperplano que los separe y que no contenga C si y solo si $\text{ri}(C) \cap P = \emptyset$.

10. Minimización con restricciones

Consideremos ahora un problema de optimización de la forma

$$\begin{array}{ll} \text{mín} & f(x) \\ \text{sujeto a} & g(x) \leq 0. \end{array} \quad (35)$$

donde $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ son funciones continuas y convexas. En líneas generales los métodos que se usan para resolver este tipo de problemas se clasifican en dos grupos: Métodos primales y métodos primales-duales. En el primer grupo solo se usa la información del problema primal, es decir de (35), y se genera un esquema a partir de una sucesión de problemas de optimización sin restricciones. En el segundo grupo se usan las condiciones de KKT, usando la información del problema dual, y se genera un esquema a partir de una sucesión de sistemas (no lineales) de ecuaciones. En ambos casos se usa el método de Newton tanto para minimizar, como para resolver sistemas de ecuaciones, y por lo tanto asumimos que $f, g \in C^2(\mathbb{R}^n)$.

Nota. Usar el método de Newton permite dar cotas teóricas sobre la complejidad de los métodos y por lo tanto mostrar que son algoritmos con tiempo polinomial.

10.1. Minimización con restricciones de igualdad

Consideremos un problema de optimización de la forma

$$\begin{aligned} \text{mín} \quad & f(x) \\ \text{sujeto a} \quad & Ax = b. \end{aligned} \tag{36}$$

Vamos a asumir que la matriz $A \in M^{m \times n}$ tiene rango $m < n$. Recordemos que en el método de Newton para problemas sin restricciones reemplazamos f por una aproximación cuadrática, así si $x \in \mathbb{R}^n$ (no necesariamente factible) y queremos encontrar un nuevo punto de la forma $x^+ = x + \Delta x$, podemos reemplazar el problema (36) por el problema

$$\begin{aligned} \text{mín} \quad & f(x) + \langle \nabla f(x), \Delta x \rangle + \frac{1}{2} \langle Hf(x) \Delta x, \Delta x \rangle \\ \text{sujeto a} \quad & A(x + \Delta x) = b \iff A\Delta x = b - Ax. \end{aligned} \tag{37}$$

Ahora, las condiciones de optimalidad de este problema son

$$\nabla f(x) + Hf(x)\Delta x + A^T z^+ = 0, \quad A\Delta x = b - Ax,$$

para algún $z^+ \in \mathbb{R}^m$, y estas condiciones se pueden reescribir como

$$\begin{bmatrix} Hf(x) & A^T \\ A & 0 \end{bmatrix} \begin{bmatrix} \Delta x \\ z^+ \end{bmatrix} = - \begin{bmatrix} \nabla f(x) \\ Ax - b \end{bmatrix}. \tag{38}$$

Notemos que si $Hf(x)$ es definida positiva, por el supuesto sobre A , este sistema lineal es siempre consistente. Además, incluso si x no es factible, x^+ sí lo es. Este método pertenece a la familia de métodos primales y se puede enmarcar en el paradigma *aproximar y luego optimizar*.

Ahora, si *optimizamos y luego aproximamos*, tenemos que escribir las condiciones KKT del problema original (36), estas son

$$\nabla f(x) + A^T z = 0, \quad Ax - b = 0,$$

el cual es ahora un sistema de ecuaciones no lineal y podemos usar el método de Newton para resolver este sistema. Si definimos $G(x, z) = \begin{bmatrix} \nabla f(x) + A^T z \\ Ax - b \end{bmatrix}$, entonces el método hace la actualización de la forma $(x^+, z^+) = (x, z) + (\Delta x, \Delta z) = (x, z) - \nabla G(x, z)^{-1} G(x, z)$, es decir, en cada actualización debemos resolver el sistema

$$\nabla G(x, z) \begin{bmatrix} \Delta x \\ \Delta z \end{bmatrix} = \begin{bmatrix} Hf(x) & A^T \\ A & 0 \end{bmatrix} \begin{bmatrix} \Delta x \\ \Delta z \end{bmatrix} = - \begin{bmatrix} \nabla f(x) + A^T z \\ Ax - b \end{bmatrix},$$

que es similar a (38) (cambia el lado derecho). De nuevo, notemos que x^+ es factible siempre. Igual que en el método de Newton, hacer la actualización con el método puro podría sacarnos de la región de convergencia, así que podemos actualizar de la forma

$$(x_{k+1}, z_{k+1}) = (x_k + \alpha_k \Delta x_k, z_k + \alpha_k \Delta z_k).$$

De este modo, tenemos dos casos para escoger el tamaño del paso y dar un criterio de parada:

- Supongamos $Ax_k = b$, luego $A\Delta x_k = 0$ y por lo tanto $Ax_{k+1} = b$ sin importar la escogencia de α_k . Además,

$$\langle \nabla f(x_k), \Delta x_k \rangle = -\langle Hf(x_k)\Delta x_k, \Delta x_k \rangle,$$

luego Δx_k es una dirección de descenso y se puede hacer *backtracking* usando la condición de Armijo para escoger α_k . Finalmente, se puede usar $\langle Hf(x_k)\Delta x_k, \Delta x_k \rangle < \epsilon$ como criterio de parada.

- Supongamos que x_k no es factible. En este caso x_{k+1} no tiene que ser factible tampoco (si $\alpha_k \neq 1$) y además Δx_k no es necesariamente una dirección de descenso. Lo que sí se puede mostrar (inténtelo!) es que para α_k suficientemente pequeño se tiene que $\|G(x_{k+1}, z_{k+1})\| < \|G(x_k, z_k)\|$, luego se puede hacer *backtracking* buscando satisfacer la condición

$$\|G(x_{k+1}, z_{k+1})\| \leq (1 - c\alpha_k)\|G(x_k, z_k)\|.$$

Finalmente, se puede usar la condición $\|G(x_k, z_k)\| < \epsilon$ como criterio de parada.

Igual que en el caso sin restricciones, se puede empezar con el método amortiguado ($\alpha_k \neq 1$) y terminar con el método puro.

10.2. Método de barrera

Definición. Sea $Q \subset \mathbb{R}^n$ un conjunto cerrado con interior no vacío. Una función $\Phi : \mathbb{R}^n \rightarrow \mathbb{R}_+$ continua es una *función de barrera* para el conjunto Q si $\Phi(x_k) \rightarrow \infty$ siempre que $\text{dist}(x_k, \partial Q) \rightarrow 0$ y $x_k \in Q$.

Es fácil ver que si Φ_i es función de barrera de Q_i , $i = 1, \dots, n$, entonces $\sum_i \Phi_i$ es función de barrera de $\bigcap_i Q_i$ siempre que este conjunto tenga interior no vacío. Ahora, si el problema (35) satisface la condición de Slater, las siguientes son funciones de barrera para el conjunto factible $Q = \{x : g_i(x) \leq 0, i = 1, \dots, m\}$:

- Barrera potencia: $\Phi(x) = \sum_{i=1}^m \frac{1}{(-g_i(x))^p}$, con $p \geq 1$.
- Barrera exponencial: $\Phi(x) = \sum_{i=1}^m \exp(-g_i(x))$.
- Barrera logarítmica: $\Phi(x) = -\sum_{i=1}^m \log(-g_i(x))$.

Supongamos ahora que $f^* = \min_{x \in Q} f(x)$, y sean $x_0 \in \text{int}(Q)$ y $\{t_k\}_{k \geq 1}$ una sucesión de reales positiva y creciente tal que $t_k \rightarrow \infty$. El esquema general de los métodos de barrera es

$$x_{k+1} \in \arg \min_{x \in Q} f(x) + \frac{1}{t_k} \Phi(x) = \arg \min_{x \in Q} t_k f(x) + \Phi(x),$$

usando x_k como punto inicial (siempre que exista) para minimizar la función $\Phi_k(x) := f(x) + \frac{1}{t_k}\Phi(x)$. Si $\bar{x} \in Q$ y definimos $\Phi_k^* = \Phi_k(x_{k+1})$, es decir el valor mínimo de Φ_k , entonces

$$\limsup_{k \rightarrow \infty} \Phi_k^* \leq \lim_{k \rightarrow \infty} f(\bar{x}) + \frac{1}{t_k}\Phi(\bar{x}) = f(\bar{x}),$$

luego $\limsup_{k \rightarrow \infty} \Phi_k^* \leq f^*$. Por otro lado, si Φ^* es el valor mínimo de la función barrera, tenemos que

$$\Phi_k^* \geq \min_{x \in Q} f(x) + \frac{1}{t_k}\Phi(x) \geq f^* + \frac{1}{t_k}\Phi^*,$$

luego $\liminf_{k \rightarrow \infty} \Phi_k^* \geq f^*$.

El resultado anterior muestra la convergencia hacia el valor óptimo, pero también es importante entender el comportamiento de los puntos óptimos. Sea Q convexo y cerrado con interior no vacío, Φ una función de barrera para Q y f convexa tal que para todo $t \geq 0$ la función $tf(x) + \Phi(x)$ tenga en un único mínimo sobre Q , así, sea

$$x^*(t) = \arg \min_{x \in Q} tf(x) + \Phi(x).$$

Al camino $t \mapsto x^*(t)$ se le llama el *camino central* y a $x^*(0)$ el *centro analítico*. Tenemos entonces que el esquema más básico de seguimiento del camino central está dado por

- Iniciar con x_0 el centro analítico y $t_0 = 0$,
- $t_{k+1} = t_k + \delta_k$,
- $x_{k+1} = x^*(t_{k+1})$ donde se usa x_k para inicial el método de minimización.

Para poder implementar este método debemos definir varias cosas. La primera y más importante es ¿qué tipo de función barrera es mejor? Puesto que la idea es usar el método de Newton para resolver el problema de minimización, debemos buscar funciones con un buen comportamiento (al menos teórico) para este método, y la respuesta son funciones *self-concordant*. Para esto no solo es importante el tipo de función de barrera sino también las funciones g_i .

Nota. Ni la función e^x , ni $\frac{1}{x^p}$, $p > 0$ son funciones *self-concordant*.

Otra característica importante que debe cumplir Φ es que la complejidad del problema de minimización no debe incrementarse mucho cuando t es muy grande. Esta idea se desarrolla en el libro de Nesterov en las secciones 4.2.2 y 4.2.3 y se muestra que la barrera logarítmica con funciones g_i lineales o cuadráticas convexas satisface esta propiedad.

Otro punto importante del método es que seguir exactamente el camino central es muy costoso pues encontrar $x^*(t)$ exactamente requiere muchas iteraciones. Notemos que la condición de primer orden para x_{k+1} es

$$t_{k+1}\nabla f(x) + \nabla\Phi(x) = 0,$$

luego una condición aproximada que puede usarse para definir x_{k+1} está dada por

$$\|t_{k+1}\nabla f(x) + \nabla\Phi(x)\|_x^* := \langle H\Phi(x)(t_{k+1}\nabla f(x) + \nabla\Phi(x)), t_{k+1}\nabla f(x) + \nabla\Phi(x) \rangle^{1/2} \leq \beta,$$

para un parámetro β suficientemente pequeño. En ocasiones, esta condición se alcanza en un solo paso del método de Newton y en este caso se puede definir el esquema como

$$x_{k+1} = x_k - (t_{k+1}Hf(x_k) + H\Phi(x_k))^{-1} (t_{k+1}\nabla f(x_k) + \nabla\Phi(x_k)),$$

o usando el paso amortiguado de Newton.

Lo siguiente que se debe definir es el incremento en t_k , δ_k . Una posibilidad es un incremento de la forma $\delta_k = \mu t_k$, con $\mu > 0$ (e iniciando con $t_0 > 0$). Otra forma es tomar $\delta_k = \frac{\gamma}{\|\nabla f(x_k)\|_{x_k}^*}$, con $\gamma \in (0, 1)$.

Finalmente, para dar un criterio de parada, asumiendo la barrera logarítmica y Q el conjunto factible de (35), tenemos para $t > 0$, que $x^*(t)$ satisface $g_i(x^*(t)) < 0$ y además

$$t\nabla f(x^*(t)) - \sum_{i=1}^m \frac{\nabla g_i(x^*(t))}{g_i(x^*(t))} = 0,$$

luego, si x^* es óptimo del problema, tenemos que

$$\begin{aligned} 0 &= t\langle \nabla f(x^*(t)), x^*(t) - x^* \rangle - \sum_{i=1}^m \frac{\langle \nabla g_i(x^*(t)), x^*(t) - x^* \rangle}{g_i(x^*(t))} \\ &\geq t(f(x^*(t)) - f^*) + \sum_{i=1}^m \frac{g_i(x^*) - g_i(x^*(t))}{g_i(x^*(t))} \\ &= t(f(x^*(t)) - f^*) - m + \sum_{i=1}^m \frac{g_i(x^*)}{g_i(x^*(t))} \geq t(f(x^*(t)) - f^*) - m, \end{aligned}$$

es decir, $f(x^*(t)) - f^* \leq \frac{m}{t}$. Así que se puede usar como criterio de parada $\frac{m}{t_k} \leq \epsilon$.

10.2.1. Cono semidefinido positivo

Recordemos que en un problema de optimización de programación semidefinida el conjunto factible es un subconjunto de las matrices semidefinidas positivas, así que si queremos usar el método de la barrera para este problema debemos encontrar una función de barrera para este conjunto. Se puede mostrar (ver la sección 4.3.3 de Nesterov) que una función que cumple con todas las propiedades que buscamos está dada por $\Phi(X) = -\log \det X = \log \det X^{-1}$. Sabemos además que $\nabla\Phi(X) = -X^{-1}$ y además se tiene que

$$\langle H\Phi(X)Y, Y \rangle_F = \langle X^{-1}YX^{-1}, Y \rangle_F,$$

donde $\langle A, B \rangle_F := \text{tr}(AB)$, para A, B matrices simétricas.

10.3. Método primal-dual

Consideremos el problema

$$\begin{aligned} \text{mín} \quad & f(x) \\ \text{sujeto a} \quad & g(x) \leq 0 \\ & Ax = b, \end{aligned} \tag{39}$$

con f, g y A como en las secciones anteriores. Tenemos entonces que las condiciones de optimalidad KKT de (39) son

$$\begin{aligned}\nabla f(x) + \sum_{i=1}^m y_i \nabla g_i(x) + A^T z &= 0 \\ \langle y, g(x) \rangle &= 0 \iff -Yg(x) = 0\mathbf{1} \\ Ax &= b \\ g(x) &\leq 0 \\ y &\geq 0,\end{aligned}$$

donde $Y = \text{diag}(y)$ es una matriz diagonal con los valores de y en la diagonal, y $\mathbf{1}$ es el vector con todas sus entradas 1. Veremos más adelante la utilidad de escribir la segunda condición de esta forma (incluido el signo menos).

Una forma de motivar el método primal-dual es a partir del método de la barrera con barrera logarítmica (adicionando las restricciones de igualdad). Recordemos que para $t > 0$ debemos resolver el problema

$$\begin{aligned}\text{mín} \quad & f(x) - \frac{1}{t} \sum_{i=1}^m \log(-g_i(x)) \\ \text{sujeto a} \quad & Ax = b,\end{aligned} \tag{40}$$

y las condiciones de optimalidad KKT de (40) son

$$\begin{aligned}\nabla f(x) - \sum_{i=1}^m \frac{\nabla g_i(x)}{tg_i(x)} + A^T z &= 0 \\ Ax &= b \\ g(x) &\leq 0,\end{aligned}$$

que son equivalentes a

$$\begin{aligned}\nabla f(x) + \sum_{i=1}^m y_i \nabla g_i(x) + A^T z &= 0 \\ -y_i g_i(x) &= \frac{1}{t} \quad \forall i \iff -Yg(x) = \frac{1}{t}\mathbf{1} \\ Ax &= b \\ g(x) &\leq 0 \\ y &\geq 0.\end{aligned}$$

Igual que en el método de la barrera, la idea es hacer $t \rightarrow \infty$ y así aproximarnos al sistema de condiciones KKT del problema original. Análogamente, podemos definir el mapa $t \mapsto (x^*(t), y^*(t), z^*(t))$, llamado el *camino primal-dual*, donde $(x^*(t), y^*(t), z^*(t))$ son las soluciones del sistema anterior. Recordemos la función Lagrangeana asociada al problema (39):

$$\mathcal{L}(x, y, z) = f(x) + \sum_{i=1}^m y_i g_i(x) + \langle Ax - b, z \rangle,$$

y el problema dual

$$\max_{\lambda \geq 0} q(\lambda, \mu), \quad q(y, z) = \min_x \mathcal{L}(x, y, z).$$

Notemos entonces que

$$\begin{aligned} q(y^*(t), z^*(t)) &= \mathcal{L}(x^*(t), y^*(t), z^*(t)) \\ &= f(x^*(t)) - \frac{m}{t}, \end{aligned}$$

luego la brecha de dualidad asociado a $(x^*(t), y^*(t), z^*(t))$ es $\frac{m}{t}$.

Ahora, si nos olvidamos por un momento de las desigualdades, podemos intentar resolver este sistema no lineal usando el método de Newton. Igual que en el caso de los problemas con restricciones de igualdad, si (x, y, z) es tal que $g(x) < 0$ y $z > 0$, podemos encontrar el nuevo punto $(x^+, y^+, z^+) = (x, y, z) + (\Delta x, \Delta y, \Delta z)$ resolviendo el sistema

$$\begin{bmatrix} Hf(x) + \sum_{i=1}^m Hg_i(x) & \nabla g(x) & A^T \\ Y \nabla g(x) & \text{diag}(g(x)) & 0 \\ A & 0 & 0 \end{bmatrix} \begin{bmatrix} \Delta x \\ \Delta y \\ \Delta z \end{bmatrix} = - \begin{bmatrix} \nabla f(x) + \sum_{i=1}^m y_i \nabla g_i(x) + A^T z \\ Y g(x) + \frac{1}{t} \mathbf{1} \\ Ax - b \end{bmatrix}.$$

El lado derecho de este sistema lo denotamos como $r_t(x, y, z) = (r_t^d, r_t^c, r_t^p)$. La primer idea sería entonces hacer las iteraciones generadas por el método de Newton hasta obtener $r_t(x, y, z) = 0$, aumentar t y volver a solucionar el sistema. Esto, de nuevo, puede ser muy costoso y en realidad no es necesario estar siempre sobre el camino primal-dual. Veamos el método básico primal-dual:

```

Escoger parámetros  $\epsilon_f > 0, \epsilon > 0, \beta \in (0, 1), \theta \in (0, 1)$  y  $\sigma > 1$ ;
Escoger  $(x, y, z)$  tales que  $g(x) < 0$  y  $y > 0$ ;
repetir
     $t \leftarrow \sigma \frac{m}{\langle y, -g(x) \rangle}$ ;
    Calcular  $(\Delta x, \Delta y, \Delta z)$ ;
    Definir  $\bar{\alpha} = \min \left\{ 1, \min_{\Delta y_i < 0} -\frac{y_i}{\Delta y_i} \right\}$ ;
     $\alpha \leftarrow 0.99\bar{\alpha}$ ;
    mientras  $g(x^+) < 0$  y  $\|r_t(x^+, y^+, z^+)\| \leq (1 - \theta\alpha)\|r_t(x, y, z)\|$ , donde
         $(x^+, y^+, z^+) = (x, y, z) + \alpha(\Delta x, \Delta y, \Delta z)$  hacer
        |  $\alpha \leftarrow \beta\alpha$ 
    fin
hasta que  $\|r_t^d\| + \|r_t^p\| < \epsilon_f$  y  $\langle y, -g(x) \rangle < \epsilon$ ;

```

Algoritmo 4: Método primal-dual

Finalmente, podemos preguntarnos ¿por qué no resolver el sistema de ecuaciones que resulta del problema (39) directamente? Generalmente, esto resulta en que los tamaños de los pasos que evitan la infactibilidad de x y/o y son muy pequeños y por lo tanto harían el método más lento.

10.3.1. Programación lineal

Veamos ahora cómo se ve el algoritmo anterior en el caso de optimización lineal. En este caso el problema tiene la forma

$$\begin{aligned} \text{mín} \quad & \langle c, x \rangle \\ \text{sujeto a} \quad & Ax = b \\ & x \geq 0, \end{aligned} \tag{41}$$

y las condiciones de optimalidad son

$$\begin{aligned} A^T z + y - c &= 0 \\ \langle y, x \rangle = 0 &\iff Yx = 0 \\ Ax &= b \\ x &\geq 0 \\ y &\geq 0, \end{aligned}$$

con $Y = \text{diag}(y)$. Sabemos que para todo x factible para el primal, es decir, tal que $Ax = b$ y $x \geq 0$, y todo (y, z) factible para el dual, es decir, tal que $c - y - A^T z = 0$ y $y \geq 0$, entonces la brecha de dualidad está dada por $\langle y, x \rangle$. Esto nos permite encontrar $(\Delta x, \Delta y, \Delta z)$ resolviendo el sistema

$$\begin{bmatrix} 0 & I & A^T \\ Y & X & 0 \\ A & 0 & 0 \end{bmatrix} \begin{bmatrix} \Delta x \\ \Delta y \\ \Delta z \end{bmatrix} = - \begin{bmatrix} A^T z + y - c \\ Yx - \frac{\langle y, x \rangle}{\sigma n} \mathbf{1} \\ Ax - b \end{bmatrix},$$

donde $X = \text{diag}(x)$ y $\sigma > 1$.

Hay varias modificaciones que se le pueden hacer al algoritmo básico en el caso de optimización lineal, una de ellas es el algoritmo *predictor-corrector* de Mehrotra. En este método primero se calcula un paso *predictor* resolviendo el sistema

$$\begin{bmatrix} 0 & I & A^T \\ Y & X & 0 \\ A & 0 & 0 \end{bmatrix} \begin{bmatrix} \Delta x^{pr} \\ \Delta y^{pr} \\ \Delta z^{pr} \end{bmatrix} = - \begin{bmatrix} A^T z + y - c \\ Yx \\ Ax - b \end{bmatrix},$$

que es el sistema que resulta de tratar de solucionar las condiciones de optimalidad del problema original. Si se avanzara dando el paso completo, es decir, si $(x^+, y^+, z^+) = (x, y, z) + (\Delta x^{pr}, \Delta y^{pr}, \Delta z^{pr})$, se tendría que

$$X^+ y^+ = Xy + X\Delta y^{pr} + Y\Delta x^{pr} + \Delta Y^{pr} \Delta x^{pr} = \Delta Y^{pr} \Delta x^{pr},$$

que no es necesariamente cero, y se puede usar esta información para dar un paso *corrector*, como veremos más adelante, incorporando el término de *centrado* $\frac{\langle y, x \rangle}{\sigma n} \mathbf{1}$. El paso *predictor* también se puede usar para estimar el factor σ , para esto primero se debe calcular el tamaño de paso más grande que se puede dar sin perder la factibilidad, esto es

$$\begin{aligned} \alpha_p^{pr} &:= \min \left\{ 1, \min_{\Delta x_i^{pr} < 0} -\frac{x_i}{\Delta x_i^{pr}} \right\}, \\ \alpha_d^{pr} &:= \min \left\{ 1, \min_{\Delta y_i^{pr} < 0} -\frac{y_i}{\Delta y_i^{pr}} \right\}. \end{aligned}$$

La idea es que si estos tamaños de paso son grandes, quiere decir que no es necesario “centrar” y por lo tanto σ puede ser grande, de lo contrario es necesario pegarse más al camino primal-dual y por lo tanto σ no puede ser muy grande, así se define (de forma heurística)

$$\sigma = \left(\frac{\langle y, x \rangle}{\langle x + \alpha_p^{pr} \Delta x^{pr}, y + \alpha_d^{pr} y^{pr} \rangle} \right)^3,$$

y con esto se resuelve el sistema

$$\begin{bmatrix} 0 & I & A^T \\ \Lambda & X & 0 \\ A & 0 & 0 \end{bmatrix} \begin{bmatrix} \Delta x \\ \Delta y \\ \Delta z \end{bmatrix} = - \begin{bmatrix} A^T z + y - c \\ Yx + \Delta Y^{pr} \Delta x^{pr} - \frac{\langle y, x \rangle}{\sigma n} \mathbf{1} \\ Ax - b \end{bmatrix}.$$

Con este nuevo paso, podemos definir tamaños de paso distinto para cada variable, tal como hicimos en el caso del paso *predictor*, esto es

$$\alpha_p := \min \left\{ 1, \eta \min_{\Delta x_i < 0} -\frac{x_i}{\Delta x_i} \right\},$$

$$\alpha_d := \min \left\{ 1, \eta \min_{\Delta y_i < 0} -\frac{y_i}{\Delta y_i} \right\},$$

donde η es un parámetro que puede ir acercándose a 1 a medida que avanza el método. Finalmente, los valores actualizados de las variables se definen como

$$(x^+, y^+, z^+) = (x, y, z) + (\alpha_p \Delta x, \alpha_d \Delta y, \alpha_d \Delta z).$$

Notemos que en cada paso del algoritmo se debe resolver dos veces un sistema de la forma

$$\begin{bmatrix} 0 & I & A^T \\ \Lambda & X & 0 \\ A & 0 & 0 \end{bmatrix} \begin{bmatrix} \Delta x \\ \Delta y \\ \Delta z \end{bmatrix} = - \begin{bmatrix} r^d \\ r^c \\ r^p \end{bmatrix},$$

es decir, solo cambia el lado derecho del sistema. Como en cada iteración tanto x como λ tiene entradas estrictamente positivas, entonces las matrices X y Y son invertibles, luego podemos simplificar el sistema eliminando la variable $\Delta y = -X^{-1}r^c - X^{-1}Y\Delta x$ para obtener

$$\begin{bmatrix} -D^{-2} & A^T \\ A & 0 \end{bmatrix} \begin{bmatrix} \Delta x \\ \Delta z \end{bmatrix} = - \begin{bmatrix} r^d - X^{-1}r^c \\ r^p \end{bmatrix},$$

donde $D = Y^{-1/2}X^{1/2}$. Se puede seguir simplificando, ahora eliminando $\Delta x = D^2 A^T \Delta z + D^2 r^d - Y^{-1}r^c$ y como $A\Delta x = -r^p$, entonces

$$AD^2 A^T \Delta z = -r^p - AXY^{-1}r^d + AY^{-1}r^c.$$

Este último sistema es más pequeño que el original y la matriz $AD^2 A^T$ es definida positiva bajo las hipótesis sobre A . Además, se puede factorizar (Cholesky, por ejemplo) y usar esta factorización para resolver los dos sistemas que se deben resolver en cada iteración.

10.3.2. Programación cuadrática

Consideremos el siguiente problema de optimización cuadrática:

$$\begin{aligned} \text{mín} \quad & \frac{1}{2} \langle Gx, x \rangle + \langle c, x \rangle \\ \text{sujeto a} \quad & Ax \geq b, \end{aligned} \tag{42}$$

donde G es definida positiva. Las condiciones de optimalidad son

$$\begin{aligned} Gx + A^T y + c &= 0 \\ Yz &= 0 \\ Ax + z - b &= 0 \\ z &\geq 0 \\ y &\geq 0, \end{aligned}$$

y en este caso la brecha de dualidad está dada por $\frac{\langle y, z \rangle}{m}$. Así que el paso de Newton se encuentra resolviendo el sistema

$$\begin{bmatrix} G & A^T & 0 \\ 0 & Z & Y \\ A & 0 & I \end{bmatrix} \begin{bmatrix} \Delta x \\ \Delta y \\ \Delta z \end{bmatrix} = - \begin{bmatrix} Gx + A^T y + c \\ Yz - \frac{\langle y, z \rangle}{\sigma m} \mathbf{1} \\ Ax + z - b \end{bmatrix},$$

con $\sigma > 1$. Igual que en el caso de programación lineal podemos usar un algoritmo *predictor-corrector*. Primero debemos encontrar el paso *predictor* resolviendo el sistema

$$\begin{bmatrix} G & A^T & 0 \\ 0 & Z & Y \\ A & 0 & I \end{bmatrix} \begin{bmatrix} \Delta x^{pr} \\ \Delta y^{pr} \\ \Delta z^{pr} \end{bmatrix} = - \begin{bmatrix} Gx + A^T y + c \\ Yz \\ Ax + z - b \end{bmatrix},$$

con (x, y, z) tal que $y > 0$ y $z > 0$. Para encontrar el tamaño del paso *predictor*, que en este caso se usa el mismo tanto para el paso primal como para el dual, se calcula

$$\alpha^{pr} := \min \left\{ 1, \min_{\Delta x_i^{pr} < 0} -\frac{x_i}{\Delta x_i^{pr}}, \min_{\Delta z_i^{pr} < 0} -\frac{z_i}{\Delta z_i^{pr}} \right\},$$

y con esto se estima el valor de σ como

$$\sigma = \left(\frac{\langle y, z \rangle}{\langle y + \alpha^{pr} \Delta y^{pr}, z + \alpha^{pr} \Delta z^{pr} \rangle} \right)^3.$$

Con este valor de σ se resuelve el sistema

$$\begin{bmatrix} G & A^T & 0 \\ 0 & Z & Y \\ A & 0 & I \end{bmatrix} \begin{bmatrix} \Delta x \\ \Delta y \\ \Delta z \end{bmatrix} = - \begin{bmatrix} Gx + A^T y + c \\ Yz + \Delta Y^{pr} \Delta z^{pr} - \frac{\langle y, z \rangle}{\sigma n} \mathbf{1} \\ Ax + z - b \end{bmatrix},$$

para calcular el paso *corrector*. Definimos el tamaño de paso como

$$\alpha := \min \left\{ 1, \eta \min_{\Delta y_i < 0} -\frac{y_i}{\Delta y_i}, \eta \min_{\Delta z_i < 0} -\frac{z_i}{\Delta z_i} \right\},$$

donde η es un parámetro que puede ir acercándose a 1 a medida que avanza el método. Finalmente, los valores actualizados de las variables se definen como

$$(x^+, y^+, z^+) = (x, y, z) + \alpha(\Delta x, \Delta y, \Delta z).$$

Igual que en el caso de programación lineal, podemos reducir el tamaño de los sistemas que debemos resolver en cada iteración. Primero eliminamos la variable $\Delta z = -Y^{-1}r^c - Y^{-1}Z\Delta y$ para obtener

$$\begin{bmatrix} G & A^T \\ A & Y^{-1}Z \end{bmatrix} \begin{bmatrix} \Delta x \\ \Delta y \end{bmatrix} = - \begin{bmatrix} r^d \\ r^p + Y^{-1}r^c \end{bmatrix},$$

y eliminando la variable $\Delta y = -Z^{-1}Yr^p - Z^{-1}r^c - Z^{-1}YA\Delta x$, obtenemos

$$(G - A^T Z^{-1} Y A) \Delta x = -r^d + A^T Z^{-1} r^c + A^T Z^{-1} Y r^p.$$

Lo anterior puede ser eficiente si $A^T Z^{-1} Y A$ es dispersa.

10.3.3. Programación semidefinida

Por último, consideremos el siguiente problema de programación semidefinida

$$\begin{aligned} \text{mín} \quad & \langle C, X \rangle_F \\ \text{sujeto a} \quad & \langle A_i, X \rangle_F = b_i, \quad i = 1, \dots, m \\ & X \succeq 0, \end{aligned} \tag{43}$$

y su problema dual

$$\begin{aligned} \text{máx} \quad & \langle b, z \rangle \\ \text{sujeto a} \quad & \sum_{i=1}^m z_i A_i + Y = C \\ & Y \succeq 0. \end{aligned} \tag{44}$$

En este caso las condiciones de optimalidad son (compare con las de programación lineal)

$$\begin{aligned} \sum_{i=1}^m z_i A_i + Y - C &= 0 \\ XY &= 0 \\ \langle A_i, X \rangle_F &= b_i, \quad i = 1, \dots, m \\ X &\succeq 0 \\ Y &\succeq 0. \end{aligned}$$

Una forma de obtener las condiciones anteriores es a partir del método de barrera para matrices semidefinidas, así que podemos aproximar el problema (43) por el problema

$$\begin{aligned} \text{mín} \quad & \langle C, X \rangle_F - \frac{1}{t} \log \det X \\ \text{sujeto a} \quad & \langle A_i, X \rangle_F = b_i, \quad i = 1, \dots, m, \end{aligned} \tag{45}$$

cuyas condiciones de optimalidad KKT son

$$\begin{aligned}\sum_{i=1}^m z_i A_i + \frac{1}{t} X^{-1} - C &= 0 \\ \langle A_i, X \rangle_F &= b_i, \quad i = 1, \dots, m, \\ X &\succeq 0,\end{aligned}$$

que son a su vez equivalentes a

$$\begin{aligned}\sum_{i=1}^m z_i A_i + Y - C &= 0 \\ Y &= \frac{1}{t} X^{-1} \iff XY = \frac{1}{t} I \\ \langle A_i, X \rangle_F &= b_i, \quad i = 1, \dots, m, \\ X &\succeq 0 \\ Y &\succeq 0.\end{aligned}$$

Así que el paso de Newton se encuentra resolviendo el sistema

$$\begin{aligned}\sum_{i=1}^m \Delta z_i A_i + \Delta Y &= -\sum_{i=1}^m z_i A_i - Y + C \\ X \Delta Y + \Delta X Y &= -XY + \frac{1}{t} I \\ \langle A_i, \Delta X \rangle_F &= -\langle A_i, X \rangle_F + b_i, \quad i = 1, \dots, m.\end{aligned}$$

Queremos que ΔX y ΔY sean simétricas para que todas las iteraciones del método lo sean, pero, al resolver el sistema, esto no lo podemos garantizar pues XY no lo es necesariamente (solo podemos garantizar que ΔY es simétrica con la primera ecuación). Una opción es reemplazar la ecuación $XY - \frac{1}{t} I = 0$ por $Y - \frac{1}{t} X^{-1} = 0$, que al linealizar obtenemos la ecuación lineal

$$\Delta Y + \frac{1}{t} X^{-1} \Delta X X^{-1} = -Y + \frac{1}{t} X^{-1},$$

o podemos también usar la ecuación $X - \frac{1}{t} Y^{-1} = 0$, que al linealizar obtenemos

$$\Delta X + \frac{1}{t} Y^{-1} \Delta Y Y^{-1} = -X + \frac{1}{t} Y^{-1}.$$

Una forma de usar la información de ambas posibilidades es con la ecuación

$$\Delta X + W \Delta Y W = \frac{1}{t} Y^{-1} - X,$$

donde

$$W = X^{1/2} (X^{1/2} Y X^{1/2})^{-1/2} X^{1/2}.$$

A esto se le conoce como el método de Nesterov-Todd.